



國立中山大學應用數學系

碩士論文

Department of Applied Mathematics

National Sun Yat-sen University

Master's Thesis

**基於 FreeSurfer 腦結構量化特徵與臨床資料之失智症
分類研究：特徵篩選、多模型比較與集成學習**

Dementia Classification Using FreeSurfer-Derived Brain
Structural Quantitative Features and Clinical Data: Feature
Selection, Multi-Model Comparison, and Ensemble Learning

研究生：林彥宏

Yan-Hong Lin

指導教授：張福春博士

Dr. Fu-Chuen Chang

中華民國 115 年 8 月

August 2026

國立中山大學研究生學位論文審定書

本校應用數學系碩士班

研究生林彥宏（學號：M132040017）所提論文

基於 FreeSurfer 腦結構量化特徵與臨床資料之失智症分類研究：特徵篩選、多模型比較與集成學習

Dementia Classification Using FreeSurfer-Derived Brain Structural Quantitative Features and Clinical Data: Feature Selection, Multi-Model Comparison, and Ensemble Learning

於中華民國 115 年 7 月 20 日經本委員會審查並舉行口試，符合碩士學位論文標準。

學位考試委員簽章：

召集人 沈秀祝 沈秀祝

委員 張福春 張福春

委員 張中 張中

委員 于松桓 于松桓

委員 鍾思齊 鍾思齊

委員 _____

指導教授(張福春) 張福春 (簽名)

致謝

兩年的碩士班生活即將告一段落。首先，感謝指導教授張福春老師這兩年的教導。一年級時，老師帶領我們閱讀書籍與文獻，協助建立課業與研究基礎；二年級則從論文方向、實驗設計到內容撰寫，一步一步引導我完成研究。除了學業上的指導，老師也曾邀請我們參與教會活動，並帶我們去爬山、吃牛肉麵，為碩士班生活增添許多珍貴回憶。也感謝在學期間教導我的老師們，扎實的課程讓我學習到不同領域的知識，多次的報告也使我逐漸克服上臺時的緊張，學習如何整理內容並清楚表達自己的想法。感謝各位口試委員願意撥空閱讀我的論文，並提供相關建議，使我能檢視並補充不足之處，讓論文內容能夠更加完整。

求學過程中，家人始終無條件支持我的生活，而我也能夠專注於課業與研究，不必為其他事情煩惱；朋友們的陪伴，也讓我在繁忙的碩班生活中適時放鬆，大家彼此分享生活、討論遇到的困難，留下了許多特別的經歷。此外，我也要特別感謝周遭的狗狗與貓咪。每次回家時，饅頭與肥肥總會特別熱情，開心地跑過來迎接我；租屋處樓下的小貓們，則讓我每次從學校回家時，都期待摸摸牠們、餵一些零食，總能讓疲憊的身心得到滿滿的能量與溫暖。

最後，謝謝一路上所有曾經幫助、陪伴與鼓勵過我的人，讓我得以順利完成課業與論文。這段歷程留下了許多充實而珍貴的回憶，也將成為我繼續前進的重要養分。期許自己帶著這些收穫與祝福，踏實地走向下一段旅程。

林彥宏 謹於

國立中山大學

中華民國 115 年 8 月

摘要

失智症為一種以認知功能持續退化為核心特徵的神經退化性疾病。隨著高齡化加劇，早期辨識與客觀評估日益重要。結構式腦部磁振造影 (magnetic resonance imaging, MRI) 搭配 FreeSurfer 自動化分析工具，可系統性萃取腦區體積、皮質厚度與表面積等量化特徵，補充臨床量表較難直接反映之腦部結構資訊。

本研究使用高雄榮民總醫院提供之 3D T1 加權 MRI 影像與臨床資料，並以 FreeSurfer 萃取腦結構量化特徵，建立三項二元分類任務：失智症對非失智症、認知異常對正常及輕度認知障礙對正常。共納入 378 位受試者，包括失智症 85 位、輕度認知障礙 233 位及認知正常 60 位。研究比較純影像、純臨床及臨床加影像三類特徵設定，流程包括影像方向篩選、估計顱內總體積 (eTIV) 校正評估、多模型比較、特徵排序、機率校準、閾值調整、集成學習，以及完整臨床基準下之影像增量分析；正式實驗採用 20 個隨機種子搭配 5-fold 交叉驗證評估模型表現。

結果顯示，三項任務的優勢影像組合不同，純影像特徵具一定判別力，判別訊號集中於海馬迴、杏仁核、皮質下結構與部分皮質分區；eTIV 校正未改善分類效能。特徵排序顯示，臨床認知量表多位於排序前段，影像特徵分布則具神經解剖意義。多模型比較中，ElasticNet Logistic Regression 與 RidgeClassifier 等線性模型整體較為穩定，TabPFN 則多具有較高的 AUC 與較佳的機率品質。純臨床特徵呈現最佳且較穩定的整體表現，部分集成設定可取得接近最佳單一模型的表現。在完整臨床基準下，新增影像特徵的整體增量效益有限，但仍可提供臨床量表以外、具有神經解剖解釋性的補充證據。

關鍵詞：腦部磁振造影、臨床特徵、機器學習、集成學習、失智症、影像增量分析、FreeSurfer

Abstract

Dementia is a neurodegenerative disorder characterized primarily by progressive cognitive decline. As populations continue to age, the early identification and objective assessment of dementia have become increasingly important. Structural magnetic resonance imaging (MRI) of the brain, combined with FreeSurfer, an automated neuroimaging analysis tool, enables the systematic extraction of quantitative measures such as regional brain volumes, cortical thickness, and cortical surface area, thereby providing structural brain information that may not be directly captured by clinical assessment scales.

This study used three-dimensional T1-weighted MRI scans and clinical data provided by Kaohsiung Veterans General Hospital and extracted quantitative structural brain features using FreeSurfer. Three binary classification tasks were established: dementia versus non-dementia, abnormal cognition versus normal cognition, and mild cognitive impairment versus normal cognition. A total of 378 participants were included, comprising 85 participants with dementia, 233 with mild cognitive impairment, and 60 with normal cognition. The study compared imaging-only, clinical-only, and combined clinical-imaging feature settings. The workflow included screening of imaging feature combinations, evaluation of estimated total intracranial volume (eTIV) correction, multi-model comparison, feature ranking, probability calibration, decision-threshold adjustment, ensemble learning, and assessment of the incremental value of imaging against a comprehensive clinical baseline. Model performance in the formal experiments was evaluated using 5-fold cross-validation repeated across 20 random seeds.

The results showed that the best-performing imaging feature combinations differed across the three tasks. Imaging features alone demonstrated discriminative capability,

with relevant signals concentrated in the hippocampus, amygdala, subcortical structures, and selected cortical regions, whereas eTIV correction did not improve classification performance. Feature ranking showed that clinical cognitive scales generally occupied the top positions, while imaging features exhibited neuroanatomically meaningful distributions. In the multi-model comparison, linear models such as ElasticNet Logistic Regression and RidgeClassifier showed relatively stable performance, whereas TabPFN often achieved higher AUC values and better-quality probability estimates. Clinical features alone yielded the best and relatively stable overall performance, and some ensemble configurations approached the performance of the best individual model. Although the overall incremental benefit of adding imaging features to a comprehensive clinical baseline was limited, these features still provided complementary, neuroanatomically interpretable evidence in addition to that captured by clinical assessment scales.

Keywords: Clinical features, Dementia, Ensemble learning, FreeSurfer, Incremental value of imaging, Machine learning, Structural magnetic resonance imaging

目 錄

論文審定書	i
致謝	ii
摘要	iii
Abstract	iv
目錄	vi
圖次	x
表次	xi
第一章 緒論	1
1.1 研究背景	1
1.2 研究動機與目的	2
1.3 研究流程與架構	3
第二章 文獻回顧	4
2.1 失智症、輕度認知障礙與臨床認知評估	4
2.2 結構式 MRI 與 FreeSurfer 腦結構量化特徵	5
2.3 腦體積校正	6
2.4 臨床與影像資料之機器學習分類	7
2.5 機率校準、閾值調整與集成融合方法	8
第三章 資料介紹與前處理	10
3.1 資料來源	10
3.2 臨床資料	11
3.3 原始 3D T1 影像	12

3.4	FreeSurfer 影像處理	13
3.5	資料前處理	16
3.5.1	樣本與特徵清理	16
3.5.2	分類任務與交叉驗證切分	18
3.5.3	折內前處理	19
第四章	研究方法	22
4.1	整體研究架構	22
4.2	交叉驗證與評估框架	24
4.3	分類模型	25
4.3.1	線性模型	26
4.3.2	樹集成模型	28
4.3.3	核方法與距離法	29
4.3.4	機率生成模型	30
4.3.5	表格式基礎模型 TabPFN	30
4.3.6	模型彙整	31
4.3.7	評估指標	32
4.3.8	統計檢定	33
4.4	影像方向篩選	35
4.5	eTIV 線性關聯檢定與體積校正	36
4.6	多模型基線比較	38
4.7	特徵排序與特徵數選擇	39
4.8	整合分析：Phase 1–4	40
4.8.1	Phase 1：主基線實驗	40
4.8.2	Phase 2：機率校準	42
4.8.3	Phase 3：閾值調整與操作點	43

4.8.4	Phase 4：集成學習	44
4.9	完整臨床基準下之影像增量分析設計	47
4.9.1	三種模態融合	47
4.9.2	資料組成與影像特徵排序	48
4.9.3	影像特徵數 K 之選擇	48
4.9.4	統一模型陣容與訓練設定	50
4.9.5	增量價值檢驗	51
4.9.6	操作點與多閾值報告	51
4.9.7	集成與晚期融合分析	52
4.10	中期融合神經網路	53
4.10.1	模型定位	53
4.10.2	網路架構與訓練設定	53
第五章	實驗結果與討論	55
5.1	影像方向篩選結果	55
5.2	eTIV 線性相關性檢定與校正結果	57
5.3	候選方向與模型篩選	58
5.3.1	全特徵多模型基線與模型方向整合篩選	58
5.3.2	主要方向之特徵排序	64
5.3.3	Top- N 特徵數掃描與篩選	66
5.3.4	後續主要分析設定	67
5.4	整合分析：Phase 1–4 結果	68
5.4.1	Phase 1：正式基線	68
5.4.2	Phase 2：機率校準	71
5.4.3	Phase 3：閾值調整與操作點	73
5.4.4	Phase 4：集成學習	75

5.5	完整臨床基準下之影像增量分析	78
5.5.1	純影像特徵數篩選與組成	78
5.5.2	純臨床、純影像與融合方向之分類表現	80
5.5.3	影像特徵之 AUC 增量比較	81
5.5.4	操作點比較	83
5.5.5	方向內集成與晚期融合	84
5.5.6	不同融合層級之整體比較	85
5.5.7	固定參數敏感度分析	86
第六章	結論與未來展望	87
6.1	研究結論與貢獻	87
6.2	研究限制與未來展望	91
	參考文獻	94
	附錄	99
A	人體研究倫理審查資訊	99
B	詳細臨床資料欄位	100
C	3D T1 DICOM 序列資訊	102
D	FreeSurfer 軟體資訊	102
E	影像方向篩選完整結果	103
F	eTIV 線性相關性檢定與校正	106
G	主要方向特徵排序	107
H	Phase 2 逐模型校準補充結果	112
I	完整臨床基準下之影像增量補充	112
J	固定參數敏感度分析	116

圖 次

圖 3-1	受試者 C001 之 3D T1 三軸中間剖面	13
圖 4-1	整體研究架構與分析流程	23
圖 4-2	NN_fusion 中期融合神經網路架構	54
圖 5-1	任務一 APARC_ASEG_AMYG 方向之全特徵多模型基線表現	59
圖 5-2	任務二 HIPPO_ASEG 方向之全特徵多模型基線表現	59
圖 5-3	任務三 HIPPO 方向之全特徵多模型基線表現	60
圖 5-4	Top- N 特徵數掃描結果	66
圖 5-5	RidgeClassifier 四個主要資料方向之可靠度圖	72
圖 5-6	完整臨床基準分析之純影像 Top- K 特徵數篩選	78
圖 5-7	完整臨床基準分析之純影像 Top- K 特徵組成	79
圖 5-8	完整臨床基準下之逐模型 AUC 增量	82
圖 G.1	Top- N 特徵數掃描之 AUC 結果	111
圖 I.1	E2d convexSL 之資料方向權重	115

表 次

表 3-1	最終納入分析樣本之類別組成（共 378 位）	11
表 3-2	受試者 C001 之 SER00001 影像與處理資訊	12
表 3-3	本研究使用之 FreeSurfer 特徵群組	14
表 3-4	資料整合與清理各階段之樣本數及特徵數變化	17
表 3-5	三項二元分類任務之定義與樣本配置	18
表 4-1	本研究主要資料方向與任務配置	24
表 4-2	各模型訓練階段之外層交叉驗證與內層評分設定	26
表 4-3	本研究各分析階段涉及之 13 種基礎分類模型	31
表 4-4	影像方向篩選之模型與訓練設定	35
表 4-5	Phase 1 各模型之主要超參數搜尋格點	41
表 4-6	Phase 3 之四種操作點（閾值）	43
表 4-7	Top- <i>K</i> 掃描之模型與超參數設定	49
表 4-8	影像增量分析採用之統一模型陣容	50
表 4-9	完整臨床基準分析新增模型之超參數搜尋範圍	50
表 5-1	第一輪單一影像群組之分類表現	55
表 5-2	三輪影像方向篩選之各輪最高方向	56
表 5-3	三項分類任務保留之候選影像方向	57
表 5-4	任務一各候選方向之全特徵多模型表現	61
表 5-5	任務二各候選方向之全特徵多模型表現	62
表 5-6	任務三各候選方向之全特徵多模型表現	63
表 5-7	任務一主要方向之特徵排序前 15 名	64
表 5-8	任務二與任務三主要方向之特徵排序前 15 名	65
表 5-9	各任務後續主要分析設定	67
表 5-10	Phase 1 任務一各方向之逐模型結果	68
表 5-11	Phase 1 任務二各方向之逐模型結果	69
表 5-12	Phase 1 任務三各方向之逐模型結果	70
表 5-13	Phase 2 各任務與資料方向之模型平均校準結果	71
表 5-14	Platt 校準後各任務於不同閾值目標下之操作點與分類表現	73
表 5-15	Phase 4 方向內集成與最佳單一模型比較 (Platt + Youden)	75
表 5-16	Phase 4 跨方向集成之 BalAcc 比較	76
表 5-17	Phase 4 最佳 convexSL 集成之方向別權重	76
表 5-18	完整臨床基準分析之主要分類表現	80
表 5-19	完整臨床基準下之逐模型 AUC 增量比較摘要	81

表 5-20	完整臨床基準分析於不同操作目標下之最佳結果	83
表 5-21	方向內集成與跨方向晚期融合之最佳結果	84
表 5-22	完整臨床基準下不同融合層級之表現比較	85
表 A.1	各資料組別之人體研究倫理審查資訊	99
表 B.1	原始臨床資料欄位一覽	100
表 C.1	受試者 C001 之 3D T1 DICOM 序列資訊	102
表 D.1	FreeSurfer 軟體與執行資訊	102
表 E.1	任務一之 FreeSurfer 影像方向篩選結果	103
表 E.2	任務二之 FreeSurfer 影像方向篩選結果	104
表 E.3	任務三之 FreeSurfer 影像方向篩選結果	105
表 F.1	eTIV 線性相關性檢定之群組結果	106
表 F.2	eTIV 顯著性檢定之代表性特徵 (Normal 子群, $n = 60$)	106
表 F.3	eTIV 校正前後之分類表現	107
表 G.1	任務一 APARC_ASEG_AMYG 方向之 Top-30 特徵排序	107
表 G.2	任務一 APARC_ASEG_HIPPO 方向之 Top-30 特徵排序	108
表 G.3	任務二 HIPPO_ASEG 方向之 Top-30 特徵排序	109
表 G.4	任務三 HIPPO 方向之 Top-30 特徵排序	110
表 H.1	Phase 2 各校準方法取得最低 Brier score 與 ECE 之次數	112
表 H.2	Phase 2 校準方法相對 Raw 之逐模型改善情況	112
表 I.1	Clin33_FS_topK 相對 Clin33 之逐模型 AUC 重複切分比較	113
表 I.2	完整臨床基準下之任務層級 AUC 增量比較摘要	115
表 J.1	固定超參數眾數選取之穩定性摘要	116
表 J.2	固定參數與逐折調參之 Phase 1–3 與影像增量主要差異摘要	117
表 J.3	Phase 4 最佳集成管線之固定參數敏感度摘要	117
表 J.4	完整臨床基準下最佳晚期融合之固定參數敏感度比較	117

第一章 緒論

1.1 研究背景

失智症 (Dementia) 是一種以認知功能持續退化為特徵的神經退化性疾病。隨著病程進展，記憶、語言、判斷力、執行功能與日常生活能力逐漸惡化，不僅影響自主生活，也增加家庭照護與醫療資源負擔。根據衛生福利部公布之「全國社區失智症流行病學調查」¹，臺灣 65 歲以上社區長者之失智症盛行率為 7.99%，並隨年齡上升，顯示失智症已成為高齡社會的公共衛生議題。認知狀態可涵蓋正常、輕度認知障礙 (Mild Cognitive Impairment, MCI) 與失智症等階段，因此辨識不同程度之認知異常，對後續追蹤、介入與照護安排具有重要意義。

臨床認知退化評估多依賴認知量表、病史、功能狀態與醫師判斷。簡易智能狀態檢查 (Mini-Mental State Examination, MMSE) 與認知能力篩檢量表 (Cognitive Abilities Screening Instrument, CASI) 可直接反映受試者當下的認知表現，具施測方便與臨床可解釋性等優點，但較難提供腦部結構退化的客觀量化資訊。相較之下，結構式腦部磁共振造影 (structural magnetic resonance imaging, structural MRI) 搭配 FreeSurfer 等自動化分析工具，可萃取腦區體積、皮質厚度與表面積等量化特徵，提供臨床量表以外的腦部形態資訊。

近年來，機器學習已應用於失智症與認知障礙之分類研究，可整合臨床資料與腦影像特徵建立分類模型，比較不同資訊來源對分類結果的貢獻。此類方法亦提供系統化分析架構，探討臨床表現、腦部結構變化與認知退化之間的關聯。

¹資料來源：衛生福利部官方網站，<https://www.mohw.gov.tw/cp-16-78102-1.html> (存取日期：2026 年 8 月 8 日)。

1.2 研究動機與目的

臨床資料可反映受試者的認知表現、病史與功能狀態，而腦部 MRI 影像經 FreeSurfer 自動化處理後 [1]²，可提供腦區體積、皮質厚度、表面積及腦區分區等結構量化特徵。兩類資料分別呈現臨床表現與神經解剖層面的資訊，因此本研究希望透過機器學習方法整合兩者，評估影像資訊是否能補充臨床資料並改善失智症與認知異常相關任務的分類能力；同時透過比較不同分類任務、影像特徵組合（後續稱影像方向）、模型設定與融合方式，評估分類表現的變化，釐清各類資訊的實際貢獻、互補關係與表現穩定性。基於上述動機，本研究以高雄榮民總醫院提供之腦部 MRI 影像與臨床資料為基礎，建立多任務與多階段之機器學習分析框架。研究目的如下：

1. 建立失智症對非失智症 (Dementia vs. NonDementia)、認知異常對認知正常 (AbNormal vs. Normal)，以及輕度認知障礙對認知正常 (MCI vs. Normal) 三項二元分類任務，觀察臨床與影像特徵在不同認知狀態分界下的分類表現。
2. 評估 FreeSurfer 單一特徵群組、具醫學意義之組合與延伸組合的分類潛力，篩選各任務中較具判別力且具神經解剖合理性的候選影像方向。
3. 在一致的交叉驗證架構下，比較多種分類模型，進行特徵排序與篩選，並評估顱內總體積 (eTIV) 校正、機率校準、決策閾值調整與集成學習對模型表現的影響。
4. 以完整臨床特徵作為基準，比較純臨床、純影像、臨床與影像整合及不同融合策略之表現，檢驗 FreeSurfer 結構影像特徵是否能在完整臨床資訊之外提供額外且穩定的分類價值。

²資料來源：FreeSurfer 官方網站，<https://surfer.nmr.mgh.harvard.edu/fswiki> (存取日期：2026 年 7 月 22 日)。

1.3 研究流程與架構

本研究整體流程可分為以下六個階段：

1. **資料整合與前處理**：整合高雄榮民總醫院提供之臨床資料與 3D T1 加權 MRI 經 FreeSurfer 萃取之腦區結構特徵，完成樣本與特徵清理，並建立後續分析所需之臨床與影像資料集。缺失值填補、類別編碼與數值標準化等前處理參數，則於模型訓練時僅依各折訓練資料估計。
2. **三項分類任務與資料切分**：依不同認知狀態建立三項二元分類任務，分別為 Dementia vs. NonDementia、AbNormal vs. Normal，以及 MCI vs. Normal，並依各任務建立分層交叉驗證切分，作為後續模型訓練與評估之基礎。
3. **影像方向篩選**：僅使用 FreeSurfer 影像特徵，透過 ElasticNet Logistic Regression 依序比較單一特徵群組、具醫學意義之組合與延伸組合，篩選各任務中較具分類潛力且具神經解剖合理性的候選影像方向。
4. **多模型比較與特徵排序**：在候選方向上比較多種分類模型，包含線性模型、核方法、距離法、樹與梯度提升模型，以及 TabPFN。接著以 ANOVA F-score 進行特徵排序，並透過 Top- N 掃描決定後續主要分析設定。
5. **Phase 1–4 整合分析**：依序進行正式基線比較、機率校準、閾值調整與集成學習，檢驗不同模型、校準方式、操作點與集成方法對分類表現及機率品質之影響。
6. **完整臨床基準下之影像增量分析**：將資料方向重新整理為完整臨床、純影像與臨床加影像三類，並比較早期融合、中期融合與晚期融合，以檢驗 FreeSurfer 結構影像特徵是否能在完整臨床資訊之外提供額外分類價值。

第二章 文獻回顧

本章回顧與本研究相關之臨床背景、結構式腦影像特徵、FreeSurfer 腦結構量化工具 [1]，以及後續機器學習分析流程中使用之方法。由於本研究重點在於比較臨床資料與 FreeSurfer 結構影像特徵於三項認知退化分類任務中的表現，並進一步評估機率校準、閾值調整、集成學習與融合策略之影響，因此本章文獻回顧聚焦於本研究實際使用之資料、方法與技術。

2.1 失智症、輕度認知障礙與臨床認知評估

失智症 (Dementia) 是一群以認知功能持續退化為主要表現的臨床症候群，患者可能在記憶、語言、執行功能、判斷力與日常生活功能等面向出現不同程度之障礙。以阿茲海默型失智症為例，McKhann et al., 2011 [2] 針對 Alzheimer's disease dementia 提出臨床診斷建議，指出診斷判斷需綜合病史、認知功能表現與日常功能退化情形，而非僅依賴單一檢查結果。此一觀點顯示，認知退化相關分類問題本身具有多面向性，臨床資料與輔助檢查皆可能提供不同層次之資訊。

在失智症確診之前，部分個案可能已處於輕度認知障礙 (mild cognitive impairment, MCI) 階段。Albert et al., 2011 [3] 針對 MCI due to Alzheimer's disease 提出診斷建議，說明 MCI 個案已出現超出年齡與教育程度預期之認知改變，但整體日常功能尚未達失智症程度，並可依臨床表現與生物標誌物資訊進行不同程度之判斷。上述文獻說明 Normal、MCI 與 Dementia 個案在認知功能及日常生活表現上具有不同程度之差異，因此本研究依不同認知狀態分界設計三項二元分類任務，用以觀察模型在不同分類問題下的判別能力。

臨床認知評估量表是失智症與 MCI 評估中的重要資訊來源。Folstein et al., 1975 [4] 提出 Mini-Mental State Examination (MMSE)，作為臨床上快速評估認知功能的工具，涵蓋定向感、記憶、注意力與計算、語言及圖形臨摹等面向。Teng et al., 1994 [5] 則提出 Cognitive Abilities Screening Instrument (CASI)，其設計涵蓋較廣泛的認知功能面向，並可用於跨文化與流行病學研究。由於本研究臨床資料中包含 MMSE 與多項 CASI 分項，這些量表文獻可作為後續模型使用臨床認知特徵之基礎。

此外，Morris [6] 說明 Clinical Dementia Rating (CDR) 為臨床失智嚴重程度分級常用工具，可依記憶、定向感、判斷與問題解決、社區事務、家庭與嗜好，以及個人照護等功能面向評估失智嚴重程度。由於本研究目的為建立分類模型，若將與臨床診斷標籤高度重疊的 CDR 分數直接納入特徵，可能使模型學習到接近標籤定義本身的資訊。因此於資料前處理階段排除 CDR score，而保留一般臨床變數與其他認知量表特徵作為模型輸入。

2.2 結構式 MRI 與 FreeSurfer 腦結構量化特徵

結構式磁共振造影 (structural magnetic resonance imaging, structural MRI) 能提供腦部灰質、白質、腦室與皮質形態等結構資訊，因此常用於神經退化疾病之腦萎縮與區域性結構變化研究。既有阿茲海默症 (Alzheimer's disease, AD) 與 MCI 分類研究顯示，由 structural MRI 萃取之區域腦結構特徵可用於區分 AD、MCI 與正常對照族群，而特徵表示方式、分類器選擇與資料模態皆可能影響模型表現 [7, 8]。其中，海馬迴及其他內側顳葉結構與記憶及認知功能密切相關，因而常被視為認知退化影像分析的重要候選區域。

FreeSurfer 是常用的自動化腦部 MRI 結構分析工具，可由 T1 加權影像進行皮質重建、組織分割、皮質厚度估計、皮質表面分區及皮質下結構量測。Fischl [1] 指出，FreeSurfer 可產生多種具有神經解剖意義的區域量化特徵，包括腦區體積、皮質厚度與表面積等。其統計輸出亦涵蓋全腦體積摘要、皮質下結構、白質分區及不同皮質分區圖譜所產生的區域量測，可由不同層面呈現腦部結構資訊。Desikan et al. [9] 提出 Desikan–Killiany 皮質分區圖譜，依解剖標誌將大腦皮質自動標記為多個區域，並成為 FreeSurfer 常用之 *aparc* 分區來源之一。

海馬迴與杏仁核均屬於內側顳葉與邊緣系統的重要結構。Poulin et al. [10] 指出，早期阿茲海默型失智症中可觀察到杏仁核萎縮，且其萎縮程度可能與症狀嚴重度相關。在細部結構量測方面，Iglesias et al. [11] 以高解析度 *ex vivo* MRI 建立海馬亞區機率圖譜，並發展自動化海馬亞區分割方法，使研究者能取得 CA1、CA3、CA4、subiculum、molecular layer 與 hippocampal fissure 等海馬子區量測。Saygin et al. [12] 則建立杏仁核核團層級之機率圖譜，使 FreeSurfer 可估計 lateral nucleus、basal nucleus、central nucleus 與 accessory basal nucleus 等杏仁核子核體積。

綜合上述，FreeSurfer 可同時提供全腦、皮質、皮質下結構、白質分區、海馬亞區與杏仁核子核等不同層級之結構量化資訊，因此適合作為本研究之影像特徵來源。

2.3 腦體積校正

腦區體積量測可能受到個體顱內總體積 (intracranial volume, ICV) 影響；FreeSurfer 所提供之 estimated total intracranial volume (eTIV) 則可作為 ICV 的估計值。若未考量顱內容量差異，部分體積特徵可能同時反映個體先天或發育造成的整體頭顱大小差異，而非疾病相關之區域性萎縮。Voevodskaya et al., 2014 [13] 比

較不同 ICV 校正方法對健康老化與阿茲海默症 MRI 區域體積分析之影響，指出 ICV 校正方式會影響區域腦體積結果之解釋。因此，當研究使用 FreeSurfer 體積特徵進行分類分析時，需考量顱內容量差異對影像特徵解釋與模型表現之影響。本研究據此於前處理與特徵方向比較中納入 eTIV 相關檢查與校正前後之比較。

2.4 臨床與影像資料之機器學習分類

機器學習已廣泛應用於阿茲海默症與 MCI 之分類研究，常見輸入包含臨床認知量表、人口學資訊、結構式 MRI、PET 或其他生物標誌物。Cuingnet et al., 2011 [7] 使用 ADNI 資料比較多種基於 structural MRI 的阿茲海默症自動分類方法，指出不同特徵表示與分類器選擇皆會影響分類表現。Samper-González et al., 2018 [8] 進一步提出可重現之阿茲海默症分類評估框架，並比較不同資料模態、特徵形式、分類器與資料集對模型表現的影響。上述研究說明，失智症分類模型之結果不宜僅依賴單一模型或單一資料方向，而應在一致的驗證架構下比較不同資料來源、特徵處理與模型設定。

臨床資料與影像資料在資訊層次上具有差異。臨床認知量表主要反映受試者當下的認知與功能表現，結構式 MRI 則提供腦部形態與區域萎縮之客觀量測。Huang et al., 2020 [14] 回顧醫學影像與非影像臨床資料融合之研究，指出影像與非影像臨床資訊可能提供互補資訊，且融合方式會影響模型對不同資料來源的整合方式。因此，本研究除比較純臨床與純影像方向外，亦設計臨床加影像方向與三種融合策略，用以檢驗影像特徵是否能在臨床資訊之外提供額外分類價值。

在分類模型方面，本研究納入多種模型族群，以降低結論受單一模型假設影響之可能。線性模型具有相對簡潔的決策形式，並可作為具可解釋性的基準模型；樹與梯度提升模型則可捕捉非線性關係與特徵交互；核方法、距離法與樸素貝氏

則提供不同歸納偏好之對照。另由於本研究樣本數屬於中小型表格式資料，亦納入 TabPFN 作為表格式基礎模型。Hollmann et al. [15] 提出 TabPFN，透過大量合成表格式資料預訓練 Transformer，使模型可在新表格分類任務上以情境學習方式直接輸出預測，且不需針對每個資料集重新進行大量超參數搜尋。因此，TabPFN 在本研究中不僅作為一般分類模型之一，也作為與傳統線性模型、樹模型及梯度提升模型比較的新型表格式模型代表。

2.5 機率校準、閾值調整與集成融合方法

分類模型輸出的分數或機率不一定具有良好的機率意義。即使模型具有良好的排序能力，其預測機率仍可能過度自信或低估真實風險。Niculescu-Mizil and Caruana, 2005 [16] 比較多種監督式學習模型之機率品質，並討論 sigmoid calibration（常稱為 Platt scaling）與 isotonic regression 等校準方法在不同模型上的效果。其中，sigmoid calibration 透過在模型分數上擬合 sigmoid 函數，將原始分數轉換為校準後機率；isotonic regression 則為非參數式單調校準方法，不預設 sigmoid 等特定函數形狀，而是在維持單調關係的限制下擬合校準映射。因此，本研究於 Phase 2 比較 raw、Platt scaling 與 isotonic regression，並以 Brier score、ECE 與 AUC 等指標評估校準後之機率品質與排序能力。

在臨床應用中，模型機率仍需轉換為二元決策，因此決策閾值的選擇會直接影響敏感度、特異度與平衡準確率。預設閾值 0.5 並不一定適用於類別不平衡或臨床代價不對稱的任務。Youden index [17] 為 ROC 分析中常用之最佳 cut-point 選擇準則；Ruopp et al., 2008 [18] 說明其可透過最大化敏感度與特異度之和減一，尋找整體區辨能力較佳的閾值。本研究以 Youden 作為主要平衡操作點，並額外設計高敏感度與高特異度之操作目標，例如 sens@0.90 與 spec@0.90，分別對應「降

低漏判」與「降低誤判」之臨床需求。此設計使模型評估不僅限於 AUC 等排序指標，也能觀察不同操作點下之分類行為。

集成學習透過整合多個基礎模型之預測，以降低單一模型不穩定性並利用不同模型之互補誤差。Dietterich, 2000 [19] 指出，若不同模型之錯誤型態不完全相同，集成方法可能透過平均或加權方式提升整體預測穩定性。本研究於 Phase 4 比較等權平均、效能加權與凸組合超學習器 (convex super learner, convexSL)。van der Laan et al., 2007 [20] 提出 super learner，概念上是利用交叉驗證表現學習多個候選模型之組合。本研究所使用之 convexSL 可視為其簡化形式：在非負且權重總和為一的限制下，學習各模型預測機率之凸組合，藉以限制權重空間並維持集成權重之可解釋性。

除整合多個基礎模型的集成學習外，多模態資料亦可依資訊結合的位置區分為不同融合層級。Baltrušaitis et al., 2019 [21] 將融合視為多模態機器學習的核心問題之一；Huang et al., 2020 [14] 則將醫學影像與臨床資料的融合區分為早期融合 (feature-level fusion)、中期融合 (joint/intermediate fusion) 與晚期融合 (decision-level fusion) 三種策略。

早期融合係於輸入或特徵層直接整合不同模態的特徵；中期融合則先由不同分支分別學習各模態的特徵表示，再於網路中間的潛在表徵層進行資訊整合；晚期融合則由各模態分別完成建模與預測，最後於決策層結合其預測分數、機率或分類結果。基於上述分類，本研究分別以特徵串接、雙分支神經網路及預測層級集成實作早期、中期與晚期融合，藉以比較不同融合位置對臨床與影像資訊整合效果的影響。

第三章 資料介紹與前處理

本章介紹本研究之資料來源與基本特性、腦部影像資料及其經 FreeSurfer 處理後萃取之腦區結構特徵、三項分類任務設定與資料前處理流程，作為後續實驗與分析之共同基礎。

3.1 資料來源

研究資料由高雄榮民總醫院內科部神經內科提供，涵蓋失智症 (Dementia)、輕度認知障礙 (MCI) 與認知正常 (Normal) 三類受試者。依臨床資料標籤統計，原始樣本數分別為認知正常 60 位、輕度認知障礙 237 位及失智症 86 位。資料依收案時間先後分為 A、C、D、F、H 五個批次，整體收案時間為民國 106 年 11 月至 112 年 10 月，跨度約六年。各批次所屬研究計畫均經高雄榮民總醫院人體研究倫理審查委員會審查核准，其對應之 IRB 編號、計畫主持人、首次核准日期與正式計畫名稱整理於附錄 A。

每位受試者之資料包括臨床資料與腦部磁共振造影 (MRI) 影像。臨床資料涵蓋人口學、生活型態、身體功能與認知量表等多面向評估；影像資料則包含 3D T1 加權影像、3D FLAIR、動脈自旋標記、擴散峰度造影、定量磁化率造影及磁化率加權影像等類型。本研究後續採用 3D T1 加權影像作為 FreeSurfer 輸入，以萃取腦部結構量化特徵。

並非所有受試者皆同時具備可用之臨床資料與影像資料。經整理，完成 FreeSurfer 結構分析者共 390 位，具備臨床資料者共 383 位，兩類資料皆具備者共 379 位。再經後續樣本與特徵清理（詳見第 3.5.1 節），最終納入分析者共 378 位，

其三類組成如表 3-1。

表 3-1 最終納入分析樣本之類別組成（共 378 位）

類別	人數	比例 (%)
Dementia（失智症）	85	22.5
MCI（輕度認知障礙）	233	61.6
Normal（認知正常）	60	15.9
合計	378	100.0

3.2 臨床資料

臨床資料以每位受試者為一筆紀錄。原始檔案中除樣本編號 (ID) 與分類標籤 (status_bl) 外，共包含 35 個臨床欄位；移除收案日期與 CDR score 後，資料集層級保留 33 個原始臨床特徵，依性質可分為四大類：

1. **人口學資訊**：年齡 (age_at_bl)、性別 (sex)、教育年數 (EduYear)、婚姻狀態 (Marriage) 與 APOE 基因型 (APOE)。
2. **生活型態與感官狀況**：吸菸 (Smoke)、飲酒 (Alcohol)、視覺障礙 (VisualImp) 與聽覺障礙 (HearImp)。
3. **身體功能與健康指標**：身高 (Height)、體重 (Bodyweight)、身體質量指數 (BMI)、步行速度 (Gaitspeed)、最大握力 (HGmax)、四肢肌肉質量指數 (ASMI)、Charlson 共病指數 (CCI)、多重用藥指標 (Polypharmacy01)、用藥種類數 (Drugkinds)、是否使用抗精神病藥物 (Antipsychotics)、老人憂鬱量表 (GDS)、巴氏量表 (BarthelIndexScores) 以及簡易營養評估 (MNA_SF)。
4. **認知功能量表**：簡易心智量表 (MMSE)、認知功能篩檢量表 (CASI) 之各分項分數 (CASILTM、CASISTM、CASIATTEN、CASIMENMA、CASIOR-

IEN、CASIABSTR、CASILANG、CASIDRAW、CASIANML) 與 CASI 總分 (CASItotalscores)。

收案日期 (date_bl) 與臨床失智評估量表 (CDR score) 不納入分析：前者僅記錄收案時間，未作為預測變數；後者與臨床診斷標籤之資訊高度重疊，納入可能造成標籤洩漏。完整原始臨床欄位之說明、編碼與納入情形列於附錄表 B.1。

3.3 原始 3D T1 影像

受試者之腦部磁共振造影資料以 DICOM (Digital Imaging and Communications in Medicine) 格式儲存，並依受試者編號分別存放。本節以受試者 C001 之 SER00001 影像作為原始資料格式與視覺化流程示例。該影像屬於磁化準備快速梯度回波 (Magnetization-Prepared Rapid Gradient Echo, MPRAGE) 序列，其主要影像與處理資訊整理於表 3-2。

表 3-2 受試者 C001 之 SER00001 影像與處理資訊

項目	內容
SeriesDescription	O-SAG T1 MPRAGE 1mm
ProtocolName	O-SAG T1 MPRAGE 1mm
影像序列類型	磁化準備快速梯度回波序列 (MPRAGE)
ImageType	ORIGINAL、PRIMARY
MRAcquisitionType	3D
DICOM 檔案數	160
單張影像矩陣	256 × 240
像素間距	1 × 1 mm
切片厚度	1 mm
三維影像陣列尺寸	160 × 256 × 240 (切片數 × 影像列數 × 影像欄數)

程式讀取各 DICOM 檔案中的像素陣列，保留矩陣大小一致的影像，再依 InstanceNumber 排序並堆疊為三維影像陣列。接著沿三個陣列軸切取中間剖面，結果如圖 3-1。




圖 3-1 受試者 C001 之 3D T1 三軸中間剖面（左：近似矢狀方向；中：近似冠狀方向；右：近似軸狀方向）以近似方向標示。C001 之其他 3D T1 影像序列資訊見附錄表 C.1。

3.4 FreeSurfer 影像處理

FreeSurfer 為一套廣泛使用之腦部結構影像自動化分析工具，可由 3D T1 加權影像進行皮質重建、組織分割、皮質厚度測量與腦區分區。本研究使用 FreeSurfer 之 `recon-all -all` 執行標準結構影像處理流程，包括顱骨剝離、強度正規化、皮質下結構分割、皮質表面重建與皮質分區；完成標準處理後，再使用 `segmentHA_T1.sh` 進一步取得海馬亞區與杏仁核子核之細部結構量測。FreeSurfer 處理後輸出包括影像體積、皮質表面模型及各腦區之量化統計資料，後續分析僅使用腦區體積、表面積與皮質厚度等結構量化特徵，影像體積、表面模型與其他中間處理檔案則不納入分析。完成處理後，共有 390 位受試者具備分析所需之 15 個完整統計檔案；FreeSurfer 軟體版本、執行環境與處理程序另整理於附錄 D。

15 個統計檔案來自兩類輸出位置：其中 11 個取自各受試者之 `stats` 資料夾，涵蓋全腦體積摘要、皮質下結構、白質分區與皮質表面分區；其餘 4 個海馬亞區與杏仁核子核檔案，則來自 `segmentHA_T1` 延伸分割結果。皮質分區、海馬亞區與杏仁核子核均依左、右半球分別輸出。

標準 stats 檔案主要包含兩類量測資訊：使用 # Measure 標示的整體量測摘要，以及使用 # ColHeaders 標示的逐區量測。前者包括全腦體積與估計顱內總體積 (estimated total intracranial volume, eTIV)，後者則包括各腦區之體積、表面積與皮質厚度；海馬亞區與杏仁核子核統計檔則主要記錄各細部結構之體積。上述檔案依解剖區域與量測內容歸納為 9 個特徵群組，共得到 1,131 個 FreeSurfer 量化特徵。為便於追溯各特徵之原始來源，檔頭摘要與逐區量測分別以 M_ 與 C_ 起始，並於名稱中標示半球、結構、量測類型及所屬群組。例如，M_eTIV_vol_aseg 代表 aseg 群組之 eTIV；而 C_rh_entorhinal_thick_aparc 則代表 aparc 群組之右側內嗅皮質平均厚度。各群組內容整理於表 3-3。

表 3-3 本研究使用之 FreeSurfer 特徵群組

群組	stats 檔案	特徵數	主要量測內容
brainvol	brainvol.stats	16	全腦分割體積、皮質灰質、白質、皮質下灰質，以及腦室與脈絡叢等整體體積摘要。
aseg	aseg.stats	46	海馬迴、杏仁核、丘腦、尾狀核、殼核、蒼白球及腦室等皮質下結構體積，並包含 eTIV。
wmparc	wmparc.stats	70	依鄰近皮質分區標記之白質區域體積。
hippo	hipposubfields.{lh,rh}.T1.v22.stats	44	左右側海馬亞區體積，包括 subiculum、CA1、presubiculum 與 hippocampal-fissure 等。
amyg	amygdalar-nuclei.{lh,rh}.T1.v22.stats	20	左右側杏仁核子核體積，包括 Lateral-nucleus、Basal-nucleus 與 Central-nucleus 等。
aparc	{lh,rh}.aparc.stats	208	Desikan-Killiany 圖譜各皮質分區之表面積、灰質體積與平均皮質厚度。
a2009s	{lh,rh}.aparc.a2009s.stats	448	Destrieux 圖譜各皮質分區之表面積、灰質體積與平均皮質厚度。
dkt	{lh,rh}.aparc.DKTatlas.stats	193	Desikan-Killiany-Tourville 圖譜各皮質分區之表面積、灰質體積與平均皮質厚度。
ba_thresh	{lh,rh}.BA_exvivo_thresh.stats	86	閾值化 Brodmann 區域之皮質表面積、灰質體積與平均皮質厚度。
合計	15 個 stats 檔案	1,131	共歸納為 9 個 FreeSurfer 特徵群組。

註：{lh,rh} 表示左、右半球各有一個對應統計檔案；表中特徵數為完成特徵萃取、尚未進行後續特徵清理時之數量。

各群組之特徵保留與去冗餘原則如下；整體策略為以 `brainvol.stats` 作為全腦體積摘要之主要來源，其餘檔案中與之重複的全腦摘要不重複納入，以減少來源重疊與冗餘資訊。

- **brainvol**：保留所有 # Measure 作為全腦體積摘要來源（如 `BrainSegVol`、`TotalGrayVol`、`CortexVol`、`CerebralWhiteMatterVol`、`SubCortGrayVol` 等）。
- **aseg**：保留各皮質下結構之逐區體積 (`Volume_mm3`)，並保留顱內總體積 `eTIV`（統一命名為 `M_eTIV_vol_aseg`）作為後續體積校正之參考；其 # Measure 與 `brainvol.stats` 重複之全腦摘要，以及 `NVoxels`、`normMean`、`normStdDev` 等體素計數與強度統計欄位則不納入。
- **wmparc**：保留各白質分區之逐區體積 (`Volume_mm3`)；其 # Measure 與 `brainvol.stats` 重複之全腦摘要及強度統計欄位不納入。
- **hippo** 與 **amyg**：此類檔案僅含逐區量測，故保留所有海馬迴子區與杏仁核子核之體積。
- **aparc**、**a2009s**、**dkt**、**ba_thresh**（四種皮質分區圖譜）：各分區保留表面積 (`SurfArea`)、灰質體積 (`GrayVol`) 與平均皮質厚度 (`ThickAvg`) 三項指標；此外另保留各半球之整體皮質摘要 `WhiteSurfArea` 與 `MeanThickness`（其中 `ba_thresh` 無 `MeanThickness`，僅保留 `WhiteSurfArea`），而 `NumVert`、曲率與皺褶等指標，以及與 `brainvol` 重複之摘要與 `eTIV` 則不納入。

依上述規則整理後共得 9 個特徵群組、合計 1,131 個 FreeSurfer 量化特徵，作為本研究影像特徵之完整來源。

3.5 資料前處理

本節說明臨床與 FreeSurfer 影像資料之整合、清理及模型前處理，分為資料集層級與折內前處理兩部分。資料集層級處理包括樣本與特徵清理、分類任務建立及交叉驗證切分，依資料本身客觀性質判定進行處理；折內前處理則針對需由資料分布估計的參數，以各折訓練集擬合併套用至測試集，避免資料洩漏。

3.5.1 樣本與特徵清理

FreeSurfer 特徵萃取後，390 位受試者具備完整結構量化結果。與 383 位具臨床資料之受試者依 ID 配對後，379 位同時具備兩類資料；另有 4 位僅具臨床資料、11 位僅具 FreeSurfer 輸出，不納入分析。配對後交集資料為 379 列、1,168 欄，包含 1,131 個 FreeSurfer 特徵、35 個臨床欄位，以及 ID 與分類標籤 `status_bl`。

其中，1,131 個 FreeSurfer 特徵先用於探索性影像方向篩選；除 ID 與 `status_bl` 外，模型輸入僅含影像特徵，篩選方法與候選方向詳見第 4.4 節。篩選後，各任務保留 3 個候選方向，三項任務共 9 個，涵蓋 `amyg`、`aparc`、`aseg`、`brainvol`、`hippo` 與 `wmparc` 六個特徵群組，共 404 個影像特徵。與臨床資料合併後，清理前資料表為 379 列、441 欄，包含 404 個影像特徵、35 個臨床欄位，以及 ID 與 `status_bl`。正式建立交叉驗證切分前，依序進行下列資料集層級清理：

1. **統一缺失值格式**：將臨床資料中的空白字串與其他缺失標記統一轉為標準缺失值 (NaN)，並將 CASI 欄位中 5 筆以數值 999 表示之缺失資料轉為 NaN。
2. **移除缺失數最高之樣本**：受試者 A035 共缺失 16 個候選特徵，包括 12 個臨床特徵與 4 個 FreeSurfer 特徵，為所有受試者中缺失數最高者，且明顯高於次高的 8 個，故予以移除，使樣本數由 379 位降為 378 位。

3. **移除常數與高頻率值特徵**：移除 4 個於所有 378 位受試者中皆為 0 的常數特徵，分別為左右側白質低訊號區體積 WM_hypointensities，以及左右側非白質低訊號區體積 non_WM_hypointensities。此外，約 99.7% 受試者之第五腦室體積 5th_Ventricle 皆為 0，因變異程度過低而予以移除。此步驟共移除 5 個影像特徵，使 FreeSurfer 特徵由 404 個降為 399 個。
4. **移除完全重複特徵**：brainvol 群組中發現 2 組數值完全相同但名稱不同的特徵，分別為 BrainSegNotVentSurf 與 BrainSegNotVent，以及 SupraTentorialNotVentVox 與 SupraTentorialNotVent。每組擇一保留，分別保留 BrainSegNotVent 與 SupraTentorialNotVent，使 FreeSurfer 特徵由 399 個降為 397 個。
5. **移除非分析用臨床欄位**：移除收案日期 date_b1 與臨床失智評估量表 CDR score。前者未作為時間相關預測變數；後者與分類標籤 status_b1 完全對應，若納入模型可能造成標籤洩漏 (label leakage)，故均不作為分類特徵。處理後，臨床特徵由 35 個降為 33 個。

完成上述清理後，最終母表為 378 列、432 欄，包含 397 個 FreeSurfer 特徵、33 個臨床特徵，以及 ID 與 status_b1。此母表作為後續三項分類任務與折內前處理之共同來源；各階段樣本數與特徵數變化整理於表 3-4。

表 3-4 資料整合與清理各階段之樣本數及特徵數變化

階段	資料處理操作	樣本數	特徵數（臨床／影像）
1	依 ID 配對臨床資料與完整 FreeSurfer 輸出	379	35 / 1,131
2	彙整 9 個候選方向所涵蓋之六個 FreeSurfer 群組	379	35 / 404
3	依候選特徵缺失情況移除受試者 A035	378	35 / 404
4	移除常數影像特徵 4 個及高頻率值影像特徵 1 個	378	35 / 399
5	移除 brainvol 群組內完全重複之影像特徵 2 個	378	35 / 397
6	移除非分析用臨床欄位 date_b1 與 CDR score	378	33 / 397

3.5.2 分類任務與交叉驗證切分

清理後 378 位受試者依 `status_bl` 建立三項二元分類任務，分別對應失智症辨識、認知異常篩檢及較早期之 MCI 辨識。任務一將 MCI 與 Normal 合併為 Non-Dementia；任務二將 Dementia 與 MCI 合併為 AbNormal；任務三則排除 Dementia，僅比較 MCI 與 Normal。三項任務之定義與樣本配置如表 3-5。

表 3-5 三項二元分類任務之定義與樣本配置

任務	任務名稱	標籤定義	正類人數	負類人數	合計
任務一	Dementia vs. NonDementia	正類：Dementia 負類：MCI + Normal	85	293	378
任務二	AbNormal vs. Normal	正類：Dementia + MCI 負類：Normal	318	60	378
任務三	MCI vs. Normal	正類：MCI 負類：Normal (排除 Dementia)	233	60	293

三項任務之正式資料切分均採用 20 個隨機種子之 5 折分層交叉驗證 (stratified k -fold cross-validation, $k = 5$)。分層抽樣依各任務之二元標籤進行，使各折之正負類比例盡量接近整體資料分布。每一隨機種子皆重新產生一組 5 折切分，同一組切分中各受試者僅作為一次外層測試資料，其餘 4 折則作為外層訓練資料。透過多個隨機種子重複切分，可降低模型效能評估過度依賴單一資料切分的情形。所使用之外層隨機種子為 {13, 51, 99, 143, 167, 230, 298, 333, 356, 396, 450, 475, 521, 565, 620, 696, 763, 789, 875, 980}。

因此，每個任務之每個資料方向共建立 $20 \times 5 = 100$ 個外層訓練／測試折。同一任務下不同資料方向均沿用相同之外層切分，使純臨床、純影像及臨床加影像等方向在相同受試者組成的訓練集與測試集上進行評估，以維持後續資料方向與模型比較之一致性。

3.5.3 折內前處理

完成三項任務之外層交叉驗證切分後，各折依序進行缺失值處理與 eTIV 體積校正版本建立。凡需由資料分布估計之填補統計量與校正係數，均僅使用該折訓練資料估計，再套用至測試資料，以維持外層測試資料之獨立性。此階段仍保留數值特徵之原始尺度與類別特徵之原始表示；類別編碼與數值標準化則留至後續模型訓練階段，依各模型需求於折內以訓練資料擬合，再套用至測試資料。

缺失值處理

完成樣本與特徵清理後，397 個 FreeSurfer 特徵已無缺失值，剩餘缺失均來自臨床資料。其中，APOE 基因型缺失 85 筆（約 22.5%）；步行速度 (Gaitspeed) 與四肢肌肉質量指數 (ASMI) 各缺失 7 筆，最大握力 (HGmax) 缺失 5 筆，Charlson 共病指數 (CCI)、老人憂鬱量表 (GDS) 及 CASIMENMA、CASIORIEN、CASIABSTR、CASILANG 與 CASIDRAW 則各缺失 1 筆。各外層交叉驗證折依欄位類型採用下列處理方式：

1. **數值型欄位**：以該折訓練資料之中位數填補缺失值，包括先前由數值 999 轉換而來的 CASI 缺失資料。
2. **一般類別型欄位**：除 APOE 外，其餘類別型欄位皆以該折訓練資料之眾數進行缺失值填補。
3. **APOE 基因型欄位**：考量 APOE 缺失比例較高，若直接以眾數填補，可能使大量未知基因型被指定為最常見類別，因此將其缺失值編碼為獨立類別 Unknown。填補前另建立二元缺失指示變項 APOE_was_missing；原始 APOE 缺失者設為 1，其餘設為 0。

完成填補後，各折之訓練資料與測試資料均不再含有缺失值。本階段輸出的折內資料包含 33 個原始臨床特徵及 APOE_was_missing，共 34 個臨床欄位。此缺失指示變項保留於多模型基線比較、ANOVA 特徵排序與 Top- N 特徵數掃描；建立正式 Phase 1 特徵清單時則予以排除，後續 Phase 分析與影像增量分析皆使用 33 個臨床預測特徵。

eTIV 體積校正

為評估個體顱內總體積 (estimated total intracranial volume, eTIV) 對腦區體積特徵之影響，本研究由六個入選 FreeSurfer 群組的 397 個清理後特徵中辨識出 256 個候選體積特徵，並以 60 位 Normal 受試者檢驗其與 eTIV 之線性關係。各檢定之 p 值採 Benjamini-Hochberg 方法進行多重比較校正，達顯著標準者固定納入 eTIV 校正清單。於各外層交叉驗證折中，迴歸斜率與 Normal 子群平均 eTIV 僅由該折訓練資料估計，再套用至訓練與測試資料，形成未校正 (No_Adj) 與校正 (Adj) 兩種版本；其餘特徵維持原始數值。若候選方向未包含 eTIV，則於校正時暫時加入，完成後移除，不作為模型輸入。相關檢定方法、校正公式與實驗設計詳見第 4.5 節。

標準化與類別變項編碼

完成折內缺失值填補與必要之 eTIV 校正後，輸出資料仍保留數值特徵之原始尺度與類別特徵之原始表示方式。數值特徵標準化與類別變項編碼於後續模型訓練階段整合至各模型之 pipeline 中，並於每一交叉驗證折僅使用訓練資料估計所需參數，再套用至該折測試資料，避免使用全體資料預先完成轉換。

1. **數值型特徵之標準化**：數值特徵之尺度轉換於後續模型訓練流程中處理。採用標準化之分析流程使用 StandardScaler，將各數值特徵減去訓練資料之平均值後除以標準差，使其具零均值與單位變異數：

$$x' = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}}, \quad (3.1)$$

其中 μ_{train} 與 σ_{train} 分別為該特徵於當前訓練資料之平均值與標準差。

2. **類別型特徵之編碼**：採用 OneHotEncoder 進行獨熱編碼，將具 m 個類別之欄位展開為 m 個 0 / 1 指示欄位。納入編碼之類別欄位共 9 個，包括 APOE、sex、Marriage、Smoke、Alcohol、VisualImp、HearImp、Polypharmacy01 與 Antipsychotics。APOE_was_missing 本身為 0 / 1 二元指示變項，於前期資料篩選與特徵評估流程中直接保留，不另進行獨熱編碼或標準化。

綜上，本章建立之最終母表共 378 列、432 欄，包含 397 個 FreeSurfer 特徵、33 個臨床特徵，以及 ID 與 status_bl。完成三項分類任務與交叉驗證切分後，各折先進行缺失值填補與 eTIV 校正，後續於模型訓練階段再依模型需求進行標準化與類別變項編碼，作為候選方向多模型比較、特徵排序、機率校準、閾值調整、集成學習與影像增量分析之共同基礎。

第四章 研究方法

本章說明整體實驗設計與分析方法，結合 FreeSurfer 自腦部 MRI 影像萃取之結構量化特徵與臨床資料，針對三項失智症相關二元分類任務建立機器學習分析流程，涵蓋影像方向篩選、多模型比較、特徵排序、機率校準、閾值調整與集成學習。除比較不同任務、資料方向、模型及流程設定對分類表現之影響外，並評估結構影像特徵的獨立鑑別力與其在完整臨床資料之外的增量預測價值。

章節安排如下：首先說明整體研究架構（第 4.1 節），接著介紹共用之交叉驗證與評估框架（第 4.2 節）、分類模型（第 4.3 節），以及評估指標與統計檢定（第 4.3.7 節），其後依分析流程說明各階段實驗設計。

4.1 整體研究架構

整體分析分為前期管線與完整臨床基準下之影像增量分析兩個區塊。兩者均建立於三項二元分類任務、折內前處理、巢狀分層交叉驗證及折外預測 (out-of-fold prediction, OOF) 之共用框架上，主要差異在於資料組成、特徵排序範圍與分析目的。整體流程如圖 4-1 所示。

前期管線首先建立 49 個候選影像方向，並進行探索性方向篩選。於保留之候選方向上，再進行多模型基線比較與 eTIV 校正設定評估，據以選定後續主要方向與模型子集。接著於入選方向中，將臨床與影像特徵共同進行 ANOVA F-score 排序，並透過 Top- N 掃描決定正式特徵數。上述設定固定後進入整合分析：Phase 1 產生模型之 OOF 基線預測，Phase 2 比較不同機率校準設定，Phase 3 進行決策閾值調整，Phase 4 則評估方向內與跨方向集成。




圖 4-1 整體研究架構與分析流程

完整臨床基準下之影像增量分析則保留 33 個正式臨床預測特徵，另由清理後 397 個 FreeSurfer 特徵建立影像候選池。影像特徵經 ANOVA F-score 獨立排序後取 Top- K ，據此建立純臨床、純影像及臨床加影像等資料方向，並且比較早期、中期與晚期融合之表現。兩個分析區塊的主要資料方向與特徵組成整理於表 4-1。

表 4-1 本研究主要資料方向與任務配置

(A) 前期管線與 Phase 1-4 分析			
任務	純臨床方向	臨床加影像方向	
任務一	Clinical_only	clin_fs_APARC_ASEG_AMYG clin_fs_APARC_ASEG_HIPPO	
任務二	Clinical_only	clin_fs_HIPPO_ASEG	
任務三	Clinical_only	clin_fs_HIPPO	
(B) 完整臨床基準下之影像增量分析			
任務	純臨床方向	純影像方向	臨床加影像方向
任務一	Clin33	FS_top30	Clin33_FS_top30
任務二	Clin33	FS_top30	Clin33_FS_top30
任務三	Clin33	FS_top40	Clin33_FS_top40

前期管線之 Clinical_only 表示純臨床比較方向，各 clin_fs 方向則結合臨床資訊與名稱所示之 FreeSurfer 影像群組；其正式輸入特徵再依後續特徵排序與 Top- N 篩選結果決定。完整臨床基準下之影像增量分析則將 Clin33、FS_top K 與 Clin33_FS_top K 分別作為純臨床、純影像及臨床加影像方向，用以比較影像特徵的獨立分類能力及其在完整臨床資訊之外的增量價值。

4.2 交叉驗證與評估框架

對於已固定之任務、資料方向、特徵集合與模型設定，本研究採用巢狀分層交叉驗證 (nested stratified cross-validation) 評估模型表現。外層交叉驗證用於估計模型對未見資料之泛化能力，內層交叉驗證則僅於外層訓練資料中進行超參數選擇，使外層測試資料不參與模型選擇與擬合。整體流程包含以下兩個層級：

- **外層 (outer)：**沿用第 3.5.2 節建立之 20 個隨機種子 $\times$ 5 折分層交叉驗證切分，每項正式分析共形成 100 個外層訓練／測試折。各外層隨機種子主要用於資料切分；正式分析不直接將其傳入內層交叉驗證或模型本身，影像方向篩選則依外層 seed 與 fold 編號另行設定內層隨機種子。
- **內層 (inner)：**每一外層訓練折再依類別比例分層切分為 3 個內層折，用於候選超參數之比較與選擇。正式分析之內層切分固定使用 `random_state=42`；影像方向篩選則依外層 seed 與 fold 編號設定 `random_state=seed+fold_number`。各組候選參數以 3 折驗證分數之平均進行比較，選出最佳設定後，再以完整外層訓練折重新擬合模型，最後對外層測試折產生預測。除 TabPFN 沿用預設設定外，其餘具隨機性的模型固定使用隨機種子 42。

各外層折之前處理方式沿用第 3.5.3 節設定，需由資料估計之參數皆僅使用外層訓練資料建立，外層測試折不參與超參數選擇、前處理參數估計與模型擬合。同一隨機種子下 5 個外層測試折之預測彙整後，形成涵蓋全部樣本的 out-of-fold (OOF) 預測；後續機率校準、閾值調整與集成學習皆以此 OOF 預測為輸入，並採種子內留一折 (within-seed leave-one-fold-out) 設計，相關參數僅由同一隨機種子下其餘 4 折之 OOF 預測估計，再套用至保留折進行評估。須注意，巢狀交叉驗證主要適用於已固定分析設定下的折內前處理、超參數選擇與模型訓練；方向、模型與特徵數等研究層級選擇並未全部巢狀於外層交叉驗證中。各階段之外層交叉驗證與內層評分設定整理於表 4-2。

4.3 分類模型

本研究各分析階段前後共使用 13 種基礎分類模型，涵蓋線性模型、樹集成模型、核方法、距離法、機率生成模型與表格式基礎模型。不同分析階段依研究目

表 4-2 各模型訓練階段之外層交叉驗證與內層評分設定

階段	外層交叉驗證	內層評分指標
影像方向篩選	5 seeds $\times$ 5 folds	balanced accuracy
多模型基線比較	20 seeds $\times$ 5 folds	balanced accuracy
Phase 1 主基線實驗	20 seeds $\times$ 5 folds	balanced accuracy
完整臨床基準下之影像增量分析	20 seeds $\times$ 5 folds	ROC-AUC

的使用其中不同模型子集，以下依模型族群說明基本原理、代表公式與特性。

4.3.1 線性模型

本節介紹 Logistic Regression、ElasticNet Logistic Regression、RidgeClassifier 與 LinearSVC 四種線性模型。此類模型皆以 $f(x) = \beta^T x + \beta_0$ 作為線性決策函數，其中 β 為特徵係數， β_0 為截距。線性模型結構簡潔且適用於高維資料，但較難直接捕捉非線性關係與特徵交互作用。

Logistic Regression 以 sigmoid 函數將 $f(x)$ 映射至 $(0, 1)$ 區間，作為陽性類別 ($y = 1$) 之預測機率：

$$\hat{p}(x) = \frac{1}{1 + \exp[-f(x)]}. \quad (4.1)$$

本研究採用 L_2 正則化限制係數幅度以降低過擬合風險。此模型可直接輸出預測機率，故作為線性機率模型之基準。

ElasticNet Logistic Regression [22] 在對數損失 (log loss) 之上結合 L_1 與 L_2 正則化，其最佳化目標可表示為：

$$\min_{\beta, \beta_0} \left\{ -\frac{1}{n} \sum_{i=1}^n w_i [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)] + \lambda \left[\rho \|\beta\|_1 + \frac{1 - \rho}{2} \|\beta\|_2^2 \right] \right\}, \quad (4.2)$$

其中 $y_i \in \{0, 1\}$ ， $\hat{p}_i = \hat{p}(x_i)$ ， w_i 為樣本權重， λ 控制整體正則化強度， ρ （對應

l1_ratio) 決定 L_1 與 L_2 之比例。 L_1 項可將係數壓縮為零以達成稀疏化， L_2 項有助於穩定高度相關特徵之估計，適合本研究特徵數較多且具共線性之影像資料。

RidgeClassifier 將類別標籤編碼為 $\tilde{y}_i \in \{-1, +1\}$ ，並以 L_2 正則化之最小平方損失 (squared loss) 為目標函數建立分類邊界：

$$\min_{\beta, \beta_0} \sum_{i=1}^n w_i [\tilde{y}_i - (\beta^\top x_i + \beta_0)]^2 + \alpha \|\beta\|_2^2, \quad (4.3)$$

其中 α 控制 L_2 正則化強度。此模型計算快速、在特徵高度相關或高維情境下具有較穩定之係數估計；限制在於原始輸出為決策分數而非機率。

LinearSVC 以 squared hinge loss 與最大間隔原則建立線性分類邊界：

$$\min_{\beta, \beta_0} \frac{1}{2} \|\beta\|_2^2 + C \sum_{i=1}^n w_i [\max(0, 1 - \tilde{y}_i f(x_i))]^2, \quad (4.4)$$

其中 C 控制間隔違反懲罰與正則化之權衡， C 越大則相對正則化越弱。此模型適合高維資料，但對特徵尺度與 C 之選取較敏感，且原始輸出為決策分數。

RidgeClassifier 與 LinearSVC 之決策分數 s_i 經 sigmoid 函數映射為 $[0, 1]$ 區間的原始預測分數：

$$\hat{p}_{i, \text{raw}} = \frac{1}{1 + \exp(-s_i)}. \quad (4.5)$$

此轉換僅用於統一輸出尺度，不代表經校準之預測機率。四種線性模型均採 class_weight=balanced 處理類別不平衡。

4.3.2 樹集成模型

樹模型透過遞迴分割特徵空間建立分類規則，可自動學習非線性關係與特徵交互作用，且對特徵尺度相對不敏感。本研究納入 RandomForest、ExtraTrees、XGBoost、LightGBM 與 CatBoost 五種樹集成模型，其中 RandomForest 與 ExtraTrees 屬於隨機化樹集成方法，XGBoost、LightGBM 與 CatBoost 則採用 boosting 架構。若模型複雜度控制不當，仍可能於小樣本高維情境下產生過擬合。

隨機化樹集成模型透過建立多棵具有差異性的決策樹並平均其預測結果，以降低單棵樹之變異。設第 b 棵樹對正類 ($y = 1$) 之預測機率為 $p_b(x)$ ，則 B 棵樹之集成輸出為：

$$\hat{p}(x) = \frac{1}{B} \sum_{b=1}^B p_b(x). \quad (4.6)$$

RandomForest 對訓練樣本進行 bootstrap 抽樣，並於各節點隨機選取部分特徵進行分裂；ExtraTrees 增加分裂過程之隨機性，於隨機選取的特徵上產生候選分裂點，以增加樹間差異。較高程度的隨機化有助於降低模型變異，但可能增加偏誤。

Boosting 模型以加法形式依序加入決策樹作為基學習器，使新增之樹逐步修正既有模型之預測誤差：

$$F_m(x) = F_{m-1}(x) + \nu h_m(x), \quad (4.7)$$

其中 $F_m(x)$ 為加入第 m 棵樹後之模型輸出， $h_m(x)$ 為第 m 棵決策樹， ν 為學習率。

XGBoost 於梯度提升架構中加入模型複雜度正則化，並利用損失函數之一階與二階梯度資訊進行最佳化，以控制模型複雜度並提升訓練效率。

LightGBM 採用直方圖分箱 (histogram-based binning) 與葉節點導向 (leaf-wise)

之成長策略，優先分裂可帶來較大損失下降的葉節點，因此可形成較深且不對稱的樹結構。在小樣本資料中仍需透過樹深度與葉節點數等參數限制模型複雜度，以降低過擬合風險。

CatBoost 引入有序提升 (ordered boosting) 機制，透過訓練樣本之排列，使樣本的梯度估計基於其前序資料所建立的模型資訊，以降低傳統梯度提升過程中可能產生的估計偏差與預測偏移 (prediction shift)。

4.3.3 核方法與距離法

RBF-kernel SVC 延續前述 SVC 之最大間隔框架，將線性內積替換為徑向基 (radial basis function, RBF) 核函數：

$$k(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|_2^2). \quad (4.8)$$

透過核技巧 (kernel trick)，模型可於不直接建構高維特徵映射之情況下學習非線性分類邊界。 γ 控制核之作用範圍，值越大則相似度衰減越快、決策邊界越局部。此模型能捕捉複雜非線性關係，但對特徵尺度、 C 與 γ 較敏感，計算成本亦高於 LinearSVC。

k -最近鄰 (kNN) 依特徵空間中距離最近之 k 個訓練樣本進行分類，以鄰近樣本之類別（加權）比例作為預測機率：

$$\hat{p}(y = c \mid \mathbf{x}) = \frac{\sum_{j \in \mathcal{N}_k(\mathbf{x})} w_j \mathbb{I}(y_j = c)}{\sum_{j \in \mathcal{N}_k(\mathbf{x})} w_j}, \quad (4.9)$$

其中 $\mathcal{N}_k(\mathbf{x})$ 表示距離樣本 $\mathbf{x}$ 最近之 k 個訓練樣本， w_j 為鄰居權重。kNN 可形成局部非線性邊界，但對特徵尺度、加權方式與 k 值較敏感，且高維資料可能降低距

離之區辨力。

4.3.4 機率生成模型

高斯樸素貝氏 (Gaussian Naive Bayes, GNB) 假設在給定類別 c 後，各特徵彼此條件獨立，且數值特徵服從常態分布：

$$p(\mathbf{x} \mid y = c) = \prod_{j=1}^p \frac{1}{\sqrt{2\pi\sigma_{cj}^2}} \exp \left[-\frac{(x_j - \mu_{cj})^2}{2\sigma_{cj}^2} \right], \quad (4.10)$$

其中 μ_{cj} 與 σ_{cj}^2 分別為類別 c 下第 j 個特徵之平均與變異數，由訓練資料估計。實作時另以 `var_smoothing` 對變異數加入小量平滑，以提升數值計算之穩定性。GNB 屬於機率生成式模型，與其他判別式模型可形成互補，有助於增加集成成員之多樣性；其限制在於條件獨立與常態分布假設較強。

4.3.5 表格式基礎模型 TabPFN

TabPFN (Tabular Prior-data Fitted Network) [15] 是一種針對表格式資料設計之基礎模型 (foundation model)，預先於大量由不同資料生成機制建立之合成表格資料上進行訓練，學習多種分類問題之先驗結構。給定已標註訓練資料集 $\mathcal{D}_{\text{train}}$ 與待預測樣本 $\mathbf{x}_*$ ，TabPFN 以參數為 θ 之模型 q_θ 近似該樣本之後驗預測分布 (posterior predictive distribution)：

$$q_\theta(y_* \mid \mathbf{x}_*, \mathcal{D}_{\text{train}}) \approx p(y_* \mid \mathbf{x}_*, \mathcal{D}_{\text{train}}). \quad (4.11)$$

應用於新資料時，TabPFN 將訓練資料與待預測樣本作為 Transformer 輸入，透過情境學習 (in-context learning, ICL) 直接產生類別機率，不需針對目標資料以梯度下降更新參數。其可運用預訓練先驗，適合中小型表格資料，且通常不需大規模

超參數搜尋；限制包括模型解釋性較低，表現可能受目標資料分布與規模影響。

4.3.6 模型彙整

各模型具有不同之建模假設與決策機制，其類型與核心特性整理於表 4-3 中，作為後續模型比較與集成分析之基礎。

表 4-3 本研究各分析階段涉及之 13 種基礎分類模型

模型	類型	核心特性
Logistic Regression	線性	以 L_2 正則化控制係數幅度之線性機率模型
ElasticNet Logistic	線性	結合 L_1 與 L_2 正則化，兼具係數稀疏化與共線性控制
RidgeClassifier	線性	以 L_2 正則化之最小平方方法建立線性分類邊界
LinearSVC	線性	以 squared hinge loss 與最大間隔準則建立線性分類邊界
RandomForest	樹集成 (Bagging)	結合 bootstrap 抽樣與隨機特徵選取之多棵決策樹
ExtraTrees	樹集成 (隨機化)	隨機化候選特徵與分裂點，以增加不同決策樹之間的差異性
XGBoost	樹集成 (Boosting)	採正則化梯度提升，並使用二階泰勒展開近似目標函數
LightGBM	樹集成 (Boosting)	採直方圖分箱與葉節點導向之梯度提升方法
CatBoost	樹集成 (Boosting)	引入有序提升機制，以降低逐步提升過程中的估計偏差
RBF-kernel SVC	核方法	透過徑向基核建立非線性分類邊界
k -最近鄰 (kNN)	距離法	依鄰近訓練樣本之類別比例進行分類
Gaussian Naive Bayes	生成式模型	假設特徵條件獨立且服從常態分布之機率生成模型
TabPFN	表格式基礎模型	結合預訓練 Transformer 與情境學習之表格式分類模型

4.3.7 評估指標

本研究評估指標分為排序能力、分類表現與機率品質三類。其中，ROC 曲線下面積 (area under the receiver operating characteristic curve, ROC-AUC)、平衡準確率 (balanced accuracy, BalAcc)、敏感度 (sensitivity, Sens)、特異度 (specificity, Spec)、Brier score 與期望校準誤差 (expected calibration error, ECE) 為主要評估指標；陽性預測值 (positive predictive value, PPV) 與 F1-score 則作為輔助指標。真陽性、真陰性、偽陽性與偽陰性則分別以 TP、TN、FP 與 FN 表示。

排序能力： ROC-AUC 用以衡量模型在不同決策閾值下區分陽性與陰性樣本的能力，亦可解釋為模型將陽性樣本之預測分數排序於陰性樣本之前的機率。其數值越高，表示模型對兩類樣本的區分能力越佳，且不受單一決策閾值影響。後文皆以 AUC 表示 ROC-AUC。

特定閾值下之分類表現： 在給定決策閾值後，本研究主要以 Sens、Spec 與 BalAcc 評估分類表現：

$$\text{Sens} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad \text{Spec} = \frac{\text{TN}}{\text{TN} + \text{FP}}$$

$$\text{BalAcc} = \frac{\text{Sens} + \text{Spec}}{2}$$

Sens 表示實際陽性樣本中被正確辨識的比例，Spec 表示實際陰性樣本中被正確辨識的比例。BalAcc 為兩者之平均，可避免一般準確率受到類別比例不均衡的過度影響，因此作為本研究主要的閾值相關綜合指標。

PPV 表示模型預測為陽性的樣本中，實際為陽性的比例；F1-score 則為 PPV 與 Sens 的調和平均，用以綜合衡量陽性預測正確性與陽性檢出能力。兩者作為本

研究之輔助評估指標，計算方式如下：

$$PPV = \frac{TP}{TP + FP} \quad F1 = 2 \cdot \frac{PPV \cdot Sens}{PPV + Sens}$$

機率品質：以 Brier score 與 ECE 評估模型輸出機率之品質。Brier score 衡量預測機率與真實標籤之平方誤差：

$$Brier = \frac{1}{n} \sum_{i=1}^n (\hat{p}_i - y_i)^2$$

其中 $y_i \in \{0, 1\}$ 為真實標籤， $\hat{p}_i$ 為樣本屬於陽性類別之預測機率。Brier score 越低，表示預測機率與實際結果之整體誤差越小。

ECE 則衡量各預測機率區間中，平均預測機率與實際陽性比例之差距。令 B_m 為第 m 個機率區間，則：

$$ECE = \sum_{m=1}^M \frac{|B_m|}{n} |\text{acc}(B_m) - \text{conf}(B_m)|$$

其中 $\text{acc}(B_m)$ 表示該區間中實際陽性樣本之比例， $\text{conf}(B_m)$ 表示平均預測機率。ECE 越低，表示預測機率與實際陽性比例越一致，即校準程度越佳。

4.3.8 統計檢定

本研究實際使用之統計方法包含單變量線性迴歸之斜率檢定、Wilcoxon 配對符號等級檢定，以及 Benjamini–Hochberg 偽發現率校正。

單變量線性迴歸之斜率檢定。單變量線性迴歸用以描述單一自變數與應變數

之線性關係：

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad (4.12)$$

其中 β_0 為截距， β_1 為迴歸斜率， ε_i 為誤差項。透過檢驗虛無假設 $H_0: \beta_1 = 0$ ，可判斷兩變數之間是否具有統計上顯著的線性關係。本研究以此方法檢驗各體積特徵與 eTIV 之線性關聯，據以決定後續需進行 eTIV 校正之特徵。

Wilcoxon 配對符號等級檢定。 Wilcoxon 配對符號等級檢定 (Wilcoxon signed-rank test) 為適用於成對觀測值的非參數檢定，不要求配對差值服從常態分布。其依非零配對差值之絕對值給予等級，再比較正差值與負差值的等級總和，以判斷配對差值之分布是否以零為中心。本研究以此方法比較完整臨床基準與加入影像特徵後之 AUC 差異。

Benjamini–Hochberg 偽發現率校正。 當同時進行多項統計檢定時，若直接依各項原始 p 值判定結果，可能增加多重比較造成之假陽性。故本研究採用 Benjamini–Hochberg 偽發現率校正 (Benjamini–Hochberg false discovery rate correction, BH-FDR) [23]，以控制多重比較下的偽發現率。

對 eTIV 線性相關性檢定，本研究以 BH 校正後 $q < 0.05$ 作為統計顯著判準。至於完整臨床基準下之逐模型 AUC 增量比較，由於 Wilcoxon 檢定係基於同一批研究受試者的 20 組重複資料切分，其 BH-FDR 校正後之 q 值主要用於描述不同切分下差異方向之一致程度，不作為獨立受試者樣本之母體統計推論。

4.4 影像方向篩選

除了使用 ID 與 status_bl 完成樣本配對及建立分類標籤外，影像方向篩選之模型輸入僅包含 FreeSurfer 特徵。候選方向比較固定採用 ElasticNet Logistic Regression；該模型兼具稀疏化能力與訓練效率，適合大量候選組合之系統性比較。篩選前建立三輪候選組合，依序包含 9 個單一特徵群組、10 個具醫學意義之組合與 30 個延伸組合，每項任務共評估 49 個不重複方向。第一輪比較各群組之基礎鑑別力，第二、三輪則納入可能具有神經解剖互補性的組合，逐步擴大特徵範圍。此階段採用正式樣本與特徵清理前的資料，任務一與任務二各包含 379 位受試者，任務三排除 Dementia 後包含 294 位。模型訓練與調參設定如表 4-4。

表 4-4 影像方向篩選之模型與訓練設定

項目	設定
模型	ElasticNet Logistic Regression (penalty=elasticnet、solver=saga、class_weight=balanced、max_iter=10000)
模型隨機種子	random_state=42
前處理	以中位數填補缺失值，再以 StandardScaler 進行標準化
外層交叉驗證	5 個隨機種子 × 5 折分層交叉驗證，各方向計 25 次外層測試結果
外層隨機種子	{42, 96, 121, 256, 339}
內層參數選擇	外層訓練資料內進行 3 折分層 GridSearchCV
內層隨機種子	random_state=seed+fold_number
內層評分指標	Balanced Accuracy
C 搜尋格點	{0.005, 0.01, 0.03, 0.1, 0.3, 1, 10}
l1_ratio 搜尋格點	{0.1, 0.3, 0.5, 0.7, 0.9}
決策閾值	0.5

註：外層隨機種子用於建立不同的資料切分；內層交叉驗證之隨機種子依外層 seed 與 fold 編號設定；模型隨機種子固定為 42，用於控制 SAGA 最佳化過程之隨機性。缺失值填補與標準化參數均僅由各折訓練資料估計。

候選影像方向依下列三輪設定逐步擴充：

1. **第一輪（9 個單一群組）**：分別評估 brainvol、aseg、wmparc、hippo、amyg、aparc、a2009s、dkt 與 ba_thresh 之單獨分類表現。

2. **第二輪（10 個醫學意義組合）**：依特徵來源與神經解剖位置，組合可能具有互補性的影像特徵。候選方向主要沿內側顳葉結構（海馬亞區與杏仁核子核）、皮質下結構，以及全腦體積與皮質分區三類資訊交叉搭配，例如海馬亞區與皮質下結構、海馬亞區與杏仁核子核、全腦體積與皮質下結構，以及皮質分區與內側顳葉結構等組合。此設計反映 FreeSurfer 不同結構量測所涵蓋之解剖層次 [9, 11, 12]。
3. **第三輪（30 個延伸組合）**：在前兩輪基礎上擴充候選範圍，包括：（一）補充全腦體積與皮質下結構、海馬亞區或杏仁核子核之低至中維組合；（二）將 Desikan–Killiany、Destrieux、DKT 與 Brodmann 四種皮質分區圖譜，分別與皮質下結構、海馬亞區或杏仁核子核搭配；（三）建立以全腦體積為基礎，進一步整合皮質分區與內側顳葉結構之高維組合；（四）納入白質分區，以檢視其與灰質結構之互補性；（五）建立分別搭配 Desikan–Killiany 或 DKT 皮質分區之核心結構組合，作為較完整特徵範圍的探索。為降低不同皮質圖譜間的特徵重疊，未將所有皮質分區圖譜同時納入同一候選方向。

三輪均採用相同的模型與評估設計，並以 25 次外層測試之平均 BalAcc 為主要依據，輔以 AUC、特徵數與神經解剖可解釋性選定方向。若表現相近，則優先保留特徵數較少且結構組成明確者。綜合三輪篩選結果，每項任務最終保留 3 個候選方向，三項任務合計 9 個，作為後續多模型基線比較之輸入。

4.5 eTIV 線性關聯檢定與體積校正

腦區體積可能受到個體整體頭顱大小影響，因此針對 FreeSurfer 所產生之體積特徵，檢驗其與個體顱內總體積 (estimated total intracranial volume, eTIV) 之線性關係，並建立 eTIV 校正版本 (Adj) 與未校正版本 (No_Adj) 進行比較。

eTIV 線性關聯檢定。本研究以全體 Normal 子群之 60 位受試者為基準，針對 256 個候選體積特徵分別建立單變量線性迴歸模型：

$$x_{ij} = \beta_{0j} + \beta_{1j} \text{eTIV}_i + \varepsilon_{ij} \quad (4.13)$$

其中 x_{ij} 為第 i 位受試者之第 j 個體積特徵， β_{0j} 為截距， β_{1j} 為該特徵與 eTIV 之迴歸斜率。透過檢驗虛無假設 $H_0: \beta_{1j} = 0$ ，判斷該特徵是否與 eTIV 具有顯著線性關聯。由於同時檢驗多個體積特徵，各特徵之 p 值採 Benjamini–Hochberg 偽發現率校正，並以校正後 $q < 0.05$ 作為納入 eTIV 校正清單之標準。此特徵清單於交叉驗證前固定建立。

折內殘差法體積校正。對於納入校正清單之第 j 個特徵，本研究採用線性迴歸殘差法 (residual correction) 移除與 eTIV 相關之線性變異 [13]。在每一外層交叉驗證折中，僅使用該折訓練資料中的 Normal 子群估計迴歸斜率 $\hat{\beta}_{1j}$ 與平均 eTIV，並以下列公式計算校正後之特徵值：

$$x_{ij}^{\text{Adj}} = x_{ij} - \hat{\beta}_{1j} \left(\text{eTIV}_i - \overline{\text{eTIV}}_{\text{train,Normal}} \right) \quad (4.14)$$

其中 $\overline{\text{eTIV}}_{\text{train,Normal}}$ 為該外層訓練折之 Normal 子群平均 eTIV。此作法相當於扣除個體 eTIV 相對於參考平均值所造成的預期體積差異，使校正後特徵仍保留在原始體積尺度上，而非僅保留迴歸殘差。

同一組斜率與參考平均值分別套用於該折訓練資料與測試資料，使測試資料不參與校正參數估計。未達線性關聯顯著標準之特徵維持原始數值，不進行 eTIV 校正。若候選影像方向本身未包含 eTIV，則於校正時暫時加入 eTIV 作為參數估

計依據，完成校正後即予以移除，不作為模型輸入特徵。

校正版本比較。各候選影像方向分別建立 No_Adj 與 Adj 兩種資料版本，並於相同任務、資料切分、特徵組合與模型設定下比較 BalAcc 與 AUC。此比較用以評估移除與 eTIV 相關之線性變異後，是否能改善分類表現。須注意，校正特徵清單係利用全體 Normal 子群於交叉驗證前建立，因此特徵清單之選定並非完全巢狀；惟每一外層折之校正斜率與參考平均值均僅由該折訓練資料估計。

4.6 多模型基線比較

影像方向篩選完成後，各任務保留 3 個候選方向進入多模型基線比較。本階段使用第 4.3 節所介紹之前期 12 個模型，包含 RandomForest，但不包含後續完整臨床基準分析新增之 Gaussian Naive Bayes。此階段直接使用各候選方向之完整特徵集合，尚未進行後續 ANOVA F-score 排序與 Top- N 特徵數選擇，藉此先比較不同影像方向與模型在全特徵條件下之基線表現。

各候選方向分別建立 eTIV 未校正 (No_Adj) 與校正 (Adj) 兩種版本，並依表 4-2 所列之交叉驗證設定進行評估。同一任務下之不同候選方向與 eTIV 設定沿用相同之外層資料切分，使各模型均在相同受試者組成的訓練集與測試集上進行比較。對於需要超參數選擇之模型，於每一外層訓練折內進行 3-fold 分層內層交叉驗證，逐一評估候選參數組合，並以平均平衡準確率選取最佳參數；TabPFN 則直接擬合，不進行超參數搜尋。

此階段主要比較候選方向、eTIV 校正設定與模型之相對表現，並觀察各方向在不同模型下之表現是否具有一致性。綜合比較結果後，選定後續主線分析之影像方向與模型子集，再進入特徵排序與 Top- N 特徵數選擇，以避免在方向與模型尚未收斂前即進行特徵數調整。

4.7 特徵排序與特徵數選擇

本研究採用單變量 ANOVA F-score 進行特徵排序。對單一特徵而言，F 值為類別間變異與類別內變異之比：

$$F = \frac{\text{組間均方}}{\text{組內均方}} = \frac{\sum_{g=1}^G n_g (\bar{x}_g - \bar{x})^2 / (G - 1)}{\sum_{g=1}^G \sum_{i \in g} (x_i - \bar{x}_g)^2 / (n - G)}, \quad (4.15)$$

其中 G 為類別數， n 為總樣本數， n_g 與 $\bar{x}_g$ 分別為第 g 類之樣本數與特徵平均值， $\bar{x}$ 為全體樣本之特徵平均值。F 值越大，表示該特徵之類別間差異相對於類別內變異越大，因而具有較高的單變量區分能力。

針對前述篩選後之 4 個主要方向，本研究於 20 個隨機種子、每個種子 5 個外層訓練折中分別計算各特徵之 ANOVA F-score，共彙整 100 個外層訓練折之結果，並依各特徵的平均 F-score 由大至小建立固定排序。完成排序後，再依序建立不同的 Top- N 特徵子集，分別以 ElasticNet Logistic Regression 與 RidgeClassifier 進行評估。任務一與任務二之候選特徵數設定為 $N = 10, 20, \dots, 100$ ；任務三因可用原始特徵數為 78 個，故掃描至 Top-70。最終特徵數主要依外層平均平衡準確率判定，並輔以 AUC，以及兩個模型在不同特徵數下的整體表現與穩定性共同決定。

建立正式 Phase 1 特徵清單時，先將類別變數經 one-hot encoding 所產生的子欄依既有 ANOVA 排名映射回原始變數，並去除重複項目；另排除 APOE_was_missing 缺失指示變項，再依原有排名順序選取各任務所決定之 Top- N 特徵。若該變項原位於所選 Top- N 範圍內，則依排名順序向後補入下一個特徵，以維持正式輸入特徵數不變。

4.8 整合分析：Phase 1–4

完成影像方向篩選、多模型基線比較與 Top- N 特徵數評估後，本研究固定各任務之資料方向、特徵數與模型陣容，進入後續整合分析。前期管線將臨床與影像特徵合併後，依 ANOVA F-score 排序取前 N 名，記為 `clin_fs`，並另建立純臨床方向 `Clinical_only` 作為比較基準。整體分析依序包含 Phase 1 主基線實驗、Phase 2 機率校準、Phase 3 閾值調整與 Phase 4 集成學習；其中 Phase 1 建立各基礎模型之 OOF 預測，Phase 2–4 則以相同 OOF 預測為共同輸入，分別評估機率校準、決策閾值調整與模型集成對分類結果之影響。

4.8.1 Phase 1：主基線實驗

Phase 1 為後續整合分析之基礎階段。各任務沿用前述所選定之 Top- N 特徵數與影像方向，並納入 `Clinical_only` 作為純臨床比較基準。模型則使用多模型基線比較後保留之子集，其中任務一包含 8 個模型，任務二與任務三各包含 7 個模型。各資料方向沿用相同之外層交叉驗證切分；需要超參數選擇之模型於每一外層訓練折內，以 3-fold 分層內層交叉驗證及平均 BalAcc 選取最佳設定，TabPFN 則直接擬合，不另進行超參數搜尋。

每一外層測試折皆產生逐樣本預測結果，並計算 BalAcc、AUC、Sens、Spec 等評估指標。同一隨機種子下 5 個外層測試折之預測彙整後，形成涵蓋全部受試者之 OOF 預測，並保存作為 Phase 2–4 的共同輸入。因此，Phase 1 除用以比較不同資料方向與模型之基線表現外，亦建立後續機率校準、閾值調整與集成分析所需的統一預測基礎。各模型之主要超參數搜尋格點整理於表 4-5。

表 4-5 Phase 1 各模型之主要超參數搜尋格點

模型	適用任務	搜尋格點
ElasticNet Logistic	全部	$C \in \{0.001, 0.01, 0.1, 1, 10\}$ 、 $l1_ratio \in \{0.1, 0.3, 0.5, 0.7, 0.9\}$
RidgeClassifier	全部	$\alpha \in \{0.01, 0.1, 1, 10, 100\}$
Logistic Regression	全部	$C \in \{0.001, 0.01, 0.1, 1, 10\}$
LinearSVC	全部	$C \in \{0.001, 0.01, 0.1, 1, 10\}$
XGBoost	全部	$max_depth \in \{3, 4, 6\}$ 、 $learning_rate \in \{0.05, 0.1\}$ 、 $n_estimators \in \{100, 300\}$
LightGBM	任務一	$max_depth \in \{3, 4, 6\}$ 、 $learning_rate \in \{0.05, 0.1\}$ 、 $n_estimators \in \{100, 300\}$
CatBoost	任務一	$depth \in \{3, 4, 6\}$ 、 $learning_rate \in \{0.05, 0.1\}$ 、 $iterations \in \{100, 300\}$
ExtraTrees	任務二、三	$n_estimators \in \{100, 300, 500\}$ 、 $max_depth \in \{None, 10, 20\}$
TabPFN	全部	無（直接擬合，不調參）

固定參數敏感度分析

為評估主要結果對超參數設定方式的敏感性，本研究建立固定參數版，與逐外層折調參版本比較。對每一「任務、資料方向與模型」組合，彙整 20 個隨機種子 $\times$ 5 折共 100 個外層折選出的最佳超參數，取各超參數最常出現的數值組成固定設定，並於相同資料切分下重新訓練與評估。此分析涵蓋前期管線與完整臨床基準下之影像增量分析；TabPFN 與 NN_fusion 未採相同的超參數格點搜尋程序，故不建立固定參數版本。固定參數版 OOF 預測依正式流程進行機率校準、閾值調整與集成分析，以比較不同超參數設定方式下的結果穩定性。由於固定參數係由逐外層折調參結果彙整建立，本分析作為補充敏感度分析，用以檢視研究結論對超參數選擇方式的敏感性。詳細選取方式、參數穩定性與比較結果見附錄 J。

4.8.2 Phase 2：機率校準

本階段進行機率校準，使模型預測機率與實際陽性比例較為一致。例如，預測機率接近 0.8 的樣本中，理想上約有 80% 實際為陽性。以 Phase 1 產生的 OOF 預測為輸入，比較未校準的原始設定 (raw)、Platt scaling 與 isotonic regression 三種設定

Platt scaling 最初由 Platt [24] 提出，屬於參數式機率校準方法，透過 logistic 函數將分類器輸出分數映射為陽性類別的預測機率。校準後機率可表示為：

$$\hat{p}_{\text{cal}} = \frac{1}{1 + \exp[-(as + b)]}, \quad (4.16)$$

其中 s 為校準模型的輸入分數， a 與 b 分別控制映射曲線的斜率與位移。實作時先將原始預測機率轉換至 logit 尺度：

$$s = \log \left(\frac{\hat{p}_{\text{raw}}}{1 - \hat{p}_{\text{raw}}} \right), \quad (4.17)$$

再以近乎無正則化的 logistic regression ($C = 10^6$) 估計 a 與 b 。此方法自由度較低，在校準樣本有限時通常較為穩定；由於映射函數具有單調性，通常不會改變樣本間的預測排序。

Isotonic regression [25] 屬於非參數式校準方法，不預設特定函數形狀，僅要求模型分數越高時，校準後機率不得降低。令分數依序排列為 $s_1 \leq s_2 \leq \dots \leq s_n$ ，其目標是在單調非遞減限制下，最小化校準機率與真實標籤的平方誤差：

$$\min_g \sum_{i=1}^n [g(s_i) - y_i]^2 \quad \text{subject to} \quad g(s_1) \leq g(s_2) \leq \dots \leq g(s_n). \quad (4.18)$$

Phase 1 的原始預測機率直接作為分數 s ，據以擬合單調非遞減的分段常數映射。若測試折樣本的原始預測機率超出校準資料範圍，則截斷至最接近的邊界值。相較於 Platt scaling，isotonic regression 不預設特定函數形狀，因此可描述較具彈性的校準關係，但在校準樣本有限時較容易過擬合；其分段常數映射亦可能使不同原始分數對應至相同機率，進而壓縮部分樣本的相對排序資訊。完成校準後，raw、Platt scaling 與 isotonic regression 三種設定以 Brier score、對數損失 (log loss)、ECE 與 AUC 進行描述性比較，其他閾值相關指標則固定以 $t = 0.5$ 計算。

4.8.3 Phase 3：閾值調整與操作點

分類模型輸出之機率須經一決策閾值 t 轉為二元預測 ($\hat{y} = \mathbb{I}[\hat{p} \geq t]$)。預設之 $t = 0.5$ 在類別不平衡或不同臨床偏好下未必為最佳操作點，故本階段分別針對 Phase 2 之 raw、Platt scaling 與 isotonic regression 三種 OOF 機率設定，依不同決策目標選取操作閾值，並與固定閾值 $t = 0.5$ 並列比較。

表 4-6 Phase 3 之四種操作點（閾值）

方法	準則	適用情境
Youden	$\max_t [\text{Sens}(t) + \text{Spec}(t) - 1]$	兩類錯誤代價相近
Sens@0.90	Sens ≥ 0.90 下最大化 Spec	不可漏判之篩檢
Spec@0.90	Spec ≥ 0.90 下最大化 Sens	避免誤判健康者
default 0.5	固定 $t = 0.5$	參考基準

1. **Youden index** [17, 18]：於候選閾值中取使 Youden's $J(t) = \text{Sens}(t) + \text{Spec}(t) - 1$ 最大者，代表該閾值在敏感度與特異度上之整體表現越佳；由於對兩類錯誤等權看待，此閾值適用於偽陽性與偽陰性代價相近之情境。
2. **Sens@0.90**：先限定敏感度不低於 0.90，在所有滿足此條件之閾值中取特異度最大者。其設計對應「寧可多檢、不可漏判」之篩檢情境——先以約束保證至少九成之陽性個案被檢出，再於此前提下盡量降低偽陽性。此準則犧牲

部分特異度以換取高檢出率，適用於漏判代價遠高於誤判之任務（如本研究任務二、三之認知異常與輕度認知障礙篩檢）。

3. **Spec@0.90**：與前者對稱，先限定特異度不低於 0.90，在滿足條件之閾值中取敏感度最大者。其優先保證健康者不被誤判（控制偽陽性於一成以內），再於此前提下盡量提高檢出率，適用於誤判代價較高、需避免過度轉介或不必要後續檢查之情境。
4. **預設 0.5**：不作任何最佳化，固定以 $t = 0.5$ 分類，作為未調整閾值之參考基準，用以對照前三種閾值調整所帶來之增益。

此外，若 Sens@0.90 或 Spec@0.90 在任務中無任何閾值可滿足指定的敏感度或特異度下限，則改選使該受限指標達到最高值的閾值，以確保各情境皆能取得可用的操作點。閾值搜尋範圍設定為 0.01–0.99。須注意，閾值調整僅作用於決策層，不會改變模型對樣本的機率排序，因此四種操作點的 AUC 相同；差異僅反映在 BalAcc、Sens 與 Spec 等需依決策閾值計算的指標上。

4.8.4 Phase 4：集成學習

集成學習於模型輸出層級整合多個基礎模型的預測，藉由結合預測誤差較不相關的模型，降低單一模型誤差對最終結果的影響，以提升整體預測的穩定性與表現。本研究以 Phase 1 產生的 OOF 預測為基礎，分別使用未校準的原始機率 (raw)、Platt scaling 與 isotonic regression 校準後機率作為集成輸入。設共有 K 個成員，第 k 個成員對樣本 i 的預測機率為 $p_i^{(k)}$ ，則加權集成機率可表示為：

$$\hat{p}_i = \sum_{k=1}^K w_k p_i^{(k)}, \quad \sum_{k=1}^K w_k = 1, w_k \geq 0 \quad (4.19)$$

舉例而言，若兩成員之權重為 $(0.7, 0.3)$ ，對某樣本之預測機率分別為 $(0.8, 0.4)$ ，則集成預測為 $0.7 \times 0.8 + 0.3 \times 0.4 = 0.68$ 。本研究比較三種決定權重之方法：

1. **等權平均 (equal weighting)**：令 $w_k = 1/K$ ，不需學習，作為最簡之基準；當各成員強度相近且誤差互補時即已有效。
2. **效能加權 (performance weighting)**：依各成員於學習資料上之表現給權，取 $w_k \propto \max(\text{AUC}_k - 0.5, 0)$ 後正規化（AUC 不及 0.5 之成員權重歸零），使表現較佳之成員獲較大權重，介於等權與完全學習之間。
3. **凸組合超學習器 (convex super learner, convexSL) [20]**：不採事先指定之權重，而是將各成員之權重視為待求參數，於資料上求解最佳化問題以得最佳組合。具體而言，以各成員之 OOF 預測機率為輸入，在凸約束 $\sum_k w_k = 1$ 、 $w_k \geq 0$ 下，尋找使集成機率 $\hat{p}_i = \sum_k w_k p_i^{(k)}$ 之對數損失 (log loss) 最小之權重：

$$\min_w -\frac{1}{N} \sum_{i=1}^N \left[y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i) \right] \quad \text{s.t.} \quad \sum_k w_k = 1, w_k \geq 0, \quad (4.20)$$

其最佳化以序列二次規劃 (SLSQP) 求解。此作法可視為堆疊 (stacking) [26] 之一種——以各成員之 OOF 機率為特徵、學習其線性組合作為最終預測；其特殊之處在於對權重施加凸約束（非負且和為一），使所學權重可用以描述各成員於該集成組合中的相對加權程度，且自由度低而較不易過擬合。

convexSL 以總和為 1 且非負的成員權重建立凸組合集成，並透過最佳化決定各模型的相對權重。權重估計採用序列最小平方規劃 (sequential least squares programming, SLSQP)，以處理上述等式與不等式限制，並以對數損失 (log loss) 作為

最佳化目標。對數損失可直接反映集成預測機率與真實標籤間的差異，適合作為連續權重最佳化的目標函數。

集成分析分為兩個層級。**方向內集成 (Stage 1)** 於同一資料方向內建立多模型候選組合，各方向依 Platt 校準後之 AUC 排名選取最佳線性模型與最佳非線性/TabPFN 模型，並形成「最佳線性與最佳非線性模型配對」、「Linear-only」、「Tree/TabPFN-only」及「全部模型 (ALL)」四類候選家族；各家族分別以等權平均、效能加權與 convexSL 產生集成預測，用以評估同一資料方向內不同模型的互補性。**跨方向集成 (Stage 2)** 則結合不同資料方向的模型輸出，候選組合包含相同模型跨方向的預測，以及各方向全部模型共同形成的 ALLxALL 組合，並採等權平均與 convexSL 兩種方法進行集成。任務一比較兩個臨床加影像方向彼此及其與純臨床方向的組合，任務二與任務三則比較各自主線臨床加影像方向與純臨床方向。由於前期管線中的臨床加影像方向已包含部分臨床特徵，因此此處的跨方向集成屬於預測輸出層的結合，並非完全獨立模態間的融合；早期、中期與晚期融合的完整比較另見第 4.9 節。

Stage 1 與 Stage 2 均分別評估 raw、Platt scaling 與 isotonic regression 三種機率版本，並沿用 Phase 3 的操作點進行閾值評估；正文主要結果則以 Platt scaling 搭配 Youden 操作點呈現。

4.9 完整臨床基準下之影像增量分析設計

完成前期管線後，進一步以完整臨床特徵作為基準，檢驗 FreeSurfer 結構影像是否能在臨床資訊之外提供額外分類價值。分析保留 33 個正式臨床預測特徵，並將資料方向區分為純臨床 (Clin33)、純影像 (FS_topK) 與臨床加影像 (Clin33_FS_topK)。不同於前期管線將臨床與影像特徵合併排序，此處完整保留臨床特徵，僅對 FreeSurfer 特徵獨立排序並選取 Top-K，以評估影像本身的分類能力及其加入完整臨床資訊後的增量效果。另納入早期、中期與晚期融合，比較不同融合層級的整合表現。

4.9.1 三種模態融合

1. **早期融合 (early fusion)**：於輸入特徵層級直接結合兩種模態。將 33 個臨床特徵與所選 Top-K FreeSurfer 特徵串接為單一特徵向量後輸入基礎模型，對應 Clin33_FS_topK 方向。
2. **中期融合 (intermediate fusion)**：臨床與影像特徵先分別經由獨立神經網路分支建立潛在表徵，再於隱藏表徵層進行串接與聯合分類。本研究以中期融合神經網路 NN_fusion 作為代表，其架構詳見第 4.10 節。
3. **晚期融合 (late fusion)**：先由不同資料方向獨立產生 OOF 預測，再於模型輸出層結合其預測機率。本研究將跨資料方向的模型輸出結合視為晚期融合；同一資料方向內的跨模型集成則屬於方向內集成，不列入晚期融合。

4.9.2 資料組成與影像特徵排序

本分析以清理後母表中的 33 個正式臨床預測特徵與 397 個 FreeSurfer 特徵作為候選輸入。APOE_was_missing 不納入正式預測特徵；FreeSurfer 特徵由 brainvol、aparc、aseg、hippo、amyg 與 wmparc 六個清理後群組構成。本階段採用未進行 eTIV 殘差校正的 No_Adj 版本。

影像特徵排序僅針對上述 397 個 FreeSurfer 特徵進行。於每項任務的 20 個隨機種子、每個種子 5 個外層訓練折中，分別計算各影像特徵的 ANOVA F-score，共得到 100 個外層訓練折的排序結果；再依各特徵跨 100 折的平均 F-score 由高至低排序，建立各任務固定的影像特徵排名，並據此選取正式 Top-K 特徵。由於該排名係彙整 100 個外層訓練折後建立，而非於每一正式外層折內重新進行獨立排序，因此並非完全巢狀的特徵選擇，主要用於建立跨資料切分較穩定的任務層級影像排名。

4.9.3 影像特徵數 K 之選擇

影像特徵數 K 以純影像方向 FS_topK 進行評估，候選值設定為 $K \in \{5, 10, 15, \dots, 70\}$ 。為降低初步特徵數掃描的計算成本，從正式 20 個外層隨機種子中取前 5 個 {13, 51, 99, 143, 167}，各自進行 5-fold 分層外層交叉驗證。Top-K 掃描選用 ElasticNet Logistic Regression、RidgeClassifier、XGBoost、kNN 與 RBF-kernel SVC 五種具不同建模特性的分類器，並採較精簡的超參數搜尋範圍，各模型設定整理於表 4-7。

表 4-7 Top- K 掃描之模型與超參數設定

模型	超參數設定
ElasticNet Logistic	$C \in \{0.1, 1\}$, $l1_ratio \in \{0.3, 0.7\}$
RidgeClassifier	$\alpha \in \{0.1, 1, 10\}$
XGBoost	$max_depth \in \{3, 4\}$, $learning_rate = 0.1$, $n_estimators = 300$
kNN	$k \in \{10, 20\}$, $weights \in \{uniform, distance\}$
RBF-kernel SVC	$C \in \{1, 10\}$, $\gamma = scale$

各模型於每一外層訓練折內進行 3-fold 分層內層交叉驗證，並以 ROC-AUC 作為超參數選擇指標，內層切分固定使用 `random_state=42`。評估時先平均同一隨機種子下 5 個外層折的 AUC，再彙整 5 個隨機種子的結果；固定閾值 $t = 0.5$ 下的 BalAcc 則作為輔助診斷。由於不同模型的較佳 K 並不完全一致，正式特徵數不以單一模型最佳點或五模型平均 AUC 的最大值直接決定，而是綜合比較五個代表模型在不同 K 下的 AUC 變化與鄰近區間表現，選取兼顧不同模型結果的任務層級固定 K 。因此，Top- K 定位為探索性的多模型折衷設定，以降低特徵數選擇對單一模型局部最佳點的依賴。

依上述比較，正式分析固定使用任務一 Top-30、任務二 Top-30 與任務三 Top-40，三項任務的正式資料方向分別為：

- 任務一：Clin33、FS_top30、Clin33_FS_top30；
- 任務二：Clin33、FS_top30、Clin33_FS_top30；
- 任務三：Clin33、FS_top40、Clin33_FS_top40。

對應之特徵數分別為任務一 33/30/63、任務二 33/30/63，以及任務三 33/40/73。 K 值選定後即固定套用於完整 20 個隨機種子之正式分析。

4.9.4 統一模型陣容與訓練設定

為使三項任務與三種資料方向可直接比較，統一採用 12 個基礎分類模型，如表 4-8 所示，包含 4 個線性模型、4 個樹／梯度提升模型、TabPFN、kNN、RBF-kernel SVC 與 Gaussian Naive Bayes。另建立中期融合神經網路 NN_fusion（第 4.10 節），僅用於臨床與影像共同輸入的中期融合設定，不計入上述 12 個基礎模型。

表 4-8 完整臨床基準下之影像增量分析所採用之統一模型陣容（共 12 個）

類別	模型
線性模型（4）	ElasticNet Logistic、RidgeClassifier、Logistic Regression、LinearSVC
樹／梯度提升（4）	XGBoost、LightGBM、CatBoost、ExtraTrees
表格基礎模型（1）	TabPFN
多樣性成員（3）	k -最近鄰、RBF-kernel SVC、高斯樸素貝氏

各模型沿用正式 20 個隨機種子 $\times$ 5 折的外層資料切分；需要超參數選擇者於每一外層訓練折內進行 3-fold 分層交叉驗證，並以 ROC-AUC 作為內層評分指標。ElasticNet Logistic Regression、RidgeClassifier、Logistic Regression、LinearSVC、XGBoost、LightGBM、CatBoost 與 ExtraTrees 的搜尋範圍沿用表 4-5 設定，TabPFN 則不進行超參數搜尋。正式分析採 No_Adj 資料版本，基礎模型主要以未校準原始輸出 (raw) 進行 AUC 增量比較。

另外納入的 kNN、RBF-kernel SVC 與 Gaussian Naive Bayes 之超參數搜尋範圍整理於表 4-9。三者同樣以 3-fold 分層內層交叉驗證與 ROC-AUC 選取各外層折的最佳參數。

表 4-9 完整臨床基準分析新增模型之超參數搜尋範圍

模型	搜尋格點
kNN	$k \in \{5, 10, 15, 20\}$
RBF-kernel SVC	$C \in \{0.1, 1, 10\}$ ， $\gamma \in \{\text{scale}, 0.01, 0.1\}$
Gaussian Naive Bayes	$\text{var_smoothing} \in \{10^{-9}, 10^{-8}, 10^{-7}\}$

4.9.5 增量價值檢驗

影像增量以閾值無關的 AUC 作為主要評估指標。對每一「任務、資料方向與模型」組合，先計算 5 個外層測試折的 AUC，再於同一隨機種子內取平均，因此每個模型於每項任務皆得到 20 個種子層級 AUC，以觀察不同隨機切分下增量方向的一致性。主要比較為 Clin33_FS_topK 相對於 Clin33，評估加入影像特徵後的 AUC 增量，定義為：

$$\Delta AUC = AUC_{\text{Clin33_FS_topK}} - AUC_{\text{Clin33}}$$

每項任務包含 12 個模型，三項任務共形成 36 項主要比較。各模型以 20 個隨機切分所得的配對 AUC 差異進行 Wilcoxon signed-rank test，並對 36 項比較進行 Benjamini–Hochberg FDR 校正。另以 FS_topK 相對於 Clin33 作為佐證比較，評估純影像方向相較完整臨床基準的分類能力，同樣形成 36 項比較並獨立進行 BH-FDR 校正。由於 20 個隨機種子皆來自同一批研究受試者的重複資料切分，並非彼此獨立的樣本，因此 Wilcoxon 與 FDR 結果主要反映不同切分下 AUC 差異方向的穩健性與一致性，不作為獨立樣本層級的母體統計推論。核心增量比較採用 AUC，故後續決策閾值的選擇不影響主要比較結果。

4.9.6 操作點與多閾值報告

閾值相關分析沿用 Phase 3 的 Youden、Sens@0.90 與 Spec@0.90 三種操作目標，並採相同的種子內留一折方式決定各外層折閾值。各操作點主要報告 Bal-Acc、Sens 與 Spec，以比較不同決策需求下的分類表現。

4.9.7 集成與晚期融合分析

完成 12 個基礎模型與 NN_fusion 的 OOF 預測後，進一步於預測輸出層進行集成。每項任務中，Clin33 與 FS_topK 各包含 12 個基礎模型，Clin33_FS_topK 則包含 12 個基礎模型與 1 個 NN_fusion，因此共有 37 個候選預測成員。

集成方法與權重估計流程沿用前述 Phase 4，包含等權平均 (equal)、效能加權 (performance weighting) 與 convexSL，並採相同的種子內留一折 OOF 設計。本階段則依完整臨床基準下的資料方向與模型組合，建立以下四類集成設定：

1. **E1：方向內集成。**於 Clin33、FS_topK 或 Clin33_FS_topK 單一資料方向內結合不同模型。
2. **E2a：同模型跨方向集成。**對每一個基礎模型，同時結合 Clin33、FS_topK 與 Clin33_FS_topK 三個資料方向的預測，共 3 個成員。
3. **E2c：最佳臨床與最佳純影像模型集成。**分別依正式 AUC 結果選取表現最佳之 Clin33 模型與 FS_topK 模型，再結合兩者之預測。
4. **E2d：全成員集成。**將每項任務中全部 37 個候選預測成員共同納入集成。

其中 E2a、E2c 與 E2d 均涉及不同資料方向之預測整合，因此作為本研究晚期融合 (late fusion) 之正式候選；E1 則僅用於檢視同一資料方向內多模型集成是否具有額外效益。晚期融合結果再與純臨床、純影像、早期融合及中期融合共同比較，以評估不同融合層級下之臨床與影像整合效果。

4.10 中期融合神經網路

完整臨床基準分析另建立中期融合神經網路 (NN_fusion)，作為中期融合策略之代表。不同於早期融合直接將臨床與影像特徵串接為單一輸入向量，NN_fusion 先以兩個獨立分支分別建立臨床與影像之潛在表徵，再於隱藏表徵層進行融合與分類。

4.10.1 模型定位


NN_fusion 直接以臨床特徵與 FreeSurfer 影像特徵作為輸入並產生 OOF 預測，而非使用其他分類器的預測作為輸入，因此其性質屬於基礎分類模型，而不同於第 4.8.4 節與第 4.9.7 節的預測層級集成。其原始特徵集合與早期融合方向 Clin33_FS_topK 相同，包含 33 個正式臨床預測特徵與各任務固定的 Top-K FreeSurfer 特徵；差異在於早期融合直接串接兩類特徵後進行建模，而 NN_fusion 則先分別學習臨床與影像表徵，再於潛在空間進行融合與分類。

4.10.2 網路架構與訓練設定

NN_fusion 採雙分支前饋神經網路。臨床分支以 33 個臨床預測特徵為輸入，類別變數採 one-hot encoding，數值變數以 StandardScaler 標準化，再經 32 與 16 個神經元形成 16 維潛在表徵；其中 d_c 表示 33 個臨床特徵經類別編碼後的輸入維度。影像分支以各任務固定的 Top-K FreeSurfer 特徵為輸入，標準化後依序通過 64、32 與 16 個神經元，形成 16 維影像潛在表徵。兩分支輸出串接為 32 維向量，再經 16 個神經元與單一輸出節點產生 logit；訓練時將 logit 直接輸入 BCEWithLogitsLoss，評估與預測時再經 sigmoid 函數轉換為陽性類別預測機率。各隱藏層採線性轉換、batch normalization、ReLU 與 dropout，其中 dropout rate 設

為 0.35，整體網路架構如圖 4-2 所示。

模型採 Adam 最佳化器，學習率設為 10^{-3} 、weight decay 為 10^{-4} ，batch size 為 32，依訓練資料類別比例設定 BCEWithLogitsLoss 中的 pos_weight。每一外層訓練折以分層方式切出 20% 作為早停驗證集，最長訓練 300 epochs，以驗證 AUC 作為 early stopping 依據，patience 設為 30，保留驗證 AUC 最佳模型權重；驗證集切分與模型隨機種子皆固定為 42。評估沿用 20 個隨機種子 $\times$ 5 折外層交叉驗證，任務一與任務二使用各自的 Clin33_FS_top30，任務三使用 Clin33_FS_top40，產生與其他基礎模型相同格式的 raw OOF 預測，供後續操作點與集成分析使用。



各隱藏層：Linear $\rightarrow$ Batch Normalization $\rightarrow$ ReLU $\rightarrow$ Dropout (0.35)

圖 4-2 NN_fusion 中期融合神經網路架構

第五章 實驗結果與討論

本章依機器學習管線之順序呈現實驗結果與討論。第 5.1 節說明影像方向之探索性篩選，第 5.2 節呈現 eTIV 線性相關性檢定與校正結果；第 5.3 節進一步比較候選方向之全特徵多模型基線，並呈現主要方向之特徵排序、Top- N 特徵數掃描與後續分析設定。第 5.4 節報告 Phase 1–4 之整合分析，第 5.5 節則採用完整臨床基準下之影像增量分析，檢驗 FreeSurfer 結構影像特徵在完整臨床資訊之外是否提供額外分類增益。除比較臨床與影像資料之相對表現外，本章亦討論不同任務、模型與流程設定所呈現的差異及其方法學意涵。

5.1 影像方向篩選結果

本節呈現以 ElasticNet Logistic Regression 進行之 FreeSurfer 純影像方向篩選結果。三輪分別包含 9 個單一群組、10 個醫學意義組合與 30 個延伸組合，每項任務共比較 49 個方向；模型與評估設定見第 4.4 節。第一輪比較 9 個單一特徵群組之分類表現，結果如表 5-1。

表 5-1 第一輪單一影像群組之分類表現

群組	任務一		任務二		任務三	
	BalAcc	AUC	BalAcc	AUC	BalAcc	AUC
HIPPO	0.674	0.724	0.707	0.764	0.688	0.728
AMYG	0.656	0.726	0.693	0.751	0.641	0.703
ASEG	0.672	0.730	0.686	0.763	0.670	0.748
BRAINVOL	0.653	0.714	0.679	0.719	0.662	0.696
APARC	0.675	0.760	0.629	0.699	0.593	0.632
DKT	0.669	0.746	0.670	0.712	0.606	0.639
A2009S	0.655	0.745	0.627	0.695	0.595	0.618
BA_THRESH	0.641	0.694	0.592	0.631	0.563	0.584
WMPARC	0.643	0.674	0.573	0.635	0.529	0.567

註：數值為 25 次外層測試之平均值；粗體為各任務之最高值。

第一輪結果顯示，各任務之優勢影像群組並不完全相同。任務一以 APARC 取得最高 BalAcc，但與 HIPPO、ASEG 及 DKT 的差距不大，顯示失智與非失智之區分可能同時涉及皮質分區、皮質下結構與內側顳葉訊號。任務二以 HIPPO、AMYG 與 ASEG 表現較佳，優勢主要集中於內側顳葉及皮質下結構。任務三同樣以 HIPPO 與 ASEG 居前，BRAINVOL 次之，而 APARC、DKT、A2009S 與 WMPARC 的表現相對較弱。整體而言，BA_THRESH 與 WMPARC 在三項任務中多位於後段，顯示其單獨使用時提供的鑑別資訊較有限。

第二輪集中評估內側顳葉、皮質下結構、全腦體積摘要與皮質分區之中小型組合；第三輪則進一步納入不同皮質分區圖譜、白質分區與較廣泛的整合組合。各輪方向依平均 BalAcc 排序，表現最高者如表 5-2。

表 5-2 三輪影像方向篩選之各輪最高方向

任務	輪次（方向數）	最高方向	BalAcc	AUC
任務一	第一輪（9）	APARC	0.675	0.760
	第二輪（10）	APARC_ASEG_HIPPO	0.690	0.770
	第三輪（30）	APARC_ASEG_AMYG	0.704	0.774
任務二	第一輪（9）	HIPPO	0.707	0.764
	第二輪（10）	HIPPO_ASEG	0.716	0.783
	第三輪（30）	BRAINVOL_HIPPO_ASEG_WMPARC	0.728	0.777
任務三	第一輪（9）	HIPPO	0.688	0.728
	第二輪（10）	BRAINVOL_HIPPO_ASEG	0.690	0.754
	第三輪（30）	BRAINVOL_HIPPO_ASEG_WMPARC	0.692	0.742

註：數值為 25 次外層測試結果之平均值；各輪依平均 BalAcc 排序，粗體分別標示各任務三輪中最高之 BalAcc 與 AUC。

三輪結果顯示，影像群組組合可提升部分任務之表現，但改善幅度與最佳方向並不一致。任務一較受益於皮質分區、皮質下結構與內側顳葉資訊的整合；任務二以較精簡的 HIPPO_ASEG 取得最高 AUC，而納入 BRAINVOL 與 WMPARC 的較廣組合則具有較高 BalAcc；任務三雖由較廣組合取得最高 BalAcc，但與精簡方向的差距有限，且 AUC 未同步提升。此外，加入 WMPARC 後特徵數明顯增加，整體表

現僅小幅變化，顯示擴大特徵範圍未必帶來相應的預測改善。因此，候選方向除考量 BalAcc 與 AUC 外，亦兼顧特徵數與神經解剖可解釋性，當表現相近時優先保留較精簡的組合。

綜合上述結果，各任務分別保留兩個主要候選方向，並另納入一個三項任務共用的廣泛參考方向，最終每項任務各保留 3 個候選方向，如表 5-3 所示。候選方向除考量 BalAcc 與 AUC 表現外，亦兼顧特徵數與神經解剖可解釋性；當表現相近時，優先保留較精簡的組合。上述候選方向隨後進入正式資料清理與多模型基線比較。完整方向篩選結果列於附錄 E。

表 5-3 三項分類任務保留之候選影像方向

任務	候選影像方向	特徵數
任務一	APARC_ASEG_AMYG	274
任務一	APARC_ASEG_HIPPO	298
任務二	BRAINVOL_HIPPO_ASEG_WMPARC	176
任務二	HIPPO_ASEG	90
任務三	BRAINVOL_HIPPO_ASEG	106
任務三	HIPPO	44
三項任務	BRAINVOL_APARC_ASEG_HIPPO_AMYG	334

5.2 eTIV 線性相關性檢定與校正結果

檢定結果顯示，在六個入選 FreeSurfer 群組之 256 個候選體積特徵中，共有 201 個特徵於 BH-FDR 校正後仍與 eTIV 達顯著線性關聯，顯著比例為 78.5%。其中，全腦體積摘要與白質分區特徵之顯著比例較高，皮質分區與皮質下結構亦有多數特徵達顯著；海馬迴亞區與杏仁核子核等較小型內側顳葉結構之顯著比例則相對較低。各群組之完整結果與代表性特徵列於附錄 F。

進一步比較三項任務共 9 個候選方向之 No_Adj 與 Adj 結果後，eTIV 校正並未帶來一致的 BalAcc 或 AUC 改善。任務一各方向大致持平，任務二與任務三則

多數方向於校正後略有下降。此結果顯示，eTIV 校正雖可移除部分與頭顱大小相關之線性變異，但在本研究資料與校正設定下，未能穩定轉化為分類效能提升。完整比較結果列於附錄表 F.3。因此，後續多模型比較、Phase 1–4 整合分析及完整臨床基準下之影像增量分析，均採用未校正版本 (No_Adj) 作為主要設定。

5.3 候選方向與模型篩選

eTIV 校正未能改善整體分類表現，因此後續分析均採用未校正版本 (No_Adj)。在此基礎上，進一步整合全特徵多模型比較結果，並據此篩選各任務的候選模型與主要影像方向。圖 5-1 至圖 5-3 呈現三項任務代表方向的多指標結果，以比較各模型的整體分類表現及敏感度與特異度平衡；表 5-4 至表 5-6 則比較各任務 3 個候選方向的 BalAcc、AUC 與 Brier score，作為後續模型與方向選擇的依據。

5.3.1 全特徵多模型基線與模型方向整合篩選

任務一以 APARC_ASEG_AMYG 作為代表方向。ElasticNet Logistic Regression 取得最高 BalAcc (0.820)，Logistic Regression、RidgeClassifier、XGBoost 與 CatBoost 亦維持約 0.80 以上的表現；TabPFN 則取得最高 AUC (0.919)，ElasticNet Logistic Regression 與 CatBoost 皆為 0.915。敏感度與特異度方面，線性模型整體較為均衡，而 RBF-SVC、kNN 與 Random Forest 則較偏向高特異度與低敏感度，其中 kNN 的 Sens 僅為 0.291，Spec 則達 0.956。整體結果顯示，任務一在線性模型下具有較穩定的分類平衡，而 TabPFN 則在排序能力上表現較佳，如圖 5-1 所示。




圖 5-1 任務一 APARC_ASEG_AMYG 方向之全特徵多模型基線表現

任務二以 HIPPO_ASEG 為代表方向。ElasticNet Logistic Regression 同樣取得最高 BalAcc (0.822)，Logistic Regression、RidgeClassifier、ExtraTrees 與 XGBoost 亦具有相對較高的平衡準確率；TabPFN 則以 0.926 取得最高 AUC，ElasticNet Logistic Regression 與 CatBoost 分別為 0.919 與 0.916。與 BalAcc 較穩定的線性模型相比，部分模型在基線操作點下呈現明顯的高敏感度與低特異度，例如 RBF-SVC 與 TabPFN 的 Sens 分別為 0.955 與 0.958，Spec 則僅為 0.403 與 0.488。因此，任務二中較高的排序能力未必能直接反映為較均衡的分類結果，如圖 5-2 所示。




圖 5-2 任務二 HIPPO_ASEG 方向之全特徵多模型基線表現

任務三以 HIPPO 為代表方向，整體 BalAcc 低於任務一與任務二。ElasticNet Logistic Regression 同時取得最高 BalAcc (0.809) 與 AUC (0.901)，Logistic Re-

gression 與 RidgeClassifier 的 BalAcc 分別為 0.782 與 0.781。TabPFN 的 AUC 為 0.900，與最高結果相近，但 BalAcc 僅為 0.720；RBF-SVC 與 TabPFN 亦呈現較高敏感度與較低特異度。相較之下，ElasticNet Logistic Regression 的 Sens 與 Spec 分別為 0.816 與 0.802，在兩者之間維持較佳平衡，如圖 5-3 所示。




圖 5-3 任務三 HIPPO 方向之全特徵多模型基線表現

綜合三項代表方向，ElasticNet Logistic Regression 皆取得最高 BalAcc，其他線性模型亦多能維持較穩定的敏感度與特異度平衡；TabPFN 則在三項任務皆具有接近最高或最高的 AUC，但任務二與任務三的 BalAcc 相對較低，顯示排序能力與基線操作點下的分類平衡並不完全一致。從任務間表現進一步比較，任務一 Dementia vs. NonDementia 與任務二 AbNormal vs. Normal 的整體分類表現相對較高。相較之下，任務三 MCI vs. Normal 在多數模型下的 BalAcc 均較低，顯示當分類目標聚焦於 MCI 與認知正常個案時，兩群之間可供模型區辨的訊號相對較有限，因此形成較具挑戰性的分類情境。此差異亦說明三項任務雖使用相同的分析流程，其模型表現與適合的模型類型仍會隨分類目標而有所不同。

上述結果主要反映各任務代表方向下的模型特性，尚不足以決定後續使用的模型與資料方向。不同任務的分類難度與模型表現並不一致，單一代表方向中的最佳結果亦未必能反映模型在其他影像組合下的穩定性。因此，後續進一步納入

各任務 3 個候選方向，同時比較 BalAcc、AUC 與 Brier score，觀察模型表現是否能跨不同影像方向維持一致，並據此篩選具有較穩定整體表現的模型候選子集與主要資料方向。表 5-4 首先呈現任務一各候選方向之全特徵多模型結果。

表 5-4 任務一各候選方向之全特徵多模型表現

模型	APARC_ASEG_AMYG			APARC_ASEG_HIPPO			BRAINVOL_APARC_ASEG_HIPPO_AMYG		
	BalAcc	AUC	Brier	BalAcc	AUC	Brier	BalAcc	AUC	Brier
Logistic Regression	0.808	0.894	0.121	0.805	0.888	0.122	0.804	0.889	0.123
ElasticNet Logistic Regression	0.820	0.915	0.141	0.822	0.915	0.141	0.821	0.914	0.139
RidgeClassifier	0.814	0.899	0.154	0.804	0.891	0.155	0.804	0.891	0.155
LinearSVC	0.782	0.885	0.135	0.779	0.880	0.136	0.776	0.882	0.135
RBF-SVC	0.720	0.887	0.109	0.719	0.888	0.109	0.717	0.886	0.110
kNN	0.623	0.723	0.155	0.609	0.727	0.155	0.610	0.720	0.157
Random Forest	0.710	0.866	0.125	0.702	0.870	0.122	0.688	0.864	0.123
ExtraTrees	0.772	0.866	0.155	0.756	0.862	0.153	0.745	0.851	0.156
LightGBM	0.783	0.905	0.112	0.780	0.902	0.115	0.783	0.903	0.114
XGBoost	0.804	0.910	0.108	0.802	0.908	0.109	0.804	0.908	0.109
CatBoost	0.802	0.915	0.106	0.799	0.912	0.108	0.804	0.914	0.106
TabPFN	0.773	0.919	0.094	0.774	0.922	0.093	0.770	0.921	0.094

BalAcc 與 AUC 越高越佳，Brier score 越低越佳。粗體表示各候選方向中 BalAcc 與 AUC 的最佳值。各數值為 20 個隨機種子之平均結果。

任務一：Dementia vs. NonDementia ElasticNet Logistic Regression 在三個候選方向皆取得最高 BalAcc，TabPFN 則皆具有最高 AUC，並呈現較低的 Brier score。Logistic Regression、RidgeClassifier 與 XGBoost 的 BalAcc 亦相對穩定，LightGBM 與 CatBoost 則在 AUC 或 Brier score 上維持一定表現。綜合分類表現、排序能力與模型互補性，後續保留 ElasticNet Logistic Regression、RidgeClassifier、Logistic Regression、LinearSVC、XGBoost、LightGBM、CatBoost 與 TabPFN，共 8 個模型；k-NN、RBF-SVC、Random Forest 與 ExtraTrees 因整體表現相對有限而不再納入。

三個候選方向的整體表現相近，其中 APARC_ASEG_AMYG 的跨模型表現略具優勢，12 個模型中有 8 個於此方向取得三方向最高 BalAcc；APARC_ASEG_HIPPO 則在部分模型的 AUC 上仍具競爭力。相較於納入更多結構的廣泛參考方向，前兩個

方向在整體表現相近或略佳的情況下使用較少特徵。因此，兼顧分類效能與特徵精簡性後，保留 APARC_ASEG_AMYG 與 APARC_ASEG_HIPPO 作為後續主要方向。

表 5-5 任務二各候選方向之全特徵多模型表現

模型	HIPPO_ASEG			BRAINVOL_HIPPO_ASEG_WMPARC			BRAINVOL_APARC_ASEG_HIPPO_AMYG		
	BalAcc	AUC	Brier	BalAcc	AUC	Brier	BalAcc	AUC	Brier
Logistic Regression	0.812	0.908	0.119	0.805	0.900	0.117	0.792	0.889	0.114
ElasticNet Logistic Regression	0.822	0.919	0.118	0.814	0.914	0.124	0.816	0.911	0.124
RidgeClassifier	0.814	0.906	0.156	0.799	0.888	0.154	0.770	0.863	0.154
LinearSVC	0.798	0.899	0.135	0.784	0.877	0.134	0.763	0.859	0.134
RBF-SVC	0.679	0.887	0.092	0.681	0.882	0.091	0.688	0.877	0.091
k-NN	0.685	0.824	0.108	0.629	0.756	0.129	0.618	0.772	0.128
Random Forest	0.752	0.899	0.096	0.738	0.881	0.101	0.712	0.860	0.108
ExtraTrees	0.805	0.909	0.122	0.787	0.894	0.133	0.763	0.874	0.142
LightGBM	0.777	0.909	0.093	0.768	0.907	0.094	0.756	0.902	0.093
XGBoost	0.804	0.913	0.099	0.794	0.909	0.099	0.792	0.908	0.099
CatBoost	0.753	0.916	0.091	0.753	0.915	0.092	0.752	0.913	0.090
TabPFN	0.723	0.926	0.077	0.730	0.926	0.077	0.711	0.928	0.075

BalAcc 與 AUC 越高越佳，Brier score 越低越佳。粗體表示各候選方向中 BalAcc 與 AUC 的最佳值。各數值為 20 個隨機種子之平均結果。

任務二：AbNormal vs. Normal 整體仍以線性模型的 BalAcc 較為穩定，其中 ElasticNet Logistic Regression 在三個候選方向皆取得最高值，XGBoost 與 ExtraTrees 在部分方向亦維持相對較佳的分類表現。TabPFN 的 BalAcc 雖較低，但三個方向皆取得最高 AUC，且 Brier score 亦為各方向最低，顯示其排序能力與機率預測品質具有優勢。綜合分類表現、排序能力與模型互補性，後續保留 ElasticNet Logistic Regression、RidgeClassifier、Logistic Regression、LinearSVC、XGBoost、ExtraTrees 與 TabPFN，共 7 個模型。

三個候選方向中，HIPPO_ASEG 呈現最一致的整體優勢。12 個模型中有 9 個於此方向取得三方向最高 BalAcc，並有 11 個取得最高 AUC；其跨模型平均 BalAcc 與 AUC 亦高於另外兩個候選方向。雖然個別模型仍可能在其他方向取得較高結果，例如 TabPFN 在廣泛參考方向具有稍高的 AUC，但未形成跨模型一致趨勢。

因此，兼顧整體表現與特徵精簡性，選擇 HIPPO_ASEG 作為後續主要方向。

表 5-6 任務三各候選方向之全特徵多模型表現

模型	HIPPO			BRAINVOL_HIPPO_ASEG			BRAINVOL_APARC_ASEG_HIPPO_AMYG		
	BalAcc	AUC	Brier	BalAcc	AUC	Brier	BalAcc	AUC	Brier
Logistic Regression	0.782	0.881	0.140	0.778	0.876	0.140	0.762	0.850	0.137
ElasticNet Logistic Regression	0.809	0.901	0.129	0.794	0.893	0.129	0.786	0.880	0.128
RidgeClassifier	0.781	0.878	0.171	0.770	0.869	0.169	0.735	0.826	0.167
LinearSVC	0.770	0.873	0.154	0.757	0.860	0.153	0.734	0.818	0.153
RBF-SVC	0.681	0.867	0.112	0.666	0.856	0.115	0.677	0.843	0.115
k-NN	0.699	0.803	0.134	0.656	0.761	0.148	0.640	0.745	0.158
Random Forest	0.733	0.865	0.121	0.723	0.856	0.122	0.693	0.823	0.133
ExtraTrees	0.761	0.885	0.134	0.766	0.878	0.139	0.725	0.849	0.158
LightGBM	0.732	0.866	0.125	0.741	0.876	0.118	0.731	0.863	0.118
XGBoost	0.759	0.871	0.123	0.767	0.879	0.118	0.759	0.868	0.119
CatBoost	0.731	0.876	0.117	0.739	0.883	0.112	0.716	0.877	0.114
TabPFN	0.720	0.900	0.099	0.717	0.898	0.100	0.709	0.896	0.098

BalAcc 與 AUC 越高越佳，Brier score 越低越佳。粗體表示各候選方向中 BalAcc 與 AUC 的最佳值。各數值為 20 個隨機種子之平均結果。

任務三：MCI vs. Normal 線性模型在此任務的 BalAcc 同樣較為穩定，其中 ElasticNet Logistic Regression 在三個候選方向皆取得最高值，並於 HIPPO 方向取得整體最高 AUC。XGBoost 與 ExtraTrees 在部分方向亦具有相對較佳的 BalAcc；TabPFN 的 BalAcc 雖較低，但三個方向皆維持接近最高或最高的 AUC，且具有較低的 Brier score。綜合分類表現、排序能力與模型互補性，後續保留 ElasticNet Logistic Regression、RidgeClassifier、Logistic Regression、LinearSVC、XGBoost、ExtraTrees 與 TabPFN，共 7 個模型。

三個候選方向中，HIPPO 的跨模型表現最為穩定。12 個模型中有 8 個於此方向取得三方向最高 BalAcc，並有 9 個取得最高 AUC；其跨模型平均表現亦優於 BRAINVOL_HIPPO_ASEG 與廣泛參考方向。部分樹模型在加入 BRAINVOL 與 ASEG 後雖有小幅改善，但未形成跨模型一致趨勢。考量整體分類表現與特徵精簡性，選擇 HIPPO 作為後續主要方向。

綜合上述模型與方向篩選結果，後續分析共納入 4 個主要方向：任務一之 APARC_ASEG_AMYG 與 APARC_ASEG_HIPPO、任務二之 HIPPO_ASEG，以及任務三之 HIPPO。後續將依據上述方向進一步進行特徵排序與 Top-*N* 特徵數篩選。

5.3.2 主要方向之特徵排序

依第 4.7 節所述之特徵排序流程，本節呈現 4 個主要方向之前 15 名特徵，詳細特徵排序前 30 名結果則列於附錄 G。

表 5-7 任務一主要方向之特徵排序前 15 名

名次	APARC_ASEG_AMYG	APARC_ASEG_HIPPO
1	CASIORIEN	CASIORIEN
2	MMSE	MMSE
3	CASItotalscores	CASItotalscores
4	CASISTM	CASISTM
5	CASIMENMA	CASIMENMA
6	CASILANG	CASILANG
7	CASIANML	CASIANML
8	CASIABSTR	CASIABSTR
9	CASILTM	CASILTM
10	† L precuneus (APARC)	† L precuneus (APARC)
11	† L Hippocampus (ASEG)	† L molecular_layer_HP-head (HIPPO)
12	† L middletemporal (APARC)	† L GC-ML-DG-body (HIPPO)
13	† L inferiortemporal (APARC)	† L CA4-body (HIPPO)
14	† L Accessory-Basal-nucleus (AMYG)	† L Whole_hippocampus (HIPPO)
15	† L Corticoamygdaloid-transitio (AMYG)	† L Hippocampus (ASEG)

(† 表示影像特徵；L 表示左半球；括號內為影像特徵來源。)

任務一兩個方向之前 9 名特徵完全一致，均由 CASI 認知分項與 MMSE 所構成，而前 15 名中的其餘位置則由影像特徵占據，顯示在目前的單變量排序方法下，認知量表主要位於整體排序前段。進一步觀察影像特徵組成，兩個方向中排名最前者皆為 APARC 的左側楔前葉 (precuneus) 體積；在 APARC_ASEG_AMYG 方向中，較前段特徵包括左側楔前葉、中顳回與下顳回體積，以及 ASEG 的左側海馬體積，之後則出現 AMYG 的杏仁核副基底核與皮質-杏仁核過渡區體積；相較之下，APARC_ASEG_HIPPO 方向則較集中於海馬及其細分亞區特徵。

表 5-8 任務二與任務三主要方向之特徵排序前 15 名

名次	任務二：HIPPO_ASEG	任務三：HIPPO
1	CASItotalscores	CASItotalscores
2	MMSE	MMSE
3	CASISTM	APOE
4	CASIORIEN	APOE_was_missing
5	CASIABSTR	CASISTM
6	Gaitspeed	Gaitspeed
7	† L Whole_hippocampal_body	CASIABSTR
8	† L Whole_hippocampus	CASIORIEN
9	CASIANML	† L Whole_hippocampal_body
10	† L GC-ML-DG-head	† L Whole_hippocampus
11	† L molecular_layer_HP-head	MNA_SF
12	† L molecular_layer_HP-body	† L molecular_layer_HP-body
13	† L Whole_hippocampal_head	† L GC-ML-DG-head
14	† L CA3-head	Drugkinds
15	† L subiculum-body	† L molecular_layer_HP-head

(† 表示影像特徵；L 表示左半球；APOE_was_missing 表示原始 APOE 資料是否缺失。)

任務二與任務三的前段排序皆以臨床特徵為主，其中 CASItotalscores 與 MMSE 均位於前兩名，CASISTM、CASIABSTR、CASIORIEN 與 Gaitspeed 亦排名較前。任務三中，APOE 與 APOE_was_missing 分別位於第 3 與第 4 名；前者包含基因型及未知類別資訊，後者則反映原始 APOE 資料是否缺失，因此兩者在缺失個案上具有高度重疊的資訊，解讀時不宜視為完全獨立的預測訊號。MNA_SF 與 Drugkinds 亦進入前 15 名，顯示營養狀態與用藥資訊在任務三中具有較明顯的單變量差異。需注意的是，APOE_was_missing 僅保留於特徵排序與 Top-N 掃描階段，正式 Phase 1 特徵清單則予以排除；若其位於所選 Top-N 範圍內，則依原排名順序向後補入下一個特徵。

影像特徵方面，任務二與任務三皆以左側海馬體部整體體積 (Whole hippocampal body)、左側全海馬體積 (Whole hippocampus) 及其細分亞區位於排序前段；其中任務二雖同時納入 HIPPO 與 ASEG，但前 15 名中的影像特徵皆來自 HIPPO。綜合三項任務可見，認知量表普遍位於整體排序前段，而影像特徵則以

左側內側顳葉相關結構為主；任務一除海馬相關特徵外，亦出現左側楔前葉、顳葉與杏仁核特徵，任務二與任務三則更集中於海馬整體及其細分亞區。整體而言，海馬相關體積特徵在三項認知分類任務中皆呈現較明顯的單變量差異。

5.3.3 Top- N 特徵數掃描與篩選

依第 4.7 節所述之 Top- N 特徵數掃描流程，四個主要方向於 ElasticNet Logistic Regression 與 RidgeClassifier 下的平衡準確率變化如圖 5-4 所示。




圖 5-4 Top- N 特徵數掃描結果。陰影表示 20 個隨機種子平均結果的 95% 信賴區間，空心標記表示各模型的最高平衡準確率，垂直點線表示後續採用的特徵數。

任務一的兩個主要方向呈現不同的特徵數變化趨勢。在 APARC_ASEG_AMYG 方向中，ElasticNet Logistic Regression 與 RidgeClassifier 均於 Top-80 取得最高平衡準確率，分別為 0.829 與 0.840，因此選擇 Top-80。在 APARC_ASEG_HIPPO 方向中，ElasticNet Logistic Regression 於 Top-90 取得最高平衡準確率 0.830，RidgeClassifier 則於 Top-40 取得最高值 0.835；然而，兩模型在中高特徵數區間的表現差異有限，

且未呈現隨特徵數增加而持續改善的趨勢。考量任務一兩個方向之輸入規模一致性與整體表現，最終皆採用 Top-80。

任務二中，ElasticNet Logistic Regression 於 Top-40 取得最高平衡準確率 0.828，RidgeClassifier 則於 Top-30 取得最高值 0.842。ElasticNet Logistic Regression 在 Top-30 與 Top-40 間差異有限，而 RidgeClassifier 自 Top-30 後亦未再改善，因此綜合兩模型表現與特徵精簡性，最終採用 Top-30。

任務三的結果最為一致，ElasticNet Logistic Regression 與 RidgeClassifier 均於 Top-20 取得最高平衡準確率，分別為 0.813 與 0.812；增加更多特徵後皆未進一步改善，因此最終採用 Top-20。

整體而言，四個主要方向皆未呈現特徵數增加即可持續提升分類表現的趨勢。尤其任務二與任務三在較精簡的特徵子集下即可取得最佳或接近最佳的平衡準確率，顯示排序較後的特徵未能提供穩定的額外分類資訊。因此，後續分析分別採用任務一 Top-80、任務二 Top-30 與任務三 Top-20 作為正式輸入設定。不同 Top-*N* 設定下之 AUC 變化另列於附錄圖 G.1，作為模型排序能力之補充比較。

5.3.4 後續主要分析設定

綜合主要方向、模型候選子集與特徵數篩選結果，各任務之後續主要分析設定如表 5-9，並作為後續 Phase 1–4 實驗的固定分析輸入。

表 5-9 各任務後續主要分析設定

任務	主要方向	特徵數	模型數
任務一	APARC_ASEG_AMYG	Top-80	8
	APARC_ASEG_HIPPO	Top-80	
任務二	HIPPO_ASEG	Top-30	7
任務三	HIPPO	Top-20	7

5.4 整合分析：Phase 1–4 結果

本節比較篩選後之臨床加影像方向 (clin_fs) 與純臨床方向 (Clinical_only)

在 Phase 1–4 的結果，依序呈現正式基線、機率校準、閾值調整與集成分析。

5.4.1 Phase 1：正式基線

完成資料方向、模型與特徵數篩選後，Phase 1 比較臨床加影像與純臨床方向的正式基線表現。任務一結果如表 5-10 所示，其中 AMYG 與 HIPPO 分別為 APARC_ASEG_AMYG 與 APARC_ASEG_HIPPO 之簡稱；Sens.、Spec. 與 PPV 分別為敏感度、特異度與陽性預測值。

表 5-10 Phase 1 任務一各方向之逐模型結果

模型	特徵設定	BalAcc	AUC	Sens.	Spec.	PPV	Brier
ElasticNet Logistic	clin_fs (AMYG)	0.831	0.915	0.821	0.841	0.606	0.138
	clin_fs (HIPPO)	0.828	0.915	0.821	0.835	0.598	0.140
	Clinical_only	0.836	0.920	0.839	0.833	0.599	0.127
Ridge Classifier	clin_fs (AMYG)	0.840	0.915	0.838	0.843	0.613	0.156
	clin_fs (HIPPO)	0.828	0.908	0.825	0.831	0.591	0.159
	Clinical_only	0.848	0.921	0.866	0.830	0.603	0.156
Logistic Regression	clin_fs (AMYG)	0.838	0.913	0.814	0.862	0.638	0.112
	clin_fs (HIPPO)	0.827	0.904	0.806	0.847	0.611	0.119
	Clinical_only	0.834	0.919	0.834	0.835	0.604	0.116
LinearSVC	clin_fs (AMYG)	0.841	0.914	0.854	0.828	0.597	0.149
	clin_fs (HIPPO)	0.826	0.904	0.832	0.820	0.579	0.153
	Clinical_only	0.840	0.917	0.859	0.821	0.590	0.155
XGBoost	clin_fs (AMYG)	0.795	0.902	0.703	0.887	0.651	0.112
	clin_fs (HIPPO)	0.777	0.901	0.673	0.881	0.628	0.115
	Clinical_only	0.820	0.918	0.754	0.887	0.670	0.102
LightGBM	clin_fs (AMYG)	0.791	0.896	0.702	0.880	0.639	0.115
	clin_fs (HIPPO)	0.785	0.892	0.699	0.870	0.619	0.119
	Clinical_only	0.828	0.914	0.769	0.888	0.675	0.104
CatBoost	clin_fs (AMYG)	0.804	0.906	0.737	0.870	0.631	0.110
	clin_fs (HIPPO)	0.798	0.903	0.736	0.860	0.612	0.114
	Clinical_only	0.828	0.919	0.784	0.872	0.650	0.104
TabPFN	clin_fs (AMYG)	0.791	0.919	0.663	0.920	0.713	0.096
	clin_fs (HIPPO)	0.790	0.918	0.662	0.918	0.712	0.097
	Clinical_only	0.785	0.928	0.643	0.927	0.730	0.091

任務一中，純臨床方向在多數模型下維持較佳或相近的分類表現，其中 Clinical_only 搭配 RidgeClassifier 取得最高 BalAcc (0.848)，TabPFN 則取得最高 AUC (0.928) 與最低 Brier score (0.091)，顯示完整臨床資訊本身已具有相當強的預測能力。兩個臨床加影像方向相比，APARC_ASEG_AMYG 在 8 個模型中的 BalAcc 皆高於 APARC_ASEG_HIPPO，AUC 亦大致較高或相同，顯示前者在 Top-80 設定下具有較穩定的分類表現；然而，其最佳 BalAcc 與 AUC 仍未超越純臨床方向，加入影像後尚未形成一致的額外優勢。任務二進一步比較 HIPPO_ASEG 與純臨床方向，逐模型結果如表 5-11 所示。

表 5-11 Phase 1 任務二各方向之逐模型結果

模型	特徵設定	BalAcc	AUC	Sens.	Spec.	PPV	Brier
ElasticNet Logistic	clin_fs	0.822	0.921	0.823	0.821	0.962	0.118
	Clinical_only	0.840	0.928	0.816	0.863	0.970	0.122
Ridge Classifier	clin_fs	0.839	0.926	0.820	0.858	0.969	0.153
	Clinical_only	0.853	0.927	0.821	0.885	0.975	0.160
Logistic Regression	clin_fs	0.831	0.921	0.830	0.832	0.964	0.116
	Clinical_only	0.837	0.926	0.814	0.859	0.969	0.129
LinearSVC	clin_fs	0.820	0.924	0.799	0.840	0.965	0.144
	Clinical_only	0.832	0.924	0.813	0.852	0.968	0.145
XGBoost	clin_fs	0.786	0.908	0.873	0.699	0.940	0.103
	Clinical_only	0.795	0.916	0.882	0.707	0.942	0.098
ExtraTrees	clin_fs	0.716	0.917	0.960	0.473	0.907	0.081
	Clinical_only	0.713	0.922	0.958	0.468	0.906	0.080
TabPFN	clin_fs	0.752	0.932	0.962	0.542	0.918	0.074
	Clinical_only	0.752	0.932	0.956	0.548	0.919	0.074

註：clin_fs 表示臨床特徵結合 HIPPO_ASEG 影像特徵

任務二中，純臨床方向的優勢較為一致。ElasticNet Logistic Regression、RidgeClassifier、Logistic Regression、LinearSVC 與 XGBoost 的 BalAcc 皆以 Clinical_only 較高，其中 RidgeClassifier 取得整體最高 BalAcc (0.853)；AUC 在多數模型中亦以純臨床方向較高或與 HIPPO_ASEG 相近，TabPFN 則於兩方向皆達 0.932。部分線性模型加入 HIPPO_ASEG 後具有較低的 Brier score，顯示其機率預測誤差可能下降，但未同步轉化為 BalAcc 或 AUC 的提升。整體而言，任務二

仍以純臨床方向呈現較穩定的分類表現。任務三則進一步比較 HIPPO 與純臨床方向，逐模型結果如表 5-12 所示。

表 5-12 Phase 1 任務三各方向之逐模型結果

模型	特徵設定	BalAcc	AUC	Sens.	Spec.	PPV	Brier
ElasticNet	clin_fs	0.808	0.902	0.814	0.802	0.942	0.133
Logistic	Clinical_only	0.803	0.901	0.814	0.793	0.940	0.134
Ridge	clin_fs	0.804	0.900	0.789	0.818	0.945	0.168
Classifier	Clinical_only	0.810	0.899	0.812	0.808	0.943	0.171
Logistic	clin_fs	0.805	0.888	0.787	0.822	0.947	0.157
Regression	Clinical_only	0.807	0.900	0.815	0.799	0.941	0.144
LinearSVC	clin_fs	0.804	0.902	0.780	0.828	0.947	0.162
	Clinical_only	0.797	0.896	0.773	0.821	0.946	0.171
XGBoost	clin_fs	0.764	0.880	0.868	0.661	0.910	0.119
	Clinical_only	0.769	0.883	0.870	0.668	0.912	0.118
ExtraTrees	clin_fs	0.714	0.890	0.949	0.479	0.877	0.100
	Clinical_only	0.702	0.896	0.956	0.447	0.872	0.101
TabPFN	clin_fs	0.744	0.903	0.946	0.543	0.890	0.095
	Clinical_only	0.745	0.905	0.943	0.548	0.891	0.096

註：clin_fs 表示臨床特徵結合 HIPPO 影像特徵。

任務三的結果較為混合。加入 HIPPO 後，ElasticNet Logistic Regression、LinearSVC 與 ExtraTrees 的 BalAcc 高於純臨床方向，其餘模型則未呈現相同趨勢；整體最高 BalAcc 仍為 Clinical_only 搭配 RidgeClassifier (0.810)，最高 AUC 則為純臨床方向之 TabPFN (0.905)。不同指標的變化亦不完全一致，例如 LinearSVC 加入影像後 BalAcc 由 0.797 提升至 0.804，而 ExtraTrees 雖由 0.702 提升至 0.714，AUC 卻由 0.896 降至 0.890，顯示任務三的影像效益具有較明顯的模型與指標差異。綜合 Phase 1 三項任務，純臨床方向在任務一與任務二呈現較穩定的優勢；臨床加影像方向雖可在部分模型或指標下改善表現，但未形成跨任務與跨模型一致的增益。此外，TabPFN 多具有較高 AUC 與較低 Brier score，但在基線閾值下未必取得較高 BalAcc，而部分線性模型則具有較均衡的敏感度與特異度。此結果顯示，模型的排序能力、機率預測品質與特定操作點下的分類表現並不完全一致，後續進一步比較機率校準與閾值調整的影響。

5.4.2 Phase 2：機率校準

Phase 2 比較各任務與資料方向下，模型之未校準輸出 (Raw)、Platt scaling 與 Isotonic regression。各方向先彙整模型於 20 個隨機種子下的結果，再對該方向所有正式模型取平均，結果如表 5-13 所示。

表 5-13 Phase 2 各任務與資料方向之模型平均校準結果

任務	資料方向	Brier score			ECE			AUC	
		Raw	Platt	Isotonic	Raw	Platt	Isotonic	Raw / Platt	Isotonic
任務一	APARC_ASEG_AMYG	0.123	0.103	0.105	0.147	0.096	0.080	0.910	0.900
任務一	APARC_ASEG_HIPPO	0.127	0.106	0.108	0.150	0.097	0.082	0.906	0.897
任務一	Clinical_only	0.119	0.098	0.101	0.146	0.091	0.077	0.919	0.910
任務二	HIPPO_ASEG	0.113	0.081	0.083	0.158	0.080	0.064	0.921	0.910
任務二	Clinical_only	0.115	0.081	0.083	0.168	0.078	0.064	0.925	0.914
任務三	HIPPO	0.134	0.104	0.106	0.173	0.101	0.080	0.895	0.881
任務三	Clinical_only	0.133	0.104	0.107	0.173	0.101	0.086	0.897	0.884

註：Raw 與 Platt scaling 的 AUC 相同，故合併呈現。

由表 5-13 可見，七個資料方向的模型平均結果呈現一致趨勢：Platt scaling 在各方向均取得最低平均 Brier score，Isotonic regression 則均取得最低平均 ECE，顯示兩種校準方法皆能改善原始機率輸出，但優勢指標不同。進一步檢視 52 組「任務、方向與模型」設定，Platt scaling 在 38 組取得最低 Brier score，Isotonic regression 為 3 組，另有 11 組仍以 Raw 最低；ECE 則全部 52 組皆以 Isotonic regression 最低，顯示 Brier score 的最佳校準方式仍具有模型差異，而 ECE 的改善較為一致。逐模型結果列於附錄 H。此外，Platt scaling 在本研究結果中完整保留 Raw 的樣本排序，兩者 AUC 完全相同；Isotonic regression 採分段常數映射，可能使多個樣本得到相同的校準機率，因此雖具有較低 ECE，其 AUC 在各方向皆略低於 Raw 與 Platt scaling。例如任務二 Clinical_only 的平均 AUC 由 0.925 降至 0.914，任務三則由 0.897 降至 0.884。

為進一步呈現校準前後機率預測的變化，圖 5-5 以 RidgeClassifier 作為代表模型，呈現四個主要臨床加影像方向之可靠度曲線。各隨機種子先合併 5 個外層測試折的 OOF 預測建立可靠度曲線，再跨 20 個隨機種子彙整，以比較 Raw、Platt scaling 與 Isotonic regression 校準後與理想校準狀態之差異。




圖 5-5 RidgeClassifier 於四個主要資料方向之可靠度圖。黑色虛線表示理想校準狀態，陰影表示 95% 信賴區間。

橫軸為模型平均預測機率，縱軸為各機率區間內實際陽性比例，黑色虛線表示理想校準狀態；曲線越接近對角線，代表預測機率與實際發生比例越一致。由圖 5-5 可見，RidgeClassifier 的 Raw 曲線在四個方向皆存在不同程度的偏離，經 Platt scaling 與 Isotonic regression 後則整體向理想校準線靠近，與表 5-13 所呈現的 Brier score 與 ECE 改善趨勢一致。其中 Isotonic regression 對 ECE 的改善較明顯，而 Platt scaling 則在降低 Brier score 的同時保留原有 AUC。

綜合 Brier score、ECE 與 AUC，本研究後續以 Platt scaling 作為主要校準方法。其考量並非在所有模型與指標上皆優於 Isotonic regression，而是在整體改善機率品質的同時維持原有排序能力。由於校準後的機率尺度亦可能改變固定閾值 0.5 所對應的操作點，下一階段進一步評估不同任務與決策需求下的分類閾值。

5.4.3 Phase 3：閾值調整與操作點

Phase 3 評估校準後機率在不同決策閾值下的分類表現。本節以主分析採用的 Platt scaling 為主要呈現版本，比較固定 0.5、Youden、sens@0.90 與 spec@0.90 下不同的閾值設定，並整理各任務與資料方向之閾值及 BalAcc、敏感度與特異度，結果如表 5-14 所示。

表 5-14 Platt 校準後各任務於不同閾值目標下之操作點與分類表現

任務	資料方向	目標	平均閾值	中位數閾值	BalAcc	Sens.	Spec.
任務一	Clinical_only	default0.5	0.500	0.500	0.770	0.611	0.929
		youden	0.242	0.240	0.832	0.841	0.823
		sens@0.90	0.154	0.150	0.820	0.901	0.739
		spec@0.90	0.400	0.400	0.802	0.705	0.899
	APARC_ASEG_HIPPO	default0.5	0.500	0.500	0.749	0.570	0.928
		youden	0.221	0.220	0.816	0.836	0.796
		sens@0.90	0.135	0.130	0.788	0.901	0.675
		spec@0.90	0.425	0.430	0.777	0.653	0.901
	APARC_ASEG_AMYG	default0.5	0.500	0.500	0.758	0.584	0.931
		youden	0.238	0.235	0.824	0.834	0.813
		sens@0.90	0.143	0.140	0.797	0.899	0.695
		spec@0.90	0.400	0.400	0.796	0.691	0.900
任務二	Clinical_only	default0.5	0.500	0.500	0.727	0.954	0.500
		youden	0.848	0.850	0.824	0.794	0.854
		sens@0.90	0.695	0.700	0.795	0.903	0.686
		spec@0.90	0.885	0.890	0.824	0.751	0.897
	HIPPO_ASEG	default0.5	0.500	0.500	0.721	0.960	0.482
		youden	0.850	0.860	0.814	0.777	0.850
		sens@0.90	0.686	0.690	0.790	0.904	0.675
		spec@0.90	0.895	0.900	0.814	0.728	0.900
任務三	Clinical_only	default0.5	0.500	0.500	0.719	0.941	0.496
		youden	0.792	0.800	0.787	0.780	0.795
		sens@0.90	0.608	0.610	0.752	0.905	0.599
		spec@0.90	0.885	0.880	0.766	0.633	0.899
	HIPPO	default0.5	0.500	0.500	0.709	0.947	0.471
		youden	0.785	0.780	0.785	0.779	0.790
		sens@0.90	0.621	0.620	0.748	0.907	0.589
		spec@0.90	0.885	0.890	0.764	0.626	0.903

不同任務的操作閾值呈現明顯差異，但同一任務內不同資料方向的結果相對接近。任務一的三個方向下 Youden 平均閾值介於 0.221–0.242，明顯低於固定 0.5；任務二兩個方向介於 0.848–0.850，任務三兩個方向則介於 0.785–0.792。此差異亦反映於固定 0.5 下的敏感度與特異度：任務一的三個方向皆呈現較高特異度與較低敏感度，敏感度介於 0.570–0.611，特異度則介於 0.928–0.931；任務二與任務三則呈現相反趨勢，敏感度分別介於 0.954–0.960 與 0.941–0.947，特異度則僅介於 0.482–0.500 與 0.471–0.496。顯示即使皆採用 Platt scaling，固定 0.5 在不同任務下仍可能對應不同的敏感度與特異度配置。

經 Youden 調整後，各任務的敏感度與特異度趨於均衡，七個資料方向的 Bal-Acc 亦皆高於固定 0.5。任務一的三個方向下 BalAcc 由 0.749–0.770 提升至 0.816–0.832；任務二兩個方向由 0.721–0.727 提升至 0.814–0.824；任務三兩個方向則由 0.709–0.719 提升至 0.785–0.787。若採用不同操作目標，sens@0.90 可將敏感度維持在約 0.90，但伴隨較低的特異度；spec@0.90 則使特異度維持在約 0.90，同時降低敏感度。相較之下，Youden 在本研究三項任務中較能兼顧敏感度與特異度，顯示閾值選擇可依不同決策需求調整分類結果的取捨。

綜合 Phase 3 結果，機率校準後仍需進一步考量決策閾值所對應的分類操作點。固定 0.5 在三項任務中呈現不同的敏感度與特異度配置，而 Youden 在目前各資料方向下皆取得較均衡的分類表現。因此，後續 Phase 4 以 Platt scaling 搭配 Youden 作為主要比較設定，進一步評估方向內與跨方向集成能否改善單一模型的分類表現。

5.4.4 Phase 4：集成學習

Phase 4 以 Platt scaling 校準後之機率搭配 Youden 操作點作為主要結果，依序比較同一資料方向內的模型集成 (Stage 1) 與不同資料方向間的跨方向集成 (Stage 2)。由於此處的單一模型結果亦經 Platt 校準並重新選擇 Youden 閾值，因此其 BalAcc 與 Phase 1 固定 0.5 閾值下的數值不同。

表 5-15 Phase 4 方向內集成與最佳單一模型比較 (Platt + Youden)

任務	資料方向	最佳單一模型	單一模型 BalAcc	最佳集成設定	集成 BalAcc	Δ BalAcc
任務一	APARC_ASEG_AMYG	LinearSVC	0.8360	ALL-cvxSL	0.8354	-0.0006
任務一	APARC_ASEG_HIPPO	TabPFN	0.8312	ElasticNet_x_TabPFN-cvxSL	0.8298	-0.0013
任務一	Clinical_only	RidgeClassifier	0.8455	ALL-equal	0.8427	-0.0028
任務二	HIPPO_ASEG	RidgeClassifier	0.8251	Linear_only-equal	0.8270	+0.0019
任務二	Clinical_only	RidgeClassifier	0.8373	Tree_TabPFN_only-equal	0.8296	-0.0077
任務三	HIPPO	LinearSVC	0.7926	Linear_only-equal	0.7939	+0.0013
任務三	Clinical_only	RidgeClassifier	0.8001	Tree_TabPFN_only-equal	0.8031	+0.0031

註：最佳集成設定為該方向全部候選集成中 BalAcc 最高者； Δ BalAcc 為集成 BalAcc 減去同方向最佳單一模型 BalAcc。ALL 表示納入該方向全部基礎模型，Linear_only 表示線性模型，Tree_TabPFN_only 表示樹模型與 TabPFN；cvxSL 表示 convexSL。

表 5-15 顯示，方向內集成的 Δ BalAcc 介於 -0.0077 至 +0.0031。七個資料方向中，僅任務二的 HIPPO_ASEG、任務三的 HIPPO 與 Clinical_only 分別出現 +0.0019、+0.0013 與 +0.0031 的小幅提升；任務一的三個方向皆未超越各自最佳單一模型，任務二 Clinical_only 亦下降 0.0077。整體而言，方向內集成在部分設定下可略微改善分類表現，但正向差異最高僅為 0.0031，且僅出現在七個方向中的三個，尚未呈現穩定一致的改善趨勢。此外，各方向的最佳集成方式亦不相同，部分方向以等權平均取得較佳結果，部分方向則由 convexSL 表現較高，顯示方向內集成的效果仍會隨基礎模型組成、資料方向與分類任務而有所差異。

表 5-16 Phase 4 跨方向集成與最佳單一方向之 BalAcc 比較 (Platt + Youden)

任務	跨方向 集成設定	最佳 單一方向	單一方向 BalAcc	最佳 集成設定	跨方向集成 BalAcc	Δ BalAcc
任務一	AMYG + HIPPO	AMYG	0.8360	LinearSVC-cvxSL	0.8357	-0.0002
任務一	AMYG + HIPPO + Clinical	Clinical_only	0.8455	ALLxALL-cvxSL	0.8400	-0.0054
任務一	AMYG + Clinical	Clinical_only	0.8455	ALLxALL-cvxSL	0.8416	-0.0038
任務一	HIPPO + Clinical	Clinical_only	0.8455	ALLxALL-equal	0.8420	-0.0035
任務二	HIPPO_ASEG + Clinical	Clinical_only	0.8373	RidgeClassifier	0.8352	-0.0022
任務三	HIPPO + Clinical	Clinical_only	0.8001	LogisticRegression-cvxSL	0.7977	-0.0023

註：最佳單一方向表示該跨方向組合所包含方向中，BalAcc 最高之最佳單一模型結果。 Δ BalAcc 為跨方向集成 BalAcc 減去最佳單一方向 BalAcc，並由原始數值計算後取至小數第 4 位。任務一中 AMYG 表示 APARC_ASEG_AMYG，而 HIPPO 表示 APARC_ASEG_HIPPO；cvxSL 表示 convexSL；未標示 cvxSL 的同模型跨方向集成則採等權平均。

表 5-16 顯示，六種跨方向組合均未超越各自的最佳單一方向， Δ BalAcc 介於 -0.0054 至 -0.0002。其中，任務一僅 AMYG + HIPPO 幾乎追平最佳單一方向，差異為 -0.0002；當 Clinical_only 納入跨方向組合後，三種設定則下降約 0.0035–0.0054。任務二與任務三在臨床加影像方向結合純臨床方向後，亦分別下降 0.0022 與 0.0023。相較於 Stage 1 偶爾出現的微幅正向變化，Stage 2 的跨方向集成未呈現額外提升，顯示不同資料方向間雖可進一步整合預測結果，但目前尚未形成足以超越最佳單一方向的互補效果。為進一步檢視各方向在跨方向集成中的相對貢獻，表 5-17 整理各組合中最佳 convexSL 設定的方向別平均權重。

表 5-17 Phase 4 最佳 convexSL 跨方向集成之方向別權重 (Platt + Youden)

任務	跨方向 集成設定	最佳 convexSL 集成設定	convexSL BalAcc	Clinical weight	AMYG weight	HIPPO weight	HIPPO_ASEG weight
任務一	AMYG + HIPPO	LinearSVC-cvxSL	0.8357	–	79.7%	20.3%	–
任務一	AMYG + HIPPO + Clinical	ALLxALL-cvxSL	0.8400	72.1%	26.3%	1.6%	–
任務一	AMYG + Clinical	ALLxALL-cvxSL	0.8416	72.6%	27.4%	–	–
任務一	HIPPO + Clinical	ALLxALL-cvxSL	0.8414	86.2%	–	13.8%	–
任務二	HIPPO_ASEG + Clinical	RidgeClassifier-cvxSL	0.8327	55.7%	–	–	44.3%
任務三	HIPPO + Clinical	LogisticRegression-cvxSL	0.7977	66.3%	–	33.7%	–

註：本表於各跨方向組合中選取 BalAcc 最高之 convexSL 候選設定，再先將同一外層折內相同資料方向之模型權重加總、於每個隨機種子內平均 5 折，最後跨 20 個隨機種子彙整。Clinical 表示 Clinical_only；AMYG、HIPPO 與 HIPPO_ASEG 均為前期管線之臨床加影像方向，而非純影像模態。

方向權重結果顯示，只要 Clinical_only 納入 convexSL，純臨床方向的平均權重皆超過 50%。任務一的三個方向共同集成時 Clinical 權重為 72.1%，與 AMYG、HIPPO 分別組合時則為 72.6% 與 86.2%；任務二與任務三亦分別達 55.7% 與 66.3%。另一方面，臨床加影像方向仍保有一定權重，例如任務二 HIPPO_ASEG 為 44.3%，任務三 HIPPO 為 33.7%，顯示這些方向仍參與集成預測，但其貢獻尚未轉化為高於最佳單一方向的 BalAcc。綜合 Phase 4，方向內集成僅在部分設定出現小幅改善，最大 ΔBalAcc 為 +0.0031，而六種跨方向集成皆未超越最佳單一方向；當純臨床與臨床加影像方向共同進入 convexSL 時，權重亦多偏向 Clinical_only。整體而言，在目前模型、特徵與資料方向設定下，集成方法雖能重新分配不同模型與方向的預測權重，其額外分類增益仍相當有限，且尚未呈現穩定一致的改善。

進一步綜合 Phase 1–4，可歸納出三項主要觀察。首先，純臨床方向在多數任務與模型中已具有較強的分類與排序能力，臨床加影像方向則僅在部分模型或指標下呈現改善，尚未形成跨任務一致的優勢，且任務三的模式差異較為明顯。其次，Phase 2 與 Phase 3 顯示，模型的排序能力、機率品質與特定操作點下的分類表現應分別考量；Platt scaling 可改善整體機率品質並保留 AUC，而重新選擇決策閾值則可調整固定 0.5 下敏感度與特異度的不平衡，不同任務的適合閾值亦有所差異。最後，Phase 4 顯示進一步結合多個模型或資料方向後，整體改善仍相當有限，跨方向集成亦未呈現額外提升，顯示在目前分析管線下，最佳單一模型與純臨床方向已能提供相當主要的分類訊號。

5.5 完整臨床基準下之影像增量分析

前述 Phase 1–4 結果顯示，純臨床方向已具有穩定的分類與排序能力。本節進一步以完整保留 33 個正式臨床預測特徵之 Clin33 作為基準，不再沿用前述預先劃分之影像方向，而將 397 個 FreeSurfer 特徵重新整合為單一候選池，於各任務中獨立進行特徵排序與 Top-K 篩選。據此建立純影像方向 FS_topK 與早期融合方向 Clin33_FS_topK，檢驗影像特徵在完整臨床資訊之外是否提供額外預測價值；另以 NN_fusion 與跨方向預測集成分別代表中期與晚期融合，比較不同融合層級下的影像增量效果。逐模型 AUC 增量比較及其他補充結果列於附錄 I。

5.5.1 純影像特徵數篩選與組成

純影像特徵僅於 397 個 FreeSurfer 候選特徵中進行 ANOVA F-score 排序，不與臨床特徵共同競爭排名。由於不同模型適合的影像特徵數並不完全一致，本研究以五個代表模型比較不同 Top-K 下的 AUC，並依整體曲線表現進行任務層級的折衷選擇，而非直接採用單一模型的最佳特徵數。各任務之 Top-K 掃描結果如圖 5-6 所示。




圖 5-6 五個代表模型於不同 FreeSurfer Top-K 特徵數下之平均 AUC 表現。不同模型之最佳特徵數並不完全一致，正式 K 值依各任務整體 AUC 曲線進行選擇。

各模型的最佳 K 值與 AUC 變化趨勢存在差異，部分模型在增加特徵後趨於

穩定，亦有模型於較小或較大的特徵數下取得較高 AUC。綜合五個代表模型的整體表現後，最終任務一與任務二採用 Top-30，任務三則採用 Top-40。進一步檢視正式 Top-K 特徵的 FreeSurfer 來源群組，其組成如圖 5-7 所示。




圖 5-7 三項任務正式純影像 Top-K 特徵之 FreeSurfer 來源群組組成。任務一與任務二使用 Top-30，任務三使用 Top-40。

任務一 Top-30 中包含 16 個 HIPPO 特徵 (53.3%)、5 個 BRAINVOL 特徵 (16.7%)、4 個 APARC 特徵 (13.3%)、4 個 AMYG 特徵 (13.3%) 與 1 個 ASEG 特徵 (3.3%)。任務二與任務三則更集中於內側顳葉相關結構：任務二 Top-30 中 HIPPO 占 23 個 (76.7%)，另包含 5 個 AMYG 與 2 個 ASEG 特徵；任務三 Top-40 中則包含 28 個 HIPPO (70.0%)、6 個 AMYG (15.0%) 及 6 個 ASEG (15.0%)。

整體分布與前述影像方向篩選所呈現的趨勢大致一致。任務一除海馬與杏仁核外，亦保留全腦體積與皮質區域相關特徵，影像訊號來源相對分散；任務二與任務三則主要集中於海馬、杏仁核與相關細分結構。顯示重新由完整 FreeSurfer 特徵池進行排序後，三項任務仍呈現不同的影像特徵組成，其中海馬相關特徵在各任務中皆占有較高比例。

5.5.2 純臨床、純影像與融合方向之分類表現

為比較不同資料來源與融合方式的代表性分類表現，本節整理純臨床、純影像、早期融合與中期融合之主要結果，如表 5-18 所示。各資料方向皆以 Youden 操作點下平均 BalAcc 最高之模型作為代表，並同時列出該模型之 Sens、Spec 與 AUC；故表中 AUC 為同一 BalAcc 最佳模型之排序能力，並非另依 AUC 重新選取模型。

表 5-18 完整臨床基準分析之主要分類表現

任務	設定	最佳模型	BalAcc	Sens.	Spec.	AUC
任務一	Clin33	RidgeClassifier	0.843	0.849	0.837	0.922
	FS_top30	GaussianNB	0.705	0.725	0.685	0.772
	Clin33_FS_top30	TabPFN	0.842	0.835	0.850	0.929
	NN_fusion	NN_fusion	0.806	0.820	0.792	0.909
任務二	Clin33	RidgeClassifier	0.844	0.796	0.892	0.928
	FS_top30	GaussianNB	0.711	0.692	0.731	0.782
	Clin33_FS_top30	ElasticNetLogistic	0.834	0.772	0.896	0.926
	NN_fusion	NN_fusion	0.774	0.777	0.771	0.888
任務三	Clin33	ExtraTrees	0.803	0.779	0.827	0.898
	FS_top40	ElasticNetLogistic	0.691	0.709	0.674	0.746
	Clin33_FS_top40	TabPFN	0.802	0.776	0.828	0.898
	NN_fusion	NN_fusion	0.748	0.778	0.718	0.852

註：各設定之最佳模型依 Youden 操作點下的平均 BalAcc 選取。

三項任務中，純影像方向的分類表現皆明顯低於完整臨床方向。任務一以 Clin33 搭配 RidgeClassifier 取得 BalAcc 0.843，而 FS_top30 僅為 0.705。早期融合 TabPFN 的 BalAcc 為 0.842，與純臨床結果相近，且 AUC 達 0.929，高於表中純臨床 RidgeClassifier 的 0.922；但其 BalAcc 仍未超越完整臨床基準。中期融合 NN_fusion 則降至 BalAcc 0.806、AUC 0.909。

任務二的純臨床優勢最為明確。Clin33 下 RidgeClassifier 的 BalAcc 與 AUC 分別為 0.844 與 0.928，早期融合則為 0.834 與 0.926，而純影像方向僅為 0.711 與

0.782。中期融合亦降至 BalAcc 0.774，顯示在認知異常與認知正常分類中，目前影像資訊的加入並未改善主要分類表現。

任務三中，Clin33 下 ExtraTrees 與早期融合 TabPFN 的 BalAcc 分別為 0.803 與 0.802，兩者幾乎相同，AUC 四捨五入後亦同為 0.898；早期融合雖可接近完整臨床基準，但仍未形成明確優勢。中期融合的 BalAcc 與 AUC 則分別為 0.748 與 0.852，同樣未優於完整臨床方向。不過，上述結果僅反映各資料設定中表現最佳的代表模型，仍可能受到個別模型表現影響；為進一步檢驗影像加入後的變化是否能跨模型一致出現，下一節以相同 12 個模型進行逐模型配對 AUC 增量比較。

5.5.3 影像特徵之 AUC 增量比較

主要增量分析比較 Clin33_FS_topK 與 Clin33 的 AUC 差異。各模型先於同一隨機種子內平均 5 個外層折之 AUC，再以 20 個隨機種子所得的配對 AUC 差異進行 paired Wilcoxon signed-rank test，以評估不同資料切分下增量方向的一致程度。三項任務共包含 36 項主要比較，並共同進行 BH-FDR 校正。另將純影像 FS_topK 與 Clin33 進行 36 項補充比較，並獨立進行 BH-FDR 校正。結果整理於表 5-19。

表 5-19 完整臨床基準下之逐模型 AUC 增量比較摘要

任務	比較	$q < 0.05$ 且 $\Delta > 0$	$q < 0.05$ 且 $\Delta < 0$	其餘	平均 ΔAUC	ΔAUC 範圍
任務一	Clin33_FS_top30 vs. Clin33	0	8	4	-0.0053	[-0.0215, +0.0019]
任務二	Clin33_FS_top30 vs. Clin33	0	12	0	-0.0126	[-0.0341, -0.0030]
任務三	Clin33_FS_top40 vs. Clin33	0	9	3	-0.0148	[-0.0428, +0.0043]
任務一	FS_top30 vs. Clin33	0	12	0	-0.1441	[-0.1678, -0.0718]
任務二	FS_top30 vs. Clin33	0	12	0	-0.1512	[-0.1822, -0.1049]
任務三	FS_top40 vs. Clin33	0	12	0	-0.1487	[-0.1647, -0.1084]

註： ΔAUC 定義為比較方向減去 Clin33。前三列為臨床加影像相對純臨床之主要比較，後三列為純影像相對純臨床之補充比較，兩組各包含 36 項比較並分別進行 BH-FDR 校正。由於結果來自同一研究樣本的重複資料切分， q 值主要用於評估差異方向在不同切分下的一致程度。

主要比較顯示，三項任務皆未出現 $q < 0.05$ 且平均 ΔAUC 為正的模型。任務一有 8 個模型呈現顯著負向差異，整體平均 ΔAUC 為 -0.0053；任務二的負向

趨勢最為一致，12 個模型皆為負向且 $q < 0.05$ ，平均 ΔAUC 為 -0.0126 ；任務三則有 9 個模型呈現顯著負向差異，平均 ΔAUC 為 -0.0148 。雖然任務一少數模型可得到正向平均增量，但未形成跨模型一致的改善，顯示影像加入完整臨床資訊後，尚未呈現穩定的額外排序能力。

純影像方向與完整臨床方向的差異更為明顯。三項任務中，12 個模型的平均 ΔAUC 皆為負，且均達 $q < 0.05$ ，整體平均差異約為 -0.144 至 -0.151 。顯示 FreeSurfer 特徵本身雖具有分類訊號，其獨立排序能力仍明顯低於完整臨床特徵。主要比較之逐模型 ΔAUC 分布進一步整理於圖 5-8。




圖 5-8 各任務中 Clin33_FS_topK 相對 Clin33 之逐模型 AUC 差異。 ΔAUC 大於 0 表示加入影像後 AUC 提升，小於 0 則表示下降。

由圖 5-8 可見，三項任務的 ΔAUC 整體多分布於 0 以下，其中任務二的負向趨勢最為一致；任務一與任務三雖有少數模型呈現小幅正向變化，但未形成一致的影像增量效果。

5.5.4 操作點比較

除主要 AUC 增量比較外，本節進一步比較 Youden、sens@0.90 與 spec@0.90 三種操作目標，以觀察不同決策需求是否改變純臨床與融合方向的相對表現。各任務於不同操作目標下 BalAcc 最高之設定如表 5-20 所示。

表 5-20 完整臨床基準分析於不同操作目標下之最佳結果

任務	操作目標	最佳方向／模型	平均閾值	BalAcc	Sens.	Spec.	AUC
任務一	youden	Clin33 / RidgeClassifier	0.508	0.843	0.849	0.837	0.922
	sens@0.90	Clin33_FS_top30 / TabPFN	0.155	0.840	0.906	0.774	0.929
	spec@0.90	Clin33_FS_top30 / TabPFN	0.375	0.827	0.756	0.898	0.929
任務二	youden	Clin33 / RidgeClassifier	0.509	0.844	0.796	0.892	0.928
	sens@0.90	Clin33 / TabPFN	0.711	0.819	0.904	0.734	0.933
	spec@0.90	Clin33 / RidgeClassifier	0.511	0.850	0.793	0.906	0.928
任務三	youden	Clin33 / ExtraTrees	0.757	0.803	0.779	0.827	0.898
	sens@0.90	Clin33_FS_top40 / GaussianNB	0.010	0.782	0.733	0.832	0.835
	spec@0.90	Clin33 / RidgeClassifier	0.536	0.807	0.704	0.910	0.901

註：表中為各任務與操作目標下平均 BalAcc 最高之設定。閾值由其餘外層折之 OOF 預測選取後評估於保留折；sens@0.90 與 spec@0.90 為閾值選擇目標，不保證保留折之平均 Sens 或 Spec 仍達 0.90。

Youden 操作點下，三項任務的最佳設定皆來自純臨床 Clin33，顯示在兼顧敏感度與特異度時，完整臨床方向仍具有較穩定的整體表現。改採特定操作目標後，最佳設定則隨任務而有所變化。任務一的 sens@0.90 與 spec@0.90 皆由早期融合 TabPFN 取得最高 BalAcc，分別取得 0.906 的敏感度與 0.898 的特異度；任務二三種操作目標則均以 Clin33 表現最佳。任務三僅 sens@0.90 選到早期融合 GaussianNB，但其保留折平均敏感度僅為 0.733，顯示依高敏感度準則選出的閾值套用至保留資料後，不一定仍能維持原先設定的目標。整體而言，不同操作目標會改變敏感度與特異度間的取舍，並可能影響最佳模型與資料方向；影像融合雖在部分設定下取得較佳結果，但尚未形成跨任務一致優於完整臨床基準的趨勢。

5.5.5 方向內集成與晚期融合

在預測層級集成中，本研究將 E1 定義為同一資料方向內不同模型之方向內集成；E2a、E2c 與 E2d 則代表不同形式的跨資料方向晚期融合，其中 E2a 為同模型跨方向集成，E2c 為純臨床與純影像最佳模型之組合，E2d 則進一步納入完整候選成員進行整合。各代號之成員組成與完整集成設計詳見第 4.9.7 節，等權平均、效能加權與 convexSL 等集成方法則詳見第 4.8.4 節。表 5-21 整理三項任務於 Youden 操作點下，方向內集成與跨方向晚期融合各自表現最佳的設定。

表 5-21 方向內集成與跨方向晚期融合之最佳結果

任務	類型	設定	方法	BalAcc	Sens.	Spec.	AUC	ΔBalAcc
任務一	方向內 晚期融合	E1 Clin33	perf	0.8459	0.8612	0.8306	0.9246	+0.0029
		E2d	perf	0.8417	0.8441	0.8392	0.9220	-0.0013
任務二	方向內 晚期融合	E1 Clin33	equal	0.8338	0.8060	0.8617	0.9283	-0.0099
		E2a ExtraTrees	convexSL	0.8362	0.8124	0.8600	0.9225	-0.0075
任務三	方向內 晚期融合	E1 Clin33	convexSL	0.7993	0.8036	0.7950	0.9066	-0.0035
		E2a TabPFN	perf	0.8049	0.7965	0.8133	0.8953	+0.0021

註：ΔBalAcc 為相對各任務最佳 Clin33 單一模型之差異。E1 為方向內集成，E2a、E2c 與 E2d 為跨方向晚期融合；equal、perf 與 convexSL 分別表示等權平均、效能加權與凸組合超學習器。完整設定詳見第 4.9.7 節。

方向內集成的效果依任務而異。任務一的 E1|Clin33 以效能加權將 BalAcc 由最佳單一臨床模型約 0.843 提升至 0.8459，ΔBalAcc 為 +0.0029。由於此設定僅整合 Clin33 方向內的不同模型，其改善反映模型集成效益，而非影像資訊所帶來的增量。相較之下，任務二與任務三的方向內集成分別下降 0.0099 與 0.0035，顯示同一資料方向內增加模型組合並未形成跨任務一致的改善。

跨方向晚期融合亦呈現類似結果。任務一與任務二的最佳設定分別較 Clin33 基準下降 0.0013 與 0.0075；僅任務三的 E2a|TabPFN 取得 BalAcc 0.8049，較純臨床最佳結果 0.8028 微幅提升 0.0021。然而，其 AUC 為 0.8953，低於純臨床基準

的 0.8980，顯示此改善僅出現在特定操作點下，並未伴隨排序能力同步提升。整體而言，方向內集成與跨方向晚期融合可在個別任務產生小幅變化，但依舊未形成穩定且跨任務一致的額外分類增益。

5.5.6 不同融合層級之整體比較

將純臨床、純影像、早期融合、中期融合與跨方向晚期融合置於同一架構中比較，以整體檢視不同影像整合層級的分類表現。各任務結果整理於表 5-22，各格依序呈現「BalAcc / AUC」，其中 BalAcc 為 Youden 操作點下之結果。

表 5-22 完整臨床基準下不同融合層級之表現比較

任務	Clin33	FS_topK	早期融合	中期融合	晚期融合
任務一	0.843 / 0.922	0.705 / 0.772	0.842 / 0.929	0.806 / 0.909	0.842 / 0.922
任務二	0.844 / 0.928	0.711 / 0.782	0.834 / 0.926	0.774 / 0.888	0.836 / 0.923
任務三	0.803 / 0.898	0.691 / 0.746	0.802 / 0.898	0.748 / 0.852	0.805 / 0.895

註：各格依序為「BalAcc / AUC」。早期融合為 Clin33_FS_topK，中期融合為 NN_fusion；晚期融合採跨方向 E2a、E2c 或 E2d 之最佳設定，不包含方向內 E1。數值統一取至小數第 3 位，與前述表格之第 4 位小數差異係四捨五入所致。粗體表示同一任務之最高值。

若僅比較三種融合策略，早期融合與晚期融合的整體表現皆優於中期融合，但兩者的優勢指標略有不同。早期融合在三項任務的 AUC 分別為 0.929、0.926 與 0.898，其中任務一取得所有設定中的最高 AUC；晚期融合則在任務二與任務三取得較高的融合後 BalAcc，分別為 0.836 與 0.805，其中任務三亦微幅超越純臨床結果。相較之下，中期融合在三項任務的 BalAcc 與 AUC 均低於早期與晚期融合，顯示目前以 NN_fusion 進行特徵表示整合並未展現明顯優勢。整體來看，早期融合較有利於維持排序能力，晚期融合則偶爾可改善特定操作點下的分類表現，但兩者皆未形成跨任務一致的提升。

綜合本節的影像增量分析，可以進一步看出完整臨床資訊在三項分類任務中的重要性。純影像方向雖能捕捉以海馬、杏仁核及相關結構為主的疾病相關訊號，但其分類與排序能力明顯低於臨床特徵；當影像進一步以早期、中期與晚期等不同方式加入後，亦僅在少數任務、模型或操作目標下出現局部改善。其中，早期融合整體最接近純臨床表現，並在部分任務取得較高 AUC；晚期融合則偶爾可於特定操作點下帶來小幅 BalAcc 提升，而中期融合的整體表現相對較弱。然而，36 項逐模型 AUC 增量比較中未出現平均 ΔAUC 為正且 $q < 0.05$ 的模型，顯示這些局部改善尚未形成跨模型與跨任務一致的影像增量。整體結果說明，在目前資料與分析架構下，臨床特徵已涵蓋主要且相對穩定的預測訊號，FreeSurfer 結構影像則較適合作為補充性的解剖資訊，其額外預測價值仍針對不同任務與模型有明顯的依賴性。

5.5.7 固定參數敏感度分析

為檢視實驗結果是否高度依賴逐外層折的超參數選擇，本研究另以固定超參數重新執行主要分析流程，並與原先逐外層折調參之結果進行比較。此分析主要觀察模型表現、相對排序與集成結果是否因參數設定方式改變而產生明顯波動；固定參數之選取方式與完整比較結果列於附錄 J。

整體結果顯示，固定參數與逐外層折調參版本在 AUC 等排序指標上表現相近，未呈現一致的升降趨勢，顯示主要模型對超參數設定方式具有一定穩定性。相較之下，BalAcc、敏感度與特異度等閾值相關指標波動稍大，反映預測機率尺度與操作點仍可能有所差異。Phase 4 中部分最佳集成組合雖隨參數設定方式改變，整體效能差異有限；三項任務之最佳晚期融合設定亦維持一致。整體而言，固定參數與逐外層折調參所得結果在主要表現趨勢與模型相對比較上皆大致維持一致，顯示不同超參數設定方式未造成明顯的整體結果差異。

第六章 結論與未來展望

本研究整合結構式腦影像量化特徵與臨床特徵，建立失智與非失智、認知異常與認知正常，以及 MCI 與認知正常三項二元分類任務。分析流程涵蓋 FreeSurfer 影像方向與模型篩選、eTIV 校正評估、特徵排序與特徵數選擇，並進一步進行機率校準、閾值調整、集成學習及早期、中期與晚期融合分析。最後以完整臨床資訊作為參照，評估結構影像的額外預測價值，並透過固定參數敏感度分析檢視結果對超參數設定的穩定性。

6.1 研究結論與貢獻

綜合各階段實驗結果，本研究主要得到以下五項觀察。

1. 不同認知分類任務呈現不同的影像訊號與特徵組成。

純影像方向篩選顯示，失智與非失智分類較受益於皮質分區、皮質下結構與內側顳葉資訊的整合；認知異常與認知正常、MCI 與認知正常分類則較集中於海馬亞區及相關皮質下結構。候選方向篩選後，任務一保留 APARC_ASEG_AMYG 與 APARC_ASEG_HIPPO，任務二保留 HIPPO_ASEG，任務三則以 HIPPO 為主要方向。後續特徵排序亦呈現相近的解剖趨勢，影像特徵主要涉及海馬整體體積、海馬細分亞區、杏仁核與楔前葉等區域。綜合上述結果，不同分類任務所對應的優勢影像方向與特徵組成並不完全相同，反映結構影像訊號具有一定的任務差異。此外，增加影像群組或持續擴增特徵數並未帶來一致的效能改善，顯示較多影像資訊不必然提供額外的有效分類訊號，仍需依各任務進行方向與特徵數篩選。

2. 前處理、特徵數與模型選擇均會影響最終分類表現。

eTIV 分析顯示，多數體積特徵與顱內總體積具有顯著線性關係，尤其集中於全腦體積、白質分區與皮質分區特徵；但本研究採用的殘差校正並未穩定改善分類結果，因此後續分析採用 No_Adj 版本。此結果顯示，統計上顯著的體積關聯不一定能直接轉化為預測效能提升。特徵排序方面，三項任務的前段特徵仍以臨床資訊為主，其中 CASI 分項與 MMSE 等認知量表在不同任務中皆具有較高排序，任務三中 APOE 亦位於前段。Top- N 掃描最終分別選擇任務一 Top-80、任務二 Top-30 與任務三 Top-20，再次顯示較多特徵不必然帶來更多有效預測資訊。

模型比較亦呈現不同的效能特性。線性模型在多數任務下具有相對穩定的 BalAcc，敏感度與特異度亦通常較為均衡；TabPFN 則常具有較高 AUC 與較佳的機率預測品質，但其排序能力不一定能在特定閾值下同步轉化為較高的 BalAcc。因此，模型評估不宜僅依賴單一指標，而應同時考量分類表現、排序能力、機率品質及實際決策操作點。

3. 機率校準與閾值調整改善的是不同層面的模型表現。

Phase 2 顯示，Platt scaling 與 Isotonic regression 皆能改善原始輸出的機率品質。其中 Platt scaling 在各資料方向的平均結果中具有較低的 Brier score，並能完整保留原始 AUC，因此作為後續主要校準方式；Isotonic regression 則在 ECE 上具有較佳結果。Phase 3 進一步顯示，固定 0.5 閾值在不同任務下可能形成不同方向的敏感度與特異度偏移，Youden 操作點較適合取得兩者之間的平衡，而 sens@0.90 與 spec@0.90 則可依特定決策需求重新選擇操作點。此結果說明，AUC 所反映的排序能力、機率校準品質與特定閾值下的分類表現雖彼此相關，但並非相同的評估面向。

4. 影像融合可產生局部改善，但尚未形成穩定的額外預測增益。

Phase 1–4 與後續完整臨床分析皆顯示，臨床資訊在三項任務中已提供主要且相對穩定的預測訊號。純影像方向雖具有可辨識的分類能力，其整體表現仍低於臨床特徵；在臨床資訊之外加入影像後，36 項逐模型 AUC 主要比較中未觀察到平均 ΔAUC 為正且 $q < 0.05$ 的模型，正向變化亦未形成跨模型一致的趨勢。

不同融合層級則呈現不同的局部特性。早期融合整體最接近純臨床方向，並在部分任務維持較高 AUC；晚期融合偶爾可在特定操作點下取得小幅 Bal-Acc 改善；中期融合 NN_fusion 的整體表現則相對較弱。方向內集成亦僅於少數設定取得極小幅改善，跨方向集成則未呈現一致優於最佳單一方向的結果。整體而言，增加影像資訊或提高融合複雜度並不必然帶來額外效能，影像所提供的改善仍明顯受到任務、模型、融合方式與評估指標影響。

5. 主要研究結果對超參數設定方式具有一定穩定性，並凸顯臨床與影像資訊應分別看待。

固定參數敏感度分析顯示，固定參數與逐外層折調參版本在 AUC 等排序指標上的表現相近，主要模型與整體比較趨勢未出現明顯改變。BalAcc、敏感度與特異度等操作點相關指標雖呈現較大的變動，Phase 4 中部分最佳集成組合亦會隨參數設定方式改變，但其最終效能差異整體有限，三項任務的最佳晚期融合設定亦維持一致。顯示主要研究發現並非高度依賴特定的超參數選擇方式。

綜合上述結果，本研究的核心發現並非結構影像缺乏與認知退化相關的資訊，而是在目前資料規模、FreeSurfer 量化特徵與分析流程設定下，這些影像特徵所提供的額外訊號尚未穩定轉化為更高的分類效能。臨床認知量表與相關臨床

變數仍構成三項任務的主要預測來源；結構影像則保留具有神經解剖意義的疾病相關訊號，其額外預測價值仍有待更大樣本、不同影像表徵與外部資料進一步驗證。

本研究的主要貢獻在於建立一套由影像方向篩選、特徵選擇、模型比較、機率校準、決策閾值調整、集成學習、多層級融合至敏感度分析的完整分類流程，並將「影像本身是否具有分類能力」與「影像能否在既有臨床資訊之外提供額外預測價值」加以區分。分析結果顯示，FreeSurfer 結構量化特徵即使單獨使用，仍具有一定程度的認知狀態辨識能力，且所選特徵多集中於海馬、杏仁核及相關腦區，使模型結果同時保有神經解剖上的可解釋性。另一方面，當較完整的臨床資訊可取得時，臨床特徵仍提供較主要且穩定的預測訊號，說明影像與臨床資訊在實際應用上可能具有不同的角色，而非單純互相取代。

從實務應用角度而言，完整臨床資訊的取得可能涉及認知量表施測、病史整合、專業人員評估及資料彙整等程序；若部分應用情境受到時間、人力或臨床資料完整性的限制，既有結構 MRI 經量化後所提供的影像特徵，可能作為初步風險評估或第一階段分流的輔助資訊，再由後續較完整的臨床評估進行進一步確認。此一應用方式並非以影像取代臨床診斷，而是提供另一種可能的資訊使用順序。其實際可行性仍需進一步透過外部資料、前瞻性研究，以及檢查時間與成本效益分析加以驗證。

6.2 研究限制與未來展望

本研究雖已從資料方向、模型、校準、操作點與融合層級系統性比較臨床與結構影像資訊，仍存在部分限制。相關限制及其可延伸之研究方向整理如下。

1. 資料規模與外部驗證。

本研究樣本數仍相對有限，三項二元分類任務亦存在不同程度的類別不平衡。雖採用 20 個隨機種子與交叉驗證，以降低單一資料切分所造成的偶然性，有限樣本仍可能限制高維影像特徵與較複雜模型的穩定性，亦可能增加不同切分間的效能波動。未來若能擴大樣本數，並納入外部資料集或多中心資料進行獨立驗證，將有助於評估目前研究結果在不同收案條件、MRI 掃描環境與族群組成下是否具有相近的泛化能力。

2. 影像資訊表示與體積校正方法仍可進一步擴充。

本研究主要採用 FreeSurfer 所產生的區域層級腦結構量化特徵，其優點是具有清楚的神經解剖對應，能系統性比較海馬、杏仁核、皮質分區與皮質下結構等資訊。然而，FreeSurfer 尚包含其他未完整納入本研究的輸出，例如 mri 資料夾中的結構影像與分割結果、surf 中的皮質表面與網格資訊、label 中的腦區標籤，以及其他尚未轉換為正式特徵的統計欄位。未來可進一步利用這些影像、表面與標籤層級資訊，並結合原始 MRI 表徵或其他影像模態，檢驗區域統計特徵之外是否仍存在可利用的互補訊號。

此外，本研究僅評估一種以 Normal 子群估計線性關係的 eTIV 殘差校正策略，尚未完整比較比例校正、非線性校正，或同時納入年齡、性別、教育程度等因素的多變量方法。後續研究可進一步比較不同校正策略，以確認體積標準化方式對預測效能與影像特徵解釋所造成的影響。

3. 多模態融合方法仍屬相對受控的設計。

本研究已比較早期融合、中期融合 NN_fusion 與跨方向預測層級的晚期融合，但所採用的融合架構仍相對簡化。研究結果顯示，提高融合複雜度並未自然帶來更高效能，其中中期融合的表現亦相對較弱。未來若能結合更大樣本與更完整的影像表徵，可進一步評估注意力機制、多模態表徵學習或其他融合架構，以檢驗臨床與影像資訊之間是否存在目前方法未能充分利用的互補關係。

4. 部分研究層級與後續分析流程尚未完全巢狀於外層交叉驗證。

前期影像方向篩選、候選方向與模型篩選、部分特徵排序與特徵數選擇，皆先根據同一批研究樣本之交叉驗證結果完成，再固定相關設定進入後續分析。因此，目前的 nested cross-validation 主要確保設定固定後之外層測試折不參與折內前處理、超參數選擇與模型訓練，但並非所有研究層級之資料驅動決策皆完整包含於每一外層訓練折內。

此外，Phase 2–4 皆以 Phase 1 產生的 OOF 預測作為後續校準、閾值與集成分析的共同基礎，因此較適合作為相同基礎預測下不同後處理方法之比較與結果觀察，而非完全獨立的端到端泛化效能估計。未來可將上述選擇與後續處理完整納入各外層訓練資料內重新估計，或透過獨立外部資料進一步驗證，以取得更嚴格的泛化能力評估。

5. 重複資料切分之統計結果主要用於評估差異穩定性。

本研究以 20 個隨機種子所得的重複交叉驗證結果作為配對單位，並使用 paired Wilcoxon signed-rank test 與 BH-FDR 校正評估逐模型 AUC 差異。由於各隨機種子皆使用同一批研究樣本，僅改變受試者之外層折分配，相關 p 值與 q 值主要作為觀察不同資料切分下差異方向與穩定程度的依據。此分析

有助於避免僅根據單一資料切分判斷模型差異，但其結果仍以本研究樣本內的重複切分比較為主。未來若能取得獨立外部資料，可進一步確認影像加入臨床資訊後的增量效果，並評估相關結果於其他資料來源中的一致性。

綜合上述限制，後續研究可由單純增加模型複雜度，進一步轉向資料規模、影像資訊表示、分析流程完整性與外部驗證等面向同步改善。在資料層面，若能納入更多受試者與多中心資料，並建立獨立外部驗證資料，將有助於確認目前模型表現與影像增量結果在不同收案條件、族群組成與影像來源下的一致性。在影像資訊方面，則可進一步整合 FreeSurfer 其他輸出、原始 MRI 影像或其他影像形態，以補充目前區域量化特徵可能未能完整反映的資訊，並重新檢驗結構影像在臨床資訊之外是否具有更穩定的額外預測價值。

分析方法方面，未來可將影像方向、模型、特徵排序、特徵數選擇及後續校準與集成程序更完整地納入巢狀交叉驗證架構，並配合獨立資料進行最終評估，以降低前期資料驅動選擇對效能估計的影響。在研究設計上，取得縱向追蹤資料後，亦可將目前的橫斷式認知狀態分類延伸至認知功能變化、MCI 轉換風險與疾病進程預測，進一步探討影像特徵在不同疾病階段中的預測角色。另一方面，完整臨床資訊的取得通常涉及量表施測、病史整理與專業評估等程序，因此未來亦可評估結構影像量化資訊作為初步風險評估或第一階段分流工具的可行性，再搭配後續較完整的臨床評估進行確認。進一步將資料取得時間、人力需求與成本效益等實務因素納入考量，亦有助於更完整評估結構影像資訊在認知退化風險辨識與臨床決策輔助中的應用潛力。

參考文獻

- [1] B. Fischl, “FreeSurfer,” *NeuroImage*, vol. 62, no. 2, pp. 774–781, 2012. doi: 10.1016/j.neuroimage.2012.01.021.
- [2] G. M. McKhann, D. S. Knopman, H. Chertkow, B. T. Hyman, C. R. Jack, C. H. Kawas, W. E. Klunk, W. J. Koroshetz, J. J. Manly, R. Mayeux, R. C. Mohs, J. C. Morris, M. N. Rossor, P. Scheltens, M. C. Carrillo, B. Thies, S. Weintraub, and C. H. Phelps, “The diagnosis of dementia due to Alzheimer’s disease: Recommendations from the National Institute on Aging–Alzheimer’s Association workgroups on diagnostic guidelines for Alzheimer’s disease,” *Alzheimer’s & Dementia*, vol. 7, no. 3, pp. 263–269, 2011. doi: 10.1016/j.jalz.2011.03.005.
- [3] M. S. Albert, S. T. DeKosky, D. Dickson, B. Dubois, H. H. Feldman, N. C. Fox, A. Gamst, D. M. Holtzman, W. J. Jagust, R. C. Petersen, P. J. Snyder, M. C. Carrillo, B. Thies, and C. H. Phelps, “The diagnosis of mild cognitive impairment due to Alzheimer’s disease: Recommendations from the National Institute on Aging–Alzheimer’s Association workgroups on diagnostic guidelines for Alzheimer’s disease,” *Alzheimer’s & Dementia*, vol. 7, no. 3, pp. 270–279, 2011. doi: 10.1016/j.jalz.2011.03.008.
- [4] M. F. Folstein, S. E. Folstein, and P. R. McHugh, ““Mini-Mental State”: A practical method for grading the cognitive state of patients for the clinician,” *Journal of Psychiatric Research*, vol. 12, no. 3, pp. 189–198, 1975. doi: 10.1016/0022-3956(75)90026-6.
- [5] E. L. Teng, K. Hasegawa, A. Homma, Y. Imai, E. Larson, A. Graves, K. Sugimoto, T. Yamaguchi, H. Sasaki, D. Chiu, and L. R. White, “The cognitive abilities screening instrument (CASI): A practical test for cross-cultural epidemiological studies

- of dementia,” *International Psychogeriatrics*, vol. 6, no. 1, pp. 45–58, 1994. doi: 10.1017/S1041610294001602.
- [6] J. C. Morris, “Clinical dementia rating: A reliable and valid diagnostic and staging measure for dementia of the alzheimer type,” *International Psychogeriatrics*, vol. 9, no. S1, pp. 173–176, 1997. doi: 10.1017/S1041610297004870.
- [7] R. Cuingnet, E. Gerardin, J. Tessieras, G. Auzias, S. Lehericy, M.-O. Habert, M. Chupin, H. Benali, O. Colliot, and Alzheimer’s Disease Neuroimaging Initiative, “Automatic classification of patients with Alzheimer’s disease from structural MRI: A comparison of ten methods using the ADNI database,” *NeuroImage*, vol. 56, no. 2, pp. 766–781, 2011. doi: 10.1016/j.neuroimage.2010.06.013.
- [8] J. Samper-Gonzalez, N. Burgos, S. Bottani, S. Fontanella, P. Lu, A. Marcoux, A. Routier, J. Guillon, M. Bacci, J. Wen, A. Bertrand, H. Bertin, M.-O. Habert, S. Durrleman, T. Evgeniou, and O. Colliot, “Reproducible evaluation of classification methods in Alzheimer’s disease: Framework and application to MRI and PET data,” *NeuroImage*, vol. 183, pp. 504–521, 2018. doi: 10.1016/j.neuroimage.2018.08.042.
- [9] R. S. Desikan, F. Segonne, B. Fischl, B. T. Quinn, B. C. Dickerson, D. Blacker, R. L. Buckner, A. M. Dale, R. P. Maguire, B. T. Hyman, M. S. Albert, and R. J. Killiany, “An automated labeling system for subdividing the human cerebral cortex on MRI scans into gyral-based regions of interest,” *NeuroImage*, vol. 31, no. 3, pp. 968–980, 2006. doi: 10.1016/j.neuroimage.2006.01.021.
- [10] S. P. Poulin, R. Dautoff, J. C. Morris, L. F. Barrett, and B. C. Dickerson, “Amygdala atrophy is prominent in early Alzheimer’s disease and relates to symptom severity,”

- Psychiatry Research: Neuroimaging*, vol. 194, no. 1, pp. 7–13, 2011. doi: 10.1016/j.pscychresns.2011.06.014.
- [11] J. E. Iglesias, J. C. Augustinack, K. Nguyen, C. M. Player, A. Player, M. Wright, N. Roy, M. P. Frosch, A. C. McKee, L. L. Wald, B. Fischl, and K. Van Leemput, “A computational atlas of the hippocampal formation using ex vivo, ultra-high resolution MRI: Application to adaptive segmentation of in vivo MRI,” *NeuroImage*, vol. 115, pp. 117–137, 2015. doi: 10.1016/j.neuroimage.2015.04.042.
- [12] Z. M. Saygin, D. Kliemann, J. E. Iglesias, A. J. W. van der Kouwe, E. Boyd, M. Reuter, A. Stevens, K. Van Leemput, A. McKee, M. P. Frosch, B. Fischl, and J. C. Augustinack, “High-resolution magnetic resonance imaging reveals nuclei of the human amygdala: Manual segmentation to automatic atlas,” *NeuroImage*, vol. 155, pp. 370–382, 2017. doi: 10.1016/j.neuroimage.2017.04.046.
- [13] O. Voevodskaya, A. Simmons, R. Nordenskjold, J. Kullberg, H. Ahlstrom, L. Lind, L.-O. Wahlund, E.-M. Larsson, E. Westman, and Alzheimer’s Disease Neuroimaging Initiative, “The effects of intracranial volume adjustment approaches on multiple regional MRI volumes in healthy aging and Alzheimer’s disease,” *Frontiers in Aging Neuroscience*, vol. 6, p. 264, 2014. doi: 10.3389/fnagi.2014.00264.
- [14] S.-C. Huang, A. Pareek, S. Seyyedi, I. Banerjee, and M. P. Lungren, “Fusion of medical imaging and electronic health records using deep learning: A systematic review and implementation guidelines,” *npj Digital Medicine*, vol. 3, p. 136, 2020. doi: 10.1038/s41746-020-00341-z.
- [15] N. Hollmann, S. Müller, K. Eggenberger, and F. Hutter, “TabPFN: A transformer that solves small tabular classification problems in a second,” *arXiv preprint arXiv:2207.01848*, 2022. doi: 10.48550/arXiv.2207.01848.

- [16] A. Niculescu-Mizil and R. Caruana, “Predicting good probabilities with supervised learning,” in *Proceedings of the 22nd International Conference on Machine Learning*, pp. 625–632, 2005. doi: 10.1145/1102351.1102430.
- [17] W. J. Youden, “Index for rating diagnostic tests,” *Cancer*, vol. 3, no. 1, pp. 32–35, 1950. doi: 10.1002/1097-0142(1950)3:1<32::AID-CNCR2820030106>3.0.CO;2-3.
- [18] M. D. Ruopp, N. J. Perkins, B. W. Whitcomb, and E. F. Schisterman, “Youden Index and optimal cut-point estimated from observations affected by a lower limit of detection,” *Biometrical Journal*, vol. 50, no. 3, pp. 419–430, 2008. doi: 10.1002/bimj.200710415.
- [19] T. G. Dietterich, “Ensemble methods in machine learning,” in *Multiple Classifier Systems*, vol. 1857 of *Lecture Notes in Computer Science*, pp. 1–15, Springer, 2000. doi: 10.1007/3-540-45014-9_1.
- [20] M. J. van der Laan, E. C. Polley, and A. E. Hubbard, “Super learner,” *Statistical Applications in Genetics and Molecular Biology*, vol. 6, no. 1, p. Article 25, 2007. doi: 10.2202/1544-6115.1309.
- [21] T. Baltrusaitis, C. Ahuja, and L.-P. Morency, “Multimodal machine learning: A survey and taxonomy,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 41, no. 2, pp. 423–443, 2019. doi: 10.1109/TPAMI.2018.2798607.
- [22] H. Zou and T. Hastie, “Regularization and variable selection via the elastic net,” *Journal of the Royal Statistical Society: Series B*, vol. 67, no. 2, pp. 301–320, 2005. doi: 10.1111/j.1467-9868.2005.00503.x.
- [23] Y. Benjamini and Y. Hochberg, “Controlling the false discovery rate: A practical

and powerful approach to multiple testing,” *Journal of the Royal Statistical Society: Series B*, vol. 57, no. 1, pp. 289–300, 1995. doi: 10.1111/j.2517-6161.1995.tb02031.x.

- [24] J. C. Platt, “Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods.” Unpublished manuscript, March 26, 1999. Available: https://www.researchgate.net/publication/2594015_Probabilistic_Outputs_for_Support_Vector_Machines_and_Comparisons_to-Regularized_Likelihood_Methods, 1999.
- [25] B. Zadrozny and C. Elkan, “Transforming classifier scores into accurate multiclass probability estimates,” in *Proceedings of the Eighth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 694–699, 2002. doi: 10.1145/775047.775151.
- [26] D. H. Wolpert, “Stacked generalization,” *Neural Networks*, vol. 5, no. 2, pp. 241–259, 1992. doi: 10.1016/S0893-6080(05)80023-1.

附錄

A 人體研究倫理審查資訊

本附錄彙整各資料組別所屬研究計畫之 IRB 編號、計畫主持人、首次核准日期與正式計畫名稱，如表 A.1 所示。

表 A.1 各資料組別之人體研究倫理審查資訊

資料組別	IRB / 收件編號	計畫主持人	首次核准日期	正式計畫名稱
A 組	17-CT1-12 (161216-1)	林育德主任	2017 年 1 月 23 日	全人照護介入措施對於不同認知功能問題長者健康狀態影響的追蹤世代研究—建立門診不同程度認知功能患者周全性健康狀態追蹤研究
C、D 組	19-CT3-17 (190130-1)	梁志光科主任	2019 年 3 月 20 日	高齡長者之全人評估與照護介入和影像相關性分析
F 組	21-CT2-15 (201211-1)	林育德主任	2021 年 3 月 16 日	探討高齡者認知心理衰退及身體衰弱與醫療影像及血液生物標記之臨床相關性
H 組	22-CT1-11 (211215-1)	徐盈欣醫師	2022 年 2 月 10 日	非侵入式生物特徵早期失智偵測

B 詳細臨床資料欄位

表 B.1 原始臨床資料欄位一覽（共 35 欄）

類別	欄位名稱	說明	編碼／備註
人口學	age_at_bl	收案時年齡	數值（年）
	sex	性別	0：男性；1：女性
	EduYear	教育年數	數值（年）
	Marriage	婚姻狀態	0：未婚；1：已婚； 2：同居；3：分居； 4：離婚；5：其他
	APOE	APOE 基因型	E2E2、E2E3、E2E4、 E3E3、E3E4、E4E4； 部分資料缺失
生活型態	Smoke	吸菸習慣	0：未吸菸；1：曾吸菸； 2：目前吸菸
	Alcohol	飲酒習慣	0：未飲酒；1：曾飲酒； 2：目前飲酒
	VisualImp	視覺障礙	0：無；1：有
	HearImp	聽覺障礙	0：無；1：有
身體功能	Height	身高（公分）	數值
	Bodyweight	體重（公斤）	數值
	BMI	身體質量指數	數值
	Gaitspeed	步行速度	數值
	HGmax	最大握力	數值

續下頁

表 B.1 原始臨床資料欄位一覽（續）

類別	欄位名稱	說明	編碼／備註
	ASMI	四肢肌肉質量指數	數值
	CCI	Charlson 共病指數	數值（量表分數）
	Polypharmacy01	多重用藥	0：無；1：有
	Drugkinds	用藥種類數	數值
	Antipsychotics	抗精神病藥物使用	0：無；1：有
	GDS	老人憂鬱量表	數值（量表分數）
	BarthelIndexScores	巴氏量表	數值（量表分數）
	MNA_SF	簡易營養評估	數值（量表分數）
認知量表	MMSE	簡易心智量表	數值（量表分數）
	CASILTM	CASI 長期記憶	數值（量表分數）
	CASISTM	CASI 短期記憶	數值（量表分數）
	CASIATTEN	CASI 注意力	數值（量表分數）
	CASIMENMA	CASI 心智操作	數值（量表分數）
	CASIORIEN	CASI 定向感	數值（量表分數）
	CASIABSTR	CASI 抽象思考	數值（量表分數）
	CASILANG	CASI 語言能力	數值（量表分數）
	CASIDRAW	CASI 繪圖	數值（量表分數）
	CASIANML	CASI 動物流暢度	數值（量表分數）
	CASItotalscores	CASI 總分	數值（量表分數）
不納入分析	date_bl	收案日期	不納入（未作為預測變數）
	CDR score	臨床失智評估量表	不納入（可能造成標籤洩漏）

註：折內前處理建立 APOE_was_missing 缺失指示變項，前處理輸出包含 33 個原始臨床特徵及 1 個缺失指示變項。該變項僅保留於多模型 Baseline、ANOVA 特徵排序與 Top-*N* 掃描；正式 Phase 1 特徵清單排除，亦不納入後續 Phase 與影像增量分析。正式臨床特徵集合為 33 個臨床特徵。

C 3D T1 DICOM 序列資訊

表 C.1 進一步彙整受試者 C001 之 3D T1 資料夾內全部 DICOM 影像序列的主要檔頭資訊。該資料夾共包含 5 個影像序列與 847 個可讀取的 DICOM 檔案。其中，SER00001 之 ImageType 標示為 ORIGINAL 與 PRIMARY；SER00002 至 SER00005 則標示為 DERIVED 與 SECONDARY，屬於不同方向之衍生重組影像。

表 C.1 受試者 C001 之 3D T1 DICOM 序列主要資訊

目錄	序列描述	序列類型	數量	影像矩陣	切片厚度
SER00001	O-SAG T1 MPRAGE 1mm	ORIGINAL PRIMARY	160	256 × 240	1 mm
SER00002	AXI T1 MPRAGE 1mm	DERIVED SECONDARY	161	256 × 256	1 mm
SER00003	COR T1 MPRAGE 1mm	DERIVED SECONDARY	164	256 × 256	1 mm
SER00004	BRAIN MPRAGE AXI .9/.9	DERIVED SECONDARY	181	256 × 256	1 mm
SER00005	BRAIN MPRAGE COR .9/.9	DERIVED SECONDARY	181	256 × 256	1 mm

註：序列性質依 DICOM 檔頭之 ImageType 欄位判定；各序列之像素間距皆為 1 × 1 mm。本表呈現受試者 C001 的影像序列資訊。

D FreeSurfer 軟體資訊

表 D.1 FreeSurfer 軟體與執行資訊

項目	本研究設定
軟體名稱	FreeSurfer
軟體版本	7.4.1
執行環境	Ubuntu 22.04.5 LTS
主要處理程序	recon-all -all
延伸分區程序	segmentHA_T1.sh
官方網站	https://surfer.nmr.mgh.harvard.edu/fswiki
網站存取日期	2026 年 7 月 22 日

E 影像方向篩選完整結果

表 E.1 任務一 (Dementia vs. NonDementia) 之三輪 FreeSurfer 影像方向篩選完整結果

輪次	排名	影像方向	特徵數	BalAcc	AUC
R1	1	APARC	208	0.675 ± 0.047	0.760 ± 0.047
	2	HIPPO	44	0.674 ± 0.048	0.724 ± 0.061
	3	ASEG	46	0.672 ± 0.071	0.730 ± 0.069
	4	DKT	193	0.669 ± 0.060	0.746 ± 0.054
	5	AMYG	20	0.656 ± 0.070	0.726 ± 0.058
	6	A2009S	448	0.655 ± 0.060	0.745 ± 0.061
	7	BRAINVOL	16	0.653 ± 0.081	0.714 ± 0.080
	8	WMPARC	70	0.643 ± 0.057	0.674 ± 0.068
	9	BA_THRESH	86	0.641 ± 0.072	0.694 ± 0.082
R2	1	APARC_ASEG_HIPPO	298	0.690 ± 0.041	0.770 ± 0.050
	2	APARC_ASEG	254	0.689 ± 0.047	0.765 ± 0.044
	3	BRAINVOL_APARC_ASEG	270	0.687 ± 0.049	0.761 ± 0.052
	4	APARC_HIPPO	252	0.680 ± 0.052	0.754 ± 0.054
	5	BRAINVOL_APARC	224	0.679 ± 0.040	0.758 ± 0.047
	6	ASEG_HIPPO_AMYG	110	0.676 ± 0.073	0.735 ± 0.070
	7	HIPPO_AMYG	64	0.673 ± 0.056	0.717 ± 0.058
	8	HIPPO_ASEG	90	0.673 ± 0.070	0.731 ± 0.071
	9	BRAINVOL_ASEG_HIPPO_AMYG	126	0.664 ± 0.067	0.740 ± 0.070
R3	10	BRAINVOL_HIPPO_ASEG	106	0.659 ± 0.067	0.735 ± 0.068
	1	APARC_ASEG_AMYG	274	0.704 ± 0.040	0.774 ± 0.041
	2	DKT_ASEG_AMYG	259	0.699 ± 0.044	0.766 ± 0.052
	3	APARC_ASEG_WMPARC	324	0.697 ± 0.056	0.764 ± 0.051
	4	BRAINVOL_APARC_ASEG_WMPARC	340	0.697 ± 0.056	0.764 ± 0.051
	5	DKT_ASEG	239	0.696 ± 0.053	0.767 ± 0.054
	6	BRAINVOL_APARC_ASEG_AMYG	290	0.695 ± 0.041	0.773 ± 0.040
	7	BRAINVOL_APARC_ASEG_HIPPO	314	0.692 ± 0.041	0.770 ± 0.050
	8	BRAINVOL_ASEG_WMPARC	132	0.689 ± 0.067	0.735 ± 0.061
	9	BA_ASEG_HIPPO	176	0.683 ± 0.058	0.743 ± 0.061
	10	DKT_ASEG_HIPPO	283	0.683 ± 0.044	0.760 ± 0.047
	11	BRAINVOL_DKT_ASEG_HIPPO_AMYG	319	0.683 ± 0.051	0.763 ± 0.046
	12	WMPARC_ASEG	116	0.682 ± 0.062	0.738 ± 0.053
	13	BRAINVOL_ASEG_AMYG	82	0.681 ± 0.071	0.741 ± 0.050
	14	BA_ASEG	132	0.681 ± 0.056	0.737 ± 0.060
	15	A2009S_ASEG	494	0.678 ± 0.058	0.748 ± 0.055
	16	BRAINVOL_APARC_ASEG_HIPPO_AMYG	334	0.678 ± 0.041	0.763 ± 0.048
	17	BRAINVOL_DKT_ASEG_HIPPO	299	0.678 ± 0.044	0.758 ± 0.049
	18	DKT_HIPPO	237	0.678 ± 0.068	0.751 ± 0.059
	19	BRAINVOL_AMYG	36	0.677 ± 0.069	0.743 ± 0.075
	20	HIPPO_ASEG_WMPARC	160	0.677 ± 0.060	0.746 ± 0.064
	21	AMYG_ASEG	66	0.675 ± 0.058	0.723 ± 0.055
	22	BA_ASEG_AMYG	152	0.671 ± 0.056	0.725 ± 0.056
	23	BRAINVOL_HIPPO_ASEG_WMPARC	176	0.670 ± 0.054	0.744 ± 0.065
	24	BA_HIPPO	130	0.669 ± 0.059	0.733 ± 0.062
	25	BRAINVOL_HIPPO_AMYG	80	0.667 ± 0.063	0.732 ± 0.061
	26	BRAINVOL_WMPARC	86	0.666 ± 0.068	0.702 ± 0.082
	27	A2009S_HIPPO	492	0.666 ± 0.058	0.748 ± 0.065
	28	A2009S_ASEG_HIPPO	538	0.665 ± 0.063	0.750 ± 0.058
	29	BRAINVOL_ASEG	62	0.663 ± 0.065	0.733 ± 0.057
	30	BRAINVOL_HIPPO	60	0.655 ± 0.055	0.731 ± 0.067

表 E.2 任務二 (AbNormal vs. Normal) 之三輪 FreeSurfer 影像方向篩選完整結果

輪次	排名	影像方向	特徵數	BalAcc	AUC
R1	1	HIPPO	44	0.707 ± 0.077	0.764 ± 0.067
	2	AMYG	20	0.693 ± 0.057	0.751 ± 0.062
	3	ASEG	46	0.686 ± 0.063	0.763 ± 0.064
	4	BRAINVOL	16	0.679 ± 0.054	0.719 ± 0.068
	5	DKT	193	0.670 ± 0.075	0.712 ± 0.062
	6	APARC	208	0.629 ± 0.065	0.699 ± 0.069
	7	A2009S	448	0.627 ± 0.061	0.695 ± 0.060
	8	BA_THRESH	86	0.592 ± 0.060	0.631 ± 0.063
	9	WMPARC	70	0.573 ± 0.068	0.635 ± 0.081
R2	1	HIPPO_ASEG	90	0.716 ± 0.058	0.783 ± 0.058
	2	BRAINVOL_ASEG_HIPPO_AMYG	126	0.716 ± 0.071	0.777 ± 0.066
	3	BRAINVOL_HIPPO_ASEG	106	0.711 ± 0.066	0.781 ± 0.059
	4	APARC_ASEG_HIPPO	298	0.709 ± 0.067	0.773 ± 0.064
	5	ASEG_HIPPO_AMYG	110	0.707 ± 0.063	0.775 ± 0.060
	6	APARC_ASEG	254	0.704 ± 0.068	0.762 ± 0.060
	7	BRAINVOL_APARC_ASEG	270	0.704 ± 0.067	0.760 ± 0.061
	8	APARC_HIPPO	252	0.698 ± 0.080	0.754 ± 0.066
	9	HIPPO_AMYG	64	0.697 ± 0.080	0.763 ± 0.069
R3	10	BRAINVOL_APARC	224	0.649 ± 0.063	0.701 ± 0.064
	1	BRAINVOL_HIPPO_ASEG_WMPARC	176	0.728 ± 0.072	0.777 ± 0.063
	2	HIPPO_ASEG_WMPARC	160	0.726 ± 0.073	0.777 ± 0.064
	3	DKT_ASEG_HIPPO	283	0.722 ± 0.063	0.776 ± 0.059
	4	BRAINVOL_DKT_ASEG_HIPPO	299	0.721 ± 0.066	0.777 ± 0.060
	5	BRAINVOL_DKT_ASEG_HIPPO_AMYG	319	0.717 ± 0.062	0.777 ± 0.057
	6	DKT_ASEG	239	0.715 ± 0.059	0.771 ± 0.057
	7	BRAINVOL_HIPPO	60	0.715 ± 0.077	0.763 ± 0.069
	8	AMYG_ASEG	66	0.710 ± 0.074	0.772 ± 0.072
	9	BRAINVOL_APARC_ASEG_HIPPO	314	0.709 ± 0.067	0.770 ± 0.063
	10	BA_ASEG_HIPPO	176	0.707 ± 0.068	0.773 ± 0.067
	11	DKT_ASEG_AMYG	259	0.707 ± 0.045	0.772 ± 0.057
	12	BRAINVOL_APARC_ASEG_HIPPO_AMYG	334	0.703 ± 0.064	0.764 ± 0.064
	13	BA_HIPPO	130	0.701 ± 0.077	0.755 ± 0.067
	14	APARC_ASEG_WMPARC	324	0.700 ± 0.062	0.763 ± 0.062
	15	BRAINVOL_HIPPO_AMYG	80	0.699 ± 0.078	0.761 ± 0.076
	16	BRAINVOL_ASEG_AMYG	82	0.698 ± 0.077	0.774 ± 0.065
	17	APARC_ASEG_AMYG	274	0.696 ± 0.062	0.757 ± 0.066
	18	A2009S_ASEG_HIPPO	538	0.695 ± 0.078	0.756 ± 0.069
	19	BA_ASEG_AMYG	152	0.695 ± 0.062	0.769 ± 0.058
	20	BRAINVOL_APARC_ASEG_WMPARC	340	0.694 ± 0.071	0.764 ± 0.060
	21	BA_ASEG	132	0.692 ± 0.055	0.763 ± 0.064
	22	WMPARC_ASEG	116	0.692 ± 0.072	0.771 ± 0.066
	23	BRAINVOL_ASEG	62	0.691 ± 0.053	0.763 ± 0.057
	24	DKT_HIPPO	237	0.691 ± 0.059	0.750 ± 0.056
	25	BRAINVOL_APARC_ASEG_AMYG	290	0.691 ± 0.066	0.757 ± 0.066
	26	BRAINVOL_ASEG_WMPARC	132	0.689 ± 0.068	0.765 ± 0.063
	27	BRAINVOL_AMYG	36	0.688 ± 0.061	0.751 ± 0.061
	28	A2009S_HIPPO	492	0.684 ± 0.072	0.754 ± 0.065
	29	A2009S_ASEG	494	0.676 ± 0.064	0.738 ± 0.057
	30	BRAINVOL_WMPARC	86	0.647 ± 0.068	0.704 ± 0.071

表 E.3 任務三 (MCI vs. Normal) 之三輪 FreeSurfer 影像方向篩選完整結果

輪次	排名	影像方向	特徵數	BalAcc	AUC
R1	1	HIPPO	44	0.688 ± 0.070	0.728 ± 0.063
	2	ASEG	46	0.670 ± 0.079	0.748 ± 0.070
	3	BRAINVOL	16	0.662 ± 0.068	0.696 ± 0.078
	4	AMYG	20	0.641 ± 0.086	0.703 ± 0.069
	5	DKT	193	0.606 ± 0.064	0.639 ± 0.072
	6	A2009S	448	0.595 ± 0.068	0.618 ± 0.071
	7	APARC	208	0.593 ± 0.059	0.632 ± 0.081
	8	BA_THRESH	86	0.563 ± 0.072	0.584 ± 0.083
	9	WMPARC	70	0.529 ± 0.068	0.567 ± 0.101
R2	1	BRAINVOL_HIPPO_ASEG	106	0.690 ± 0.073	0.754 ± 0.067
	2	BRAINVOL_ASEG_HIPPO_AMYG	126	0.687 ± 0.059	0.746 ± 0.066
	3	HIPPO_ASEG	90	0.686 ± 0.077	0.750 ± 0.062
	4	ASEG_HIPPO_AMYG	110	0.682 ± 0.063	0.744 ± 0.063
	5	APARC_ASEG_HIPPO	298	0.677 ± 0.076	0.726 ± 0.074
	6	APARC_ASEG	254	0.664 ± 0.083	0.711 ± 0.072
	7	APARC_HIPPO	252	0.660 ± 0.077	0.701 ± 0.080
	8	HIPPO_AMYG	64	0.660 ± 0.080	0.709 ± 0.074
	9	BRAINVOL_APARC_ASEG	270	0.658 ± 0.078	0.709 ± 0.063
R3	10	BRAINVOL_APARC	224	0.622 ± 0.061	0.651 ± 0.074
	1	BRAINVOL_HIPPO_ASEG_WMPARC	176	0.692 ± 0.073	0.742 ± 0.064
	2	HIPPO_ASEG_WMPARC	160	0.691 ± 0.073	0.745 ± 0.064
	3	BRAINVOL_HIPPO	60	0.687 ± 0.068	0.728 ± 0.068
	4	BRAINVOL_APARC_ASEG_WMPARC	340	0.684 ± 0.087	0.730 ± 0.078
	5	BRAINVOL_DKT_ASEG_HIPPO_AMYG	319	0.683 ± 0.076	0.734 ± 0.077
	6	BRAINVOL_APARC_ASEG_HIPPO	314	0.683 ± 0.078	0.730 ± 0.075
	7	A2009S_ASEG_HIPPO	538	0.683 ± 0.077	0.715 ± 0.077
	8	BA_ASEG_HIPPO	176	0.682 ± 0.077	0.725 ± 0.071
	9	BRAINVOL_HIPPO_AMYG	80	0.682 ± 0.072	0.726 ± 0.074
	10	APARC_ASEG_WMPARC	324	0.681 ± 0.090	0.730 ± 0.078
	11	BRAINVOL_ASEG	62	0.679 ± 0.082	0.746 ± 0.072
	12	BRAINVOL_DKT_ASEG_HIPPO	299	0.679 ± 0.075	0.733 ± 0.074
	13	DKT_ASEG_HIPPO	283	0.679 ± 0.075	0.732 ± 0.075
	14	DKT_ASEG	239	0.674 ± 0.056	0.729 ± 0.065
	15	APARC_ASEG_AMYG	274	0.673 ± 0.057	0.724 ± 0.062
	16	BRAINVOL_APARC_ASEG_HIPPO_AMYG	334	0.672 ± 0.077	0.726 ± 0.074
	17	WMPARC_ASEG	116	0.672 ± 0.080	0.724 ± 0.069
	18	AMYG_ASEG	66	0.671 ± 0.079	0.741 ± 0.076
	19	DKT_ASEG_AMYG	259	0.671 ± 0.060	0.730 ± 0.061
	20	BA_ASEG_AMYG	152	0.670 ± 0.081	0.726 ± 0.068
	21	BRAINVOL_ASEG_AMYG	82	0.668 ± 0.077	0.737 ± 0.069
	22	BRAINVOL_APARC_ASEG_AMYG	290	0.667 ± 0.059	0.719 ± 0.063
	23	BA_ASEG	132	0.664 ± 0.085	0.726 ± 0.072
	24	BRAINVOL_ASEG_WMPARC	132	0.663 ± 0.079	0.712 ± 0.071
	25	BA_HIPPO	130	0.658 ± 0.068	0.705 ± 0.071
	26	BRAINVOL_AMYG	36	0.657 ± 0.071	0.715 ± 0.073
	27	A2009S_HIPPO	492	0.655 ± 0.073	0.704 ± 0.078
	28	A2009S_ASEG	494	0.645 ± 0.069	0.693 ± 0.073
	29	DKT_HIPPO	237	0.638 ± 0.068	0.693 ± 0.069
	30	BRAINVOL_WMPARC	86	0.616 ± 0.081	0.653 ± 0.078

註：R1、R2 與 R3 分別表示第一輪單一特徵群組、第二輪醫學意義組合與第三輪延伸組合。各表依同一輪內之平均 BalAcc 由高至低排序；數值為平均值 ± 標準差。

F eTIV 線性相關性檢定與校正

本節補充第 5.2 節之 eTIV 線性相關性檢定與校正結果，包括各 FreeSurfer 群組之顯著比例、代表性特徵，以及三項任務候選方向之校正前後比較。相關檢定方法與校正流程詳見第 4.5 節。

表 F.1 eTIV 線性相關性檢定之各群組顯著比例 (Normal 子群, BH-FDR)

群組	顯著數	檢定數	顯著比例 (%)
BRAINVOL (全腦體積摘要)	14	14	100.0
WMPARC (白質分區)	66	70	94.3
APARC (皮質分區)	57	68	83.8
ASEG (皮質下結構)	29	40	72.5
AMYG (杏仁核子核)	11	20	55.0
HIPPO (海馬亞區)	24	44	54.5
合計	201	256	78.5

如表 F.1 所示，256 個候選體積特徵中共有 201 個於 BH-FDR 校正後達顯著，其中 BRAINVOL、WMPARC 與 APARC 的顯著比例較高，顯示不同 FreeSurfer 體積特徵與 eTIV 的線性關聯程度並不相同。代表性特徵結果列於表 F.2。

表 F.2 eTIV 顯著性檢定之代表性特徵 (Normal 子群, $n = 60$)

類別	特徵	β	R^2	p_{FDR}
顯著 (前 6 名)	M_Mask_vol_brainvol	0.919	0.852	2.7×10^{-23}
	M_SupraTentorial_vol_brainvol	0.546	0.775	2.4×10^{-18}
	M_BrainSeg_vol_brainvol	0.592	0.767	4.5×10^{-18}
	M_SupraTentorialNotVent_vol_brainvol	0.491	0.668	1.0×10^{-13}
	M_BrainSegNotVent_vol_brainvol	0.537	0.664	1.2×10^{-13}
	M_TotalGray_vol_brainvol	0.255	0.601	1.4×10^{-11}
不顯著 (代表)	lh_subiculum_head_vol_hippo	~0	0.000	0.992
	C_rh_temporalpole_vol_aparc	~0	0.000	0.972
	C_rh parahippocampal_vol_aparc	~0	0.001	0.800
	C_CC_Mid_Anterior_vol_aseg	~0	0.001	0.795
	C_lh_pericalcarine_vol_aparc	~0	0.002	0.726

(β 為 $Y \sim \text{eTIV}$ 之回歸斜率；顯著性以 BH-FDR 於候選體積特徵上校正判定， $q < 0.05$ 為顯著。)

代表性結果顯示，與 eTIV 關聯較強的特徵主要來自全腦體積摘要；三項任務

各候選方向之校正前後分類表現進一步整理於表 F.3。

表 F.3 eTIV 校正前後之各候選方向分類表現 (ElasticNet Logistic Regression, 20 個隨機種子之平均值 $\pm$ 標準差)

任務	資料方向	校正特徵數	平衡準確率		AUC	
			No_Adj	Adj	No_Adj	Adj
任務一	APARC_ASEG_AMYG	97	0.820 $\pm$ 0.012	0.819 $\pm$ 0.014	0.915 $\pm$ 0.005	0.915 $\pm$ 0.006
	APARC_ASEG_HIPPO	110	0.822 $\pm$ 0.011	0.822 $\pm$ 0.010	0.915 $\pm$ 0.004	0.916 $\pm$ 0.005
	BRAINVOL_APARC_ASEG_HIPPO_AMYG	135	0.821 $\pm$ 0.010	0.820 $\pm$ 0.012	0.914 $\pm$ 0.006	0.915 $\pm$ 0.005
任務二	HIPPO_ASEG	53	0.822 $\pm$ 0.012	0.819 $\pm$ 0.016	0.919 $\pm$ 0.007	0.914 $\pm$ 0.007
	BRAINVOL_HIPPO_ASEG_WMPARC	133	0.814 $\pm$ 0.014	0.813 $\pm$ 0.016	0.914 $\pm$ 0.008	0.911 $\pm$ 0.008
	BRAINVOL_APARC_ASEG_HIPPO_AMYG	135	0.816 $\pm$ 0.011	0.814 $\pm$ 0.018	0.911 $\pm$ 0.010	0.906 $\pm$ 0.009
任務三	HIPPO	24	0.809 $\pm$ 0.010	0.805 $\pm$ 0.014	0.901 $\pm$ 0.008	0.899 $\pm$ 0.011
	BRAINVOL_HIPPO_ASEG	67	0.794 $\pm$ 0.021	0.789 $\pm$ 0.022	0.893 $\pm$ 0.010	0.891 $\pm$ 0.014
	BRAINVOL_APARC_ASEG_HIPPO_AMYG	135	0.786 $\pm$ 0.025	0.786 $\pm$ 0.021	0.880 $\pm$ 0.018	0.878 $\pm$ 0.012

表 F.3 顯示，三項任務共 9 個候選方向於 eTIV 校正後均未呈現一致的分類效能改善。任務一整體表現大致持平，任務二與任務三則多數方向於校正後略低於未校正版本。因此，主線分析採用未校正版本 (No_Adj) 作為主要設定。

G 主要方向特徵排序

本節補充正文四個主要方向之前 30 名特徵排序結果，如表 G.1 至表 G.4 所示。特徵排序以 ANOVA F-score 為依據，彙整 20 個隨機種子與 5 折交叉驗證共 100 個外層訓練折之結果，並以平均 F-score 決定最終排名。表中另列各特徵之 ANOVA p -value 中位數，作為單變量組間差異的描述性參考。類別變數經 one-hot encoding 後，於表中回推至原始變數層級呈現；其中 APOE 與 APOE_was_missing 分別表示基因型資訊與缺失指示變項。

表 G.1 任務一 APARC_ASEG_AMYG 方向之 Top-30 特徵排序

排名	特徵名稱	來源	平均 F-score	p -value 中位數
1	CASIORIEN	Clinical	203.379	7.96×10^{-36}
2	MMSE	Clinical	195.542	3.77×10^{-34}
3	CASItotalscores	Clinical	181.719	2.89×10^{-32}

續下頁

排名	特徵名稱	來源	平均 F-score	<i>p</i> -value 中位數
4	CASISTM	Clinical	99.061	3.71×10^{-20}
5	CASIMENMA	Clinical	60.538	1.57×10^{-13}
6	CASILANG	Clinical	57.390	5.64×10^{-13}
7	CASIANML	Clinical	51.600	5.91×10^{-12}
8	CASIABSTR	Clinical	46.353	5.75×10^{-11}
9	CASILTM	Clinical	43.448	3.37×10^{-10}
10	C_lh_precuneus_vol_aparc	aparc	43.110	3.01×10^{-10}
11	C_Left_Hippocampus_vol_aseg	aseg	39.304	1.61×10^{-9}
12	C_lh_middletemporal_vol_aparc	aparc	38.297	2.76×10^{-9}
13	C_lh_inferiortemporal_vol_aparc	aparc	34.857	1.57×10^{-8}
14	lh_Accessory_Basal_nucleus_vol_amyg	amyg	32.400	3.27×10^{-8}
15	lh_Corticoamygdaloid_transitio_vol_amyg	amyg	32.263	2.88×10^{-8}
16	rh_Central_nucleus_vol_amyg	amyg	31.563	5.28×10^{-8}
17	lh_Whole_amygdala_vol_amyg	amyg	31.465	4.48×10^{-8}
18	C_rh_middletemporal_vol_aparc	aparc	30.803	7.72×10^{-8}
19	rh_Accessory_Basal_nucleus_vol_amyg	amyg	30.103	1.55×10^{-7}
20	lh_Basal_nucleus_vol_amyg	amyg	29.590	1.27×10^{-7}
21	rh_Cortical_nucleus_vol_amyg	amyg	28.958	2.72×10^{-7}
22	C_rh_precuneus_vol_aparc	aparc	28.804	1.61×10^{-7}
23	C_lh_precuneus_surf_aparc	aparc	26.905	4.01×10^{-7}
24	CASIDRAW	Clinical	26.804	4.57×10^{-7}
25	rh_Corticoamygdaloid_transitio_vol_amyg	amyg	26.676	5.80×10^{-7}
26	lh_Paralaminar_nucleus_vol_amyg	amyg	26.527	4.74×10^{-7}
27	CASIATTEN	Clinical	26.135	6.21×10^{-7}
28	lh_Lateral_nucleus_vol_amyg	amyg	25.924	7.19×10^{-7}
29	C_Left_Amygdala_vol_aseg	aseg	25.912	7.25×10^{-7}
30	C_rh_inferiorparietal_vol_aparc	aparc	25.897	7.54×10^{-7}

表 G.2 任務一 APARC_ASEG_HIPPO 方向之 Top-30 特徵排序

排名	特徵名稱	來源	平均 F-score	<i>p</i> -value 中位數
1	CASIORIEN	Clinical	203.379	7.96×10^{-36}
2	MMSE	Clinical	195.542	3.77×10^{-34}
3	CASItotalscores	Clinical	181.719	2.89×10^{-32}
4	CASISTM	Clinical	99.061	3.71×10^{-20}
5	CASIMENMA	Clinical	60.538	1.57×10^{-13}
6	CASILANG	Clinical	57.390	5.64×10^{-13}
7	CASIANML	Clinical	51.600	5.91×10^{-12}
8	CASIABSTR	Clinical	46.353	5.75×10^{-11}
9	CASILTM	Clinical	43.448	3.37×10^{-10}
10	C_lh_precuneus_vol_aparc	aparc	43.110	3.01×10^{-10}
11	lh_molecular_layer_HP_head_vol_hippo	hippo	40.986	7.77×10^{-10}
12	lh_GC_ML_DG_body_vol_hippo	hippo	40.928	6.86×10^{-10}

續下頁

排名	特徵名稱	來源	平均 F-score	<i>p</i> -value 中位數
13	lh_CA4_body_vol_hippo	hippo	40.228	7.33×10^{-10}
14	lh_Whole_hippocampus_vol_hippo	hippo	39.436	1.15×10^{-9}
15	C_Left_Hippocampus_vol_aseg	aseg	39.304	1.61×10^{-9}
16	lh_Whole_hippocampal_head_vol_hippo	hippo	38.333	2.25×10^{-9}
17	C_lh_middletemporal_vol_aparc	aparc	38.297	2.76×10^{-9}
18	lh_Whole_hippocampal_body_vol_hippo	hippo	36.698	4.20×10^{-9}
19	lh_GC_ML_DG_head_vol_hippo	hippo	36.473	4.63×10^{-9}
20	lh_CA4_head_vol_hippo	hippo	34.902	1.19×10^{-8}
21	C_lh_inferiortemporal_vol_aparc	aparc	34.857	1.57×10^{-8}
22	rh_GC_ML_DG_body_vol_hippo	hippo	34.520	1.66×10^{-8}
23	lh_subiculum_body_vol_hippo	hippo	34.256	1.09×10^{-8}
24	lh_CA1_head_vol_hippo	hippo	33.648	2.21×10^{-8}
25	lh_presubiculum_head_vol_hippo	hippo	33.377	2.23×10^{-8}
26	rh_CA4_body_vol_hippo	hippo	33.216	3.23×10^{-8}
27	lh_subiculum_head_vol_hippo	hippo	32.865	3.74×10^{-8}
28	lh_CA3_head_vol_hippo	hippo	31.727	4.58×10^{-8}
29	C_rh_middletemporal_vol_aparc	aparc	30.803	7.72×10^{-8}
30	lh_molecular_layer_HP_body_vol_hippo	hippo	30.473	7.14×10^{-8}

表 G.3 任務二 HIPPO_ASEG 方向之 Top-30 特徵排序

排名	特徵名稱	來源	平均 F-score	<i>p</i> -value 中位數
1	CASItotalscores	Clinical	71.546	1.42×10^{-15}
2	MMSE	Clinical	66.272	1.23×10^{-14}
3	CASISTM	Clinical	63.233	3.57×10^{-14}
4	CASIORIEN	Clinical	46.685	5.29×10^{-11}
5	CASIABSTR	Clinical	44.681	1.12×10^{-10}
6	Gaitspeed	Clinical	39.335	1.59×10^{-9}
7	lh_Whole_hippocampal_body_vol_hippo	hippo	36.579	4.57×10^{-9}
8	lh_Whole_hippocampus_vol_hippo	hippo	36.150	6.88×10^{-9}
9	CASIANML	Clinical	34.667	1.18×10^{-8}
10	lh_GC_ML_DG_head_vol_hippo	hippo	34.490	1.69×10^{-8}
11	lh_molecular_layer_HP_head_vol_hippo	hippo	34.482	1.55×10^{-8}
12	lh_molecular_layer_HP_body_vol_hippo	hippo	34.264	1.57×10^{-8}
13	lh_Whole_hippocampal_head_vol_hippo	hippo	34.025	1.98×10^{-8}
14	lh_CA3_head_vol_hippo	hippo	33.345	2.92×10^{-8}
15	lh_subiculum_body_vol_hippo	hippo	31.621	6.13×10^{-8}
16	lh_CA4_head_vol_hippo	hippo	31.548	5.39×10^{-8}
17	CASIMENMA	Clinical	31.536	4.96×10^{-8}
18	lh_GC_ML_DG_body_vol_hippo	hippo	31.503	5.47×10^{-8}
19	APOE	Clinical	30.938	8.09×10^{-8}
20	APOE_was_missing	Clinical	30.938	8.09×10^{-8}
21	lh_presubiculum_head_vol_hippo	hippo	30.788	7.29×10^{-8}

續下頁

排名	特徵名稱	來源	平均 F-score	<i>p</i> -value 中位數
22	rh_GC_ML_DG_body_vol_hippo	hippo	30.734	1.03×10^{-7}
23	lh_subiculum_head_vol_hippo	hippo	30.571	7.96×10^{-8}
24	MNA_SF	Clinical	28.734	1.51×10^{-7}
25	rh_Whole_hippocampal_body_vol_hippo	hippo	28.399	3.22×10^{-7}
26	C_Left_Amygdala_vol_aseg	aseg	28.246	2.56×10^{-7}
27	C_Left_Hippocampus_vol_aseg	aseg	27.846	3.17×10^{-7}
28	lh_HATA_vol_hippo	hippo	27.575	3.63×10^{-7}
29	Drugkinds	Clinical	27.034	3.95×10^{-7}
30	rh_Whole_hippocampus_vol_hippo	hippo	26.728	6.39×10^{-7}

表 G.4 任務三 HIPPO 方向之 Top-30 特徵排序

排名	特徵名稱	來源	平均 F-score	<i>p</i> -value 中位數
1	CASItotalscores	Clinical	58.622	4.32×10^{-13}
2	MMSE	Clinical	50.562	1.27×10^{-11}
3	APOE	Clinical	46.463	9.30×10^{-11}
4	APOE_was_missing	Clinical	46.463	9.30×10^{-11}
5	CASISTM	Clinical	41.456	6.67×10^{-10}
6	Gaitspeed	Clinical	29.729	1.99×10^{-7}
7	CASIABSTR	Clinical	29.724	1.56×10^{-7}
8	CASIORIEN	Clinical	28.099	2.86×10^{-7}
9	lh_Whole_hippocampal_body_vol_hippo	hippo	25.572	6.92×10^{-7}
10	lh_Whole_hippocampus_vol_hippo	hippo	24.512	1.43×10^{-6}
11	MNA_SF	Clinical	24.390	2.05×10^{-6}
12	lh_molecular_layer_HP_body_vol_hippo	hippo	24.290	1.70×10^{-6}
13	lh_GC_ML_DG_head_vol_hippo	hippo	22.666	3.74×10^{-6}
14	Drugkinds	Clinical	22.475	4.67×10^{-6}
15	lh_molecular_layer_HP_head_vol_hippo	hippo	22.461	3.61×10^{-6}
16	lh_Whole_hippocampal_head_vol_hippo	hippo	22.101	4.86×10^{-6}
17	lh_subiculum_body_vol_hippo	hippo	21.627	4.84×10^{-6}
18	lh_CA3_head_vol_hippo	hippo	21.483	8.11×10^{-6}
19	CASIANML	Clinical	21.197	6.95×10^{-6}
20	lh_CA4_head_vol_hippo	hippo	20.743	8.68×10^{-6}
21	CASIMENMA	Clinical	20.361	1.04×10^{-5}
22	lh_subiculum_head_vol_hippo	hippo	20.138	1.45×10^{-5}
23	lh_GC_ML_DG_body_vol_hippo	hippo	19.992	9.60×10^{-6}
24	Marriage	Clinical	19.397	2.45×10^{-5}
25	lh_presubiculum_head_vol_hippo	hippo	19.135	1.98×10^{-5}
26	rh_GC_ML_DG_body_vol_hippo	hippo	19.049	1.95×10^{-5}
27	rh_Whole_hippocampal_body_vol_hippo	hippo	18.409	2.69×10^{-5}
28	lh_HATA_vol_hippo	hippo	17.373	6.70×10^{-5}
29	rh_Whole_hippocampus_vol_hippo	hippo	17.162	5.68×10^{-5}
30	rh_molecular_layer_HP_head_vol_hippo	hippo	17.152	5.93×10^{-5}

G.1 Top- N 特徵數掃描之 AUC 補充結果

正文以平衡準確率作為 Top- N 特徵數選擇之主要依據，本節補充四個主要方向於不同特徵數下的 AUC 變化，結果如圖 G.1 所示。




圖 G.1 四個主要方向於不同 Top- N 特徵數下之 AUC 表現。陰影表示 20 個隨機種子平均結果的 95% 信賴區間，空心標記表示各模型之最高 AUC。

AUC 結果顯示，任務一兩個方向之 ElasticNet Logistic Regression 與 RidgeClassifier 均於 Top-10 取得最高 AUC；任務二之最高 AUC 位於 Top-30 附近，任務三則於 Top-20 取得較高 AUC。整體而言，AUC 同樣未呈現隨特徵數增加而持續改善的趨勢。任務二與任務三之 AUC 結果與正文採用的 Top-30 與 Top-20 設定大致一致；任務一雖於較少特徵下具有較高 AUC，正式特徵數仍依正文預先設定的平衡準確率準則採用 Top-80。

H Phase 2 逐模型校準補充結果

正文表 5-13 呈現各任務與資料方向之模型平均校準結果。本附錄進一步整理 52 組「任務、資料方向與模型」設定之逐模型比較，其中任務一包含 24 組，任務二與任務三各包含 14 組。

表 H.1 Phase 2 各校準方法取得最低 Brier score 與 ECE 之次數

方法	Brier score 最低		ECE 最低	
	組數	比例	組數	比例
Raw	11	21.2%	0	0.0%
Platt scaling	38	73.1%	0	0.0%
Isotonic regression	3	5.8%	52	100.0%

表 H.2 Phase 2 校準方法相對 Raw 之逐模型改善情況

方法	Brier 改善組數	平均 Brier 改善量	ECE 改善組數	平均 ECE 改善量	平均 Δ AUC
Platt scaling	41/52 (78.8%)	0.0265	44/52 (84.6%)	0.0666	0.0000
Isotonic regression	41/52 (78.8%)	0.0243	52/52 (100.0%)	0.0824	-0.0109

註：改善量定義為 Raw 減去校準後結果，正值表示 Brier score 或 ECE 下降； Δ AUC 為校準後 AUC 減去 Raw AUC。

I 完整臨床基準下之影像增量補充

本節補充正文之完整臨床基準影像增量分析，呈現逐模型 AUC 比較、任務層級摘要，以及晚期融合權重與模型預測相關性之補充診斷。主要比較為 Clin33_FS_topK 相對於 Clin33，純影像方向 FS_topK 相對於 Clin33 則作為補充比較；相關分析設定與流程詳見正文。

表 I.1 Clin33_FS_topK 相對 Clin33 之逐模型 AUC 重複切分比較

任務	模型	Clin33 AUC	Clin33+FS AUC	Δ AUC	p	FDR q	重複切分判 準
任務一	ElasticNetLogistic	0.9192	0.9182	-0.0010	0.3683	0.3788	未達 $q < 0.05$
任務一	RidgeClassifier	0.9223	0.9204	-0.0020	0.0009	0.0012	負向且 $q < 0.05$
任務一	LogisticRegression	0.9204	0.9142	-0.0062	0.0001	0.0002	負向且 $q < 0.05$
任務一	LinearSVC	0.9176	0.9125	-0.0051	0.0005	0.0008	負向且 $q < 0.05$
任務一	XGBoost	0.9061	0.9026	-0.0035	0.1231	0.1385	未達 $q < 0.05$
任務一	LightGBM	0.9110	0.9047	-0.0062	0.0010	0.0014	負向且 $q < 0.05$
任務一	ExtraTrees	0.9227	0.9179	-0.0048	0.0012	0.0016	負向且 $q < 0.05$
任務一	kNN	0.9023	0.8924	-0.0099	< 0.0001	< 0.0001	負向且 $q < 0.05$
任務一	SVC_RBF	0.9166	0.9095	-0.0071	0.0020	0.0026	負向且 $q < 0.05$
任務一	GaussianNB	0.8434	0.8219	-0.0215	< 0.0001	< 0.0001	負向且 $q < 0.05$
任務一	CatBoost	0.9186	0.9201	+0.0015	0.2774	0.3026	未達 $q < 0.05$
任務一	TabPFN	0.9272	0.9291	+0.0019	0.0569	0.0683	未達 $q < 0.05$
任務二	ElasticNetLogistic	0.9289	0.9259	-0.0030	0.0023	0.0029	負向且 $q < 0.05$
任務二	RidgeClassifier	0.9277	0.9170	-0.0107	< 0.0001	< 0.0001	負向且 $q < 0.05$
任務二	LogisticRegression	0.9264	0.9179	-0.0086	< 0.0001	< 0.0001	負向且 $q < 0.05$
任務二	LinearSVC	0.9246	0.9130	-0.0116	< 0.0001	< 0.0001	負向且 $q < 0.05$
任務二	XGBoost	0.9118	0.9007	-0.0111	< 0.0001	< 0.0001	負向且 $q < 0.05$

續下頁

任務	模型	Clin33 AUC	Clin33+FS AUC	Δ AUC	p	FDR q	重複切分判 準
任務二	LightGBM	0.9122	0.9008	-0.0114	0.0001	0.0002	負向且 $q < 0.05$
任務二	ExtraTrees	0.9235	0.9115	-0.0120	< 0.0001	< 0.0001	負向且 $q < 0.05$
任務二	kNN	0.9256	0.8915	-0.0341	< 0.0001	< 0.0001	負向且 $q < 0.05$
任務二	SVC_RBF	0.9180	0.9079	-0.0101	0.0002	0.0003	負向且 $q < 0.05$
任務二	GaussianNB	0.8864	0.8609	-0.0255	< 0.0001	< 0.0001	負向且 $q < 0.05$
任務二	CatBoost	0.9162	0.9094	-0.0068	< 0.0001	< 0.0001	負向且 $q < 0.05$
任務二	TabPFN	0.9327	0.9264	-0.0063	< 0.0001	< 0.0001	負向且 $q < 0.05$
任務三	ElasticNetLogistic	0.9024	0.8929	-0.0095	0.0007	0.0011	負向且 $q < 0.05$
任務三	RidgeClassifier	0.9014	0.8780	-0.0234	< 0.0001	< 0.0001	負向且 $q < 0.05$
任務三	LogisticRegression	0.8985	0.8792	-0.0193	< 0.0001	< 0.0001	負向且 $q < 0.05$
任務三	LinearSVC	0.8978	0.8741	-0.0237	< 0.0001	< 0.0001	負向且 $q < 0.05$
任務三	XGBoost	0.8799	0.8798	-0.0000	0.7285	0.7285	未達 $q < 0.05$
任務三	LightGBM	0.8777	0.8820	+0.0043	0.1140	0.1324	未達 $q < 0.05$
任務三	ExtraTrees	0.8980	0.8836	-0.0144	< 0.0001	< 0.0001	負向且 $q < 0.05$
任務三	kNN	0.8933	0.8506	-0.0428	< 0.0001	< 0.0001	負向且 $q < 0.05$
任務三	SVC_RBF	0.8863	0.8670	-0.0193	< 0.0001	< 0.0001	負向且 $q < 0.05$
任務三	GaussianNB	0.8586	0.8349	-0.0238	< 0.0001	< 0.0001	負向且 $q < 0.05$
任務三	CatBoost	0.8828	0.8852	+0.0024	0.3488	0.3693	未達 $q < 0.05$

續下頁

任務	模型	Clin33 AUC	Clin33+FS AUC	Δ AUC	p	FDR q	重複切分判 準
任務三	TabPFN	0.9063	0.8976	-0.0087	< 0.0001	< 0.0001	負向且 $q < 0.05$

表 I.2 完整臨床基準下之任務層級 AUC 增量比較摘要

比較類型	任務	$q < 0.05$ 且 $\Delta > 0$	$q < 0.05$ 且 $\Delta < 0$	其餘	正向 Δ	平均 Δ AUC	Δ AUC 範圍
主要比較	任務一	0	8	4	2	-0.0053	[-0.0215, +0.0019]
	任務二	0	12	0	0	-0.0126	[-0.0341, -0.0030]
	任務三	0	9	3	2	-0.0148	[-0.0428, +0.0043]
補充比較	任務一	0	12	0	0	-0.1441	[-0.1678, -0.0718]
	任務二	0	12	0	0	-0.1512	[-0.1822, -0.1049]
	任務三	0	12	0	0	-0.1487	[-0.1647, -0.1084]

表 I.1 與表 I.2 顯示，三項任務共 36 個主要比較中，僅 4 個模型呈現正向平均 Δ AUC，且均未同時具有 $q < 0.05$ ；29 個模型則呈現負向平均 Δ AUC 且 $q < 0.05$ 。純影像方向相對完整臨床方向亦皆呈現負向平均差異。整體而言，在目前資料與設定下，加入 FreeSurfer 結構影像尚未形成跨任務與模型一致的正向 AUC 增量。

I.1 晚期融合權重之補充診斷




圖 I.1 E2d 全成員跨方向集成採 convexSL 時，Clin33、FS_topK 與 Clin33_FS_topK 三個資料方向之平均權重。

圖 I.1 顯示，任務一中 Clin33、FS_topK 與 Clin33_FS_topK 的平均權重分別為 45.3%、3.0% 與 51.7%；任務二分別為 97.6%、0.0% 與 2.4%，任務三則為 85.7%、0.0% 與 14.3%。其中，任務二與任務三的權重主要集中於完整臨床方向，三項任務對純影像方向分配的平均權重皆較低。

I.2 臨床加影像模型之預測相關性

作為集成結果之補充診斷，本研究計算 Clin33_FS_topK 下 12 個早期融合基礎模型與 NN_fusion OOF 預測間的 Pearson correlation。任務一、任務二與任務三之模型兩兩相關係數平均值分別為 0.848、0.831 與 0.815，顯示各模型預測具有相當程度的重疊。較高的預測相關性可能限制集成可利用的模型差異，可作為集成未形成穩定額外增益之補充觀察，但不單獨作為其原因之判定依據。

J 固定參數敏感度分析

本節補充第 4.8.1 節之固定參數敏感度分析，呈現固定參數設定及其與逐外層折調參版本之詳細比較結果。Phase 1 與完整臨床基準影像增量分析共包含 144 組可調參模型設定，其固定參數設定情形整理於表 J.1；Phase 1–3 與影像增量基礎模型之效能差異整理於表 J.2；固定參數版 Phase 1 OOF 預測重新進行 Phase 4 集成後之結果列於表 J.3；完整臨床基準下之最佳跨方向晚期融合比較則整理於表 J.4。其中， Δ 定義為固定參數版本減去逐折調參版本。

表 J.1 固定超參數眾數選取之穩定性摘要

分析集合	設定數	組合出現率中位數	單參數眾數比例中位數	未曾出現組合數
Phase 1 正式方向	45	45.0%	69.0%	0
完整臨床基準影像增量分析	99	49.0%	72.0%	0
合計	144	46.0%	70.5%	0

表 J.2 固定參數與逐折調參之 Phase 1–3 與影像增量主要差異摘要

階段	比較項目	指標	平均差異 (範圍) $ \Delta \leq 0.005$	
Phase 1	正式方向之線性模型	AUC	+0.0025 [−0.0182, +0.0095]	23/28
Phase 1	正式方向之非線性與樹系模型	AUC	+0.0012 [−0.0022, +0.0054]	15/17
影像增量	Clin33、FS_topK、Clin33_FS_topK	AUC	+0.0033 [−0.0001, +0.0129]	73/99
Phase 2	Platt 校準後	AUC	+0.0020 [−0.0182, +0.0095]	38/45
Phase 2	Platt 校準後	Brier	−0.0034 [−0.0155, +0.0006]	35/45
Phase 3	全部校準方法與操作目標	AUC	+0.0029 [−0.0182, +0.0190]	424/540
Phase 3	三種調整閾值目標	BalAcc	+0.0110 [−0.0122, +0.1211]	148/405
Phase 3	固定閾值 0.5	BalAcc	+0.0075 [−0.0442, +0.0947]	46/135

註： Δ 為固定參數版本減去逐折調參版本；Brier score 之負差異表示固定參數版本誤差較低。

表 J.3 Phase 4 最佳集成管線之固定參數敏感度摘要

階段	分析單位數	最佳設定相同	平均 Δ BalAcc	平均 $ \Delta$ BalAcc	平均 $ \Delta$ AUC
Stage 1	7	0/7	+0.0045	0.0051	0.0021
Stage 2	6	2/6	+0.0035	0.0035	0.0029

表 J.4 完整臨床基準下最佳晚期融合之固定參數敏感度比較

任務	逐折調參最佳設定	固定參數最佳設定	設定相同	BalAcc _{tuned}	BalAcc _{fixed}	AUC _{tuned}	AUC _{fixed}
任務一	E2d / E2d / perf	E2d / E2d / perf	是	0.8417	0.8484	0.9220	0.9232
任務二	E2a / E2a ExtraTrees / convexSL	E2a / E2a ExtraTrees / convexSL	是	0.8362	0.8435	0.9225	0.9225
任務三	E2a / E2a TabPFN / perf	E2a / E2a TabPFN / perf	是	0.8049	0.8049	0.8953	0.8953

綜合表 J.1 至表 J.4，所有固定參數組合皆曾於原外層折中實際出現。固定參數與逐折調參版本在 AUC 等排序能力指標上的差異整體較小，而 BalAcc 等閾值相關指標之變動相對較明顯。Phase 4 中部分最佳集成設定雖隨參數設定方式改變，但 BalAcc 與 AUC 的最終效能差異整體有限；完整臨床基準下三項任務之最佳跨方向晚期融合設定則在兩版本中皆保持一致。整體而言，固定參數與逐折調參版本在主要模型比較與結果趨勢上大致一致，不同超參數設定方式未造成明顯的整體結果改變。